

سوال ۱: SVD

$$A \in \mathbb{R}^{m \times n}, \text{rank}(A) = r$$

$$A = U_{m \times m} \underbrace{\sum_{m \times n}}_{\text{نشیء قطری}} V_{n \times n}^T$$

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$$

$$U^{-1} = U^T, V^{-1} = V^T$$

$$U^T U = I, V^T V = I$$

بخش الف)

ترمیم: چون مقادیر σ_i و نرم نامعینی هستند مشکلی ایجاد نمی کند.

اثبات را با ترمین ℓ_2 نرم شروع می کنیم.

$$\|A\|_F^2 = \max_{\|x\|_2=1} \|Ax\|_2^2 = \max_{\|x\|_2=1} (Ax)^T (Ax)$$

تعریف نرم ℓ_2 ترمین ℓ_2

$$= \max_{\|x\|_2=1} x^T A^T A x$$

$$A = U \Sigma V^T$$

حال تعریف SVD را جایگزین می کنیم در رابطه $A^T A$:

$$A^T A = (U \Sigma V^T)^T (U \Sigma V^T) = (V \Sigma^T U^T) (U \Sigma V^T) = V \Sigma^T (U^T U) \Sigma V^T$$

$$A^T A = V (\Sigma^T \Sigma) V^T$$

چون $U^T U = I$ ماتریس متعامد است.

حال در عبارت $\|A\|_F^2$ آن را جایگزین می کنیم:

$$\|A\|_F^2 = \max_{\|x\|_2=1} x^T V (\Sigma^T \Sigma) V^T x = \max_{\|x\|_2=1} \underbrace{(V^T x)^T}_{y} (\Sigma^T \Sigma) \underbrace{(V^T x)}_y$$

حال یک بردار جدید به شکل $y = V^T x$ تعریف می کنیم. چون V متعامد است اندازه norm را حفظ می کند. بنابراین $\|y\|_2 = \|V^T x\|_2 = \|x\|_2 = 1$

در تعریف spectral norm آن را داریم. Shahed

پس شرط $\|y\|_2 = 1$ تبدیل به شرط $\|y\|_2 = 1$ شود.

$$y = V x \quad \text{تغییر متغیر} \rightarrow \|A\|_2^2 = \max_{\|y\|_2=1} y^T (\Sigma^T \Sigma) y$$

$$\rightarrow \|A\|_2^2 = \max_{\|y\|_2=1} \|\Sigma y\|_2^2$$

توجه کنید که $\Sigma^T \Sigma$ یک ماتریس قطری است که درایه های قطر اصلی آن مقدارهای تکی به توان ۲ هستند.

$$\Sigma^T \Sigma = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2, 0, \dots, 0) \in \mathbb{R}^{n \times n}$$

$$\|A\|_2^2 = \max_{\|y\|_2=1} \sum_{i=1}^n \sigma_i^2 y_i^2 \quad (\sigma_i = 0 \text{ for } i > r) \quad \text{پس،}$$

ما می خواهیم این عبارت را با شرط $\sum_{i=1}^n y_i^2 = 1$ بیشینه کنیم.

هرچنین توجه کنید که چون مقادیر تکی σ_i شده اند پس بزرگترین آن ها σ_1 است.

$$\max_{1 \leq i \leq n} (\sigma_i) = \sigma_1, \quad y^T \Sigma^T \Sigma y = \sum_{i=1}^n \sigma_i^2 y_i^2$$

یک جمع وزن دار با وزن های σ_i^2
اعداد مثبت

برای بیشینه کردن عبارت باید همه وزن ها را به بزرگترین ضریب بدسیم که این معادل آن است که:

$$\left. \begin{array}{l} y_1 = 1 \\ y_i = 0 \text{ for all } i > 1 \end{array} \right\} \rightarrow y = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = e_1$$

بنابراین بزرگترین مقدار ممکن برابر است با: $y = e_1$

$$\|A\|_F^2 = \max_{\|y\|_2=1} \sum_{i=1}^n \sigma_i^2 y_i^2 = \sigma_1^2 x_1 + \sigma_2^2 x_2 + \dots + \sigma_n^2 x_n$$

$$\|A\|_F^2 = \sigma_1^2$$

همچنین توجه کنید که جوابی $\|A\|_F^2$ هم σ_1^2 است چرا که:

$$\|Ay\|_2^2 = \sum_{i=1}^r \sigma_i^2 y_i^2 \leq \sigma_1^2 \sum_{i=1}^r y_i^2 \leq \sigma_1^2 \|y\|_2^2 = \sigma_1^2$$

$\sigma_i \leq \sigma_1$

این عبارت با انتخاب $y = e_1$ حسابی شد $\rightarrow \|A\|_F^2 \leq \sigma_1^2$

* نکته: $y = e_1$ معادل انتخاب $x = v_1$ است. first right singular vector of V

$$y = V^T x \rightarrow Vy = VV^T x \rightarrow Vy = x$$

$\downarrow e_1 = v$

$$Ve_1 = x \rightarrow \boxed{x = v_1}$$

در نهایت چون می دانیم مقادیر تکین و norm نامنفی هستند با ارفتن ریشه دوم عبارت خواسته شده را اثبات می کنیم.

$$\|A\|_F^2 = \sigma_1^2 \xrightarrow{\text{square root}} \boxed{\|A\|_F = \sigma_1} \quad \square$$



Date:

Subject:

3

(ب) تجزیه مقدار تکی و تجزیه ویژه این ~~ماتریس~~ ماتریس یکسان است.

$$A \in \mathbb{R}^{n \times n}$$

$$A = A^T$$

A is positive

semidefinite

$$\Rightarrow A = U \Sigma V^T = P D P^T$$

$$\Sigma = D, U = P, V = P \rightarrow V^T = P^T$$

توجیه: فرض کنید $A \in \mathbb{R}^{n \times n}$ یک ماتریس متقارن و معین نیم مثبت (PSD) باشد پس A یک تجزیه ویژه به شکل زیر دارد:

$$A = P D P^T$$

که در آن P یک ماتریس متعامد و $D = \text{diag}(\lambda_1, \dots, \lambda_n)$ با $\lambda_i \geq 0$ (مقادیر ویژه نامنفی) است.

چون A ماتریس متقارن PSD است مقادیر ویژه نامنفی دارد. ($\lambda_i \geq 0$)

بیا بر آن را با SVD ($A = U \Sigma V^T$) مقایسه کنیم. برای هر ماتریس حقیقی داریم:

$$A^T A = V \Sigma^T \underbrace{U^T U}_I \Sigma V^T = V \Sigma^T \Sigma V^T$$

$$A A^T = U \Sigma \underbrace{V^T V}_I \Sigma^T U^T = U \Sigma \Sigma^T U^T$$

$$A^T = A$$

چون A متقارن است پس: $A^T A = A A = A^2 = A^T A$

$$A^2 = (P D P^T)(P D P^T) = P D^2 P$$

بنابراین بردار ویژه های A و A^2 یکسان هستند. یعنی بردار ویژه های A هم A و هم A^2 را قطری می کنند.

معین چون A معین ~~نیم مثبت~~ است مقدار ویژه های λ_i نامنفی اند پس می توانیم $\lambda_i \geq 0$ را در نظر بگیریم. (توضیح صفر بعد)

Date:

Subject:



مقادیر تکین A برابر $\sqrt{\text{eigenvalues of } A^T A}$ هستند. برای
ماتریس متقارن A ، مقدار ویژه های $A^T A = A^2$ برابر λ_i^2 اند
پس $\sigma_i = |\lambda_i|$

حال چون A یک ماتریس PSD است $\lambda_i \geq 0$ پس $|\lambda_i| = \lambda_i$
پس مقادیر تکین برابر با مقدار ویژه ها هستند. $\sigma_i = \lambda_i$

همچنین تجربه کنید که بردار تکین های راست و چپ منطبق بر بردار ویژه
های شوند یعنی $U = V = P$

بنابراین برای یک ماتریس متقارن معین نیم مثبت تجزیه SVD
و تجزیه ویژه یک factorization یکسان هستند.

$$A = U \Sigma V^T$$

که $\Sigma = D$ و $U = P$ و $V^T = P^T$ است.

نکته: اگر A متقارن بود ولی PSD نبود، آنرا SVD ~~نه~~

مقادیر تکین برابر با قدر مطلق مقادیر ویژه می شدند و بردار تکین

ها بردار ویژه ها بودند. علامت ها هم توسط U و V جذب می شدند.

Shahed

$$k \leq r$$

$$\|A - A_k\|_2 = \sigma_{k+1} \quad \text{اثبات قضیه}$$

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T$$

طبق تجزیه SVD می دانیم که:

همچنین بهترین تقریب مرتبه k ماتریس A نیز بوسیله تجزیه SVD میسر می شود:

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$$

بنابراین ماتریس خطای تقریب برابر است با:

$$A - A_k = \sum_{i=1}^r \sigma_i u_i v_i^T - \sum_{i=1}^k \sigma_i u_i v_i^T = \sum_{i=k+1}^r \sigma_i u_i v_i^T + \sum_{i=1}^k \sigma_i u_i v_i^T - \sigma_i u_i v_i^T$$

$$\rightarrow A - A_k = \sum_{i=k+1}^r \sigma_i u_i v_i^T \quad A - A_k = U(\Sigma - \Sigma_k)V$$

* نکته کلیدی: توجه کنید که عبارت به دست آمده خود یک تجزیه SVD است!

چرا که ماتریس $A - A_k$ دارای:

- بردارهای تکی چپ (left singular vectors) $u_{k+1}, u_{k+2}, \dots, u_r$ است.
- بردارهای تکی راست (right singular vectors) $v_{k+1}, v_{k+2}, \dots, v_r$ است.
- مقدارهای تکی $\sigma_{k+1}, \sigma_{k+2}, \dots, \sigma_r$ به صورت نزولی است.

از بخش الف همین سوال می دانیم که spectral norm ماتریس A دقیقاً برابر با بزرگترین مقدار تکی آن است. همچنین چون $\sigma_{k+1} \geq \sigma_{k+2} \geq \dots \geq \sigma_r$ پس بزرگترین مقدار تکی ماتریس $A - A_k$ برابر σ_{k+1} است.

$$A - A_k = \sum_{i=k+1}^r \sigma_i u_i v_i^T \rightarrow \|A - A_k\|_F = \max(\sigma_{k+1}, \sigma_{k+2}, \dots, \sigma_r) = \sigma_{k+1}$$

تجزیه SVD

$$\|A - A_k\|_2 = \sigma_{k+1} \quad \square$$

بخش d) خیر- تجزیه SVD یک ماتریس A لزوماً یکتا نیست.

ولی جنبه های خاصی unique است درحالی که بقیه جنبه ها unique نیست.

جنبه های unique:

۱. مقدار تکیه: مجموعه مقادیر تکیه $\{\sigma_1, \sigma_2, \dots, \sigma_r\}$ به همراه multiplicity آنها به صورت unique توسط A تعیین می شود.

۲. Singular subspaces: برای هر مقدار تکیه متمایز σ_i زیرفضاهای:

$$\text{span}\{u_i : \sigma_i = \sigma_i\} \leftarrow \text{left singular subspace}$$

$$\text{span}\{v_i : \sigma_i = \sigma_i\} \leftarrow \text{right singular subspace}$$

به صورت unique توسط ماتریس A تعیین می شوند.

جنبه های غیر unique:

۱. مقدار تکیه های تکراری: اگر $\sigma_i = \sigma_j$ برای $i \neq j$ (multiplicity > 1) آنگاه هر پایه متعامد نرمال متناظر با زیرفضای تکیه قابل استفاده در SVD است. ما می توانیم هر تبدیل خطی orthonormal نظیر rotation یا reflection را روی یک زیرفضای سازش پایه های جدید استفاده کنیم. مثلاً اگر $\sigma_1 = \sigma_2 = \sigma_3$ ما می توانیم (u_1, u_2, u_3) را با هر پایه orthonormal زیرفضای $\text{span}\{u_1, u_2, u_3\}$ جایگزین کنیم و به طور مشابه برای (v_1, v_2, v_3) نیز انجام دهیم.

۲. ابهام علامت (sign ambiguity):

برای هر جفت مقدار تکیه (u_i, v_i) ما می توانیم آن را با $(-u_i, -v_i)$ جایگزین کنیم چرا که

$$\sigma_i u_i v_i^T = \sigma_i (-u_i) (-v_i)^T$$

Shahed



$$\sigma_i = 0$$

۳. مقدار تکیه های صفری: هنگام گسترش به full SVD (که $U \in \mathbb{R}^{m \times m}$ و $V \in \mathbb{R}^{n \times n}$)، بردار تکیه های متناظر با مقدار تکیه های صفری می توانند هر پایه orthonormal null space های $Null(A)$ و $Null(A^T)$ به ترتیب باشند. بنابراین آزادی قابل ترجمه در انتخاب ستون های مربوط به $\sigma_i = 0$ در U و V وجود دارد.

خلاصه: SVD یک ساختار هندسی ~~منحصربه فرد~~ (مقادیر تکیه وزیر فضا های مرتبط) ارائه می دهد، اما انتخاب خاص پایه های متعامد در زیر فضا های منحصربه فرد نیست. (valid) در عمل، الگوریتم های عددی ممکن است SVD های متفاوتی برای یک ماتریس یکسان به خصوص زمانی که مقادیر تکیه مکرر وجود دارد به ترانند.

سوال ۲ کانولوشن با کرنل گاوسی و صوار سازی سیگنال

$$\text{بخش الف) اثبات } \frac{d}{dt}(f * g) = f * \frac{d}{dt}g$$

از تعریف کانولوشن شروع می کنیم:

$$(f * g)(t) = \int_{-\infty}^{\infty} f(\tau) g(t - \tau) d\tau$$

$$\frac{d}{dt}$$

حال از دو طرف نسبت به t مشتق می گیریم:

$$\frac{d}{dt}(f * g)(t) = \frac{d}{dt} \int_{-\infty}^{\infty} f(\tau) g(t - \tau) d\tau$$

می توانیم در طرف راست مشتق را وارد انتگرال کنیم بر وسیله قانون Leibniz rule. همچنین توجه کنید $f(\tau)$ تابعی از t نیست و عدد ثابت است. 8



چرا می توانیم مشتق و انتگرال را جابه جا کنیم؟

جابه جایی مشتق و انتگرال توسط قاعده انتگرال لایب نیتس (مشتق گیری زیر علامت انتگرال) که به دو شرط اصلی نیاز دارد: ۱- انتگرال گیرنده باید نسبت به پارامتر t برای هر x ثابت مشتق پذیر باشد و ۲- مشتق باید یک شرط تسلط یکنواخت (uniform domination condition) را برآورده کند. باید یک تابع انتگرال گیر $M(x)$ وجود داشته باشد که $|f'(t-x)|$ و $f(x)$ را به طور یکنواخت روی مقادیر t کران دار کند. شرط اول به راحتی برآورده می شود زیرا گاوسی به طور نامتناهی مشتق پذیر است؛ بنابراین $g(t-x)$ و مشتقات آن نسبت به t وجود دارد و صواب است. هستند.

شرط دوم (uniform domination) به دلیل ویژگی گاوسی بنامی گاوسی به قرار است. گاوسی و تمام مشتقات آن سریع تر از هر چند جمله ای گاوسی می یابند. e^{-t^2} و با سرعت بسیار زیادی به صفر میل می کند وقتی که $|t| \rightarrow \infty$ ، حتی اگر سیگنال f به صورت چند جمله ای رشد کند (یا کران دار باشد)، حاصل ضرب $g(t-x)f(x)$ تحت تسلط گاوسی بنامی $M(x)$ قرار دارد. این بدان معناست که می توانیم یک تابع انتگرال پذیر $M(x)$ پیدا کنیم که جبهه مشتق را برای تمام مقادیر مربوط t به طور یکنواخت کران دار کند و تضمین کند که انتگرال $\int_{-\infty}^{\infty} M(x) dx$ همگرا می شود.

در واقع $smoothness$ نامتناهی گاوسی (که تضمین می کند مشتق وجود دارند) و گاوسی بنامی آن را مناسب برای جابه جایی عملیات مشتق و انتگرال می کند. این یکی از دلایل متعددی گاوسی ها در تحلیل ریاضی و پردازش سیگنال بسیار بنیادی هستند.

Shahed

$$\frac{d}{dt}(f * g)(t) = \int_{-\infty}^{\infty} f(\tau) \left[\frac{d}{dt} g(t-\tau) \right] d\tau$$

حال با استفاده از chain rule مشتق را معادله می کنیم.

$$u = t - \tau$$

$$\frac{du}{dt} = 1 \rightarrow \frac{d}{dt} g(t-\tau) = g'(t-\tau) \frac{d(t-\tau)}{dt} = g'(t-\tau) \cdot 1 = \frac{dg}{dt}(t-\tau)$$

$$\frac{d}{dt}(f * g)(t) = \int_{-\infty}^{\infty} f(\tau) \frac{dg}{dt}(t-\tau) d\tau$$

حال آن را در انتگرال جایگذاری می کنیم:

عبارت درست آمده طبق تعریف کانولوشن برابر با کانولوشن f با $\frac{dg}{dt}$ است.

$$\frac{d}{dt}(f * g)(t) = \int_{-\infty}^{\infty} f(\tau) \frac{dg}{dt}(t-\tau) d\tau = (f * \frac{dg}{dt})(t) = (f * g)'(t)$$

$$\rightarrow \boxed{\frac{d}{dt}(f * g)(t) = (f * \frac{dg}{dt})(t)} \quad \square$$

۲. کرنل گاوسی $g(t) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{t^2}{2\sigma^2}}$ یک ویژگی قابل توجه دارد.

این کرنل بی‌نهایت بار مشتق پذیر است ($g \in C^\infty$) یعنی تمامی

مشتق‌های $\frac{dg}{dt}, \frac{d^2g}{dt^2}, \frac{d^3g}{dt^3}, \dots$ موجودند و پیوسته و مشتق پذیر هستند.

در واقع هر مشتق ضرب یک چندجمله‌ای در یک تابع گاوسی است. چنین تابعی بسیار smooth است و طبق قضیه قسمت ۱ سیگنالی را نتیجتاً می‌دهد که هموار است. در منحنی بعد ~~توضیحات~~ آورده است.

Shahed

چرا این ویژگی smoothness ایجاد می کنند؟

با استفاده از قضیه مشتق کانولوشن به صورت مکرر حتی برای یک سیگنال ناپیوسته نظیر یک پله داریم:

- مشتق اول: $\frac{d}{dt}(f * g) = f * \frac{dg}{dt}$ موجود است چرا که $\frac{dg}{dt}$ موجود است.

- مشتق دوم: $\frac{d^2}{dt^2}(f * g) = f * \frac{d^2g}{dt^2}$ موجود است چرا که $\frac{d^2g}{dt^2}$ موجود است.

- مشتق n ام: $\frac{d^n}{dt^n}(f * g) = f * \frac{d^ng}{dt^n}$ موجود است برای هر n دلخواه.

ایده کلیدی: smoothness از kernel به نتیجه انتقال پیدا می کند. اثر چه

ممکن است f ناپیوسته و مشتق ناپذیر باشد ولی نتیجه حاصل از

کانولوشن $f * g$ بینهایت مشتق پذیر بودن را از kernel به ارث می برد.

این اتفاق می افتد زیرا کانولوشن اساساً یک میانگین وزنی از سیگنال است و جایی که فیلتر گاوسی وزن های همجوار و روبه گاهش ارائه می دهد هر نقطه از خروجی ترکیبی هموار از مقدار ورودی است و هرگونه انتقال و ناپیوستگی شدید را از بین می برد.

Shahed

ب) ۱. طبق قضیه فوری کانولوشن داریم:

$$F\{f * g\}(\omega) = F\{f\}(\omega) \cdot F\{g\}(\omega)$$

حقیقت کلیدی: تبدیل فوری یک سیگنال گاوسی، خودش یک سیگنال گاوسی است.

$$g(t) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{t^2}{2\sigma^2}} \xrightarrow[\text{تبدیل فوری}]{F} G(\omega) = e^{-\frac{\sigma^2 \omega^2}{2}}$$

توجه شود که مهم شکل سیگنال است چون ضرایب ثابت آنها متفاوت است.

$$F\{h\}(\omega) = \int h(t) e^{-i\omega t} dt$$

چرا تابع گاوسی مانند low-pass filter عمل می کند؟

۱. بیشینه مقدار در فرکانس صفر است. ($G(0) = 1$)

۲. monotonic decay: با افزایش $|\omega|$ تابع $G(\omega)$ به شکل نمایی کاهش می یابد.

۳. معیاری سریع در فرکانس های بالا: $G(\omega) = 0$ برای مقادیر بزرگ $|\omega|$

وقتی spectra ها قریب می شوند:

$$\text{output spectra} = F(\omega) \cdot G(\omega)$$

- برای فرکانس های پایین ($\omega \approx 0$): $G(\omega) \approx 1$ ← اجزای سیگنال حفظ می شوند.

- برای فرکانس های بالا ($\text{large } |\omega|$): $G(\omega) \approx 0$ ← اجزای سیگنال فشرده و حذف می شوند.


باتوجه به ویژگی های بالا نتیجه می گیریم که این یک فیلتر رفتاری مشابه

فیلتر پایین گذر دارد. Shaked

تفسیر فیزیکی: فرکانس های بالا نشان دهنده نوسانات سریع، لبه های تیز، نویز و جزئیات دقیق هستند.
فرکانس های پایین نشان دهنده تغییرات آهسته و ساختار کلی سیگنال هستند. فیلتر گاوسی مانند یک دکه صدا عمل می کند که با افزایش فرکانس، صدای آن به تدریج کاهش می دهد.

نتیجه: نویز و نوسانات سریع حذف می شوند درحالی که شکل کلی باقی می ماند.

از نظر هندسی نیز شباهت زیادی با فیلتر پایین گذر وجود دارد.



۲. بین عرض یک تابع در حوزه زمان و عرض تبدیل فوریه آن رابطه معکوس وجود دارد.
(fundamental reciprocal relationship)

در حوزه زمان یک سیگنال گاوسی با انحراف معیار $\sigma_t = \sigma$ برابر است با:

$$g(t) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{t^2}{2\sigma^2}} \rightarrow \sigma_t = \sigma$$

در حوزه فرکانس یک سیگنال گاوسی با انحراف معیار $\sigma_\omega = \frac{1}{\sigma}$

$$G(\omega) = e^{-\frac{\sigma^2 \omega^2}{2}} = e^{-\frac{\omega^2}{2 \times (\frac{1}{\sigma})^2}} \rightarrow \sigma_\omega = \frac{1}{\sigma}$$

Shahed

رابطه معکوس به شکل زیر است:

$$\sigma_t \cdot \sigma_\omega = \sigma \times \frac{1}{\sigma} = 1$$

این نمودی از اصل عدم قطعیت در پردازش سیگنال است.

اثر افزایش σ (wider time domain gaussian):

۱. حوزه زمان: فیلتر پهن تر می شود و میانگین آن روی یک همسایگی بزرگتر گرفته می شود.

۲. حوزه فرکانس: تابع گاوسی باریک تر می شود ($\frac{1}{\sigma}$ کوچکتر) و با افزایش فرکانس سریع تر افت می کند.

۳. فرکانس قطع (Cut off) کاهش می یابد؛ فرکانس های بیشتری تضعیف می شوند.

۴. نتیجه: فیلتر پایین گذر قوی تر ← هموارسازی شدیدتر

خلاصه:

- σ کوچک: Smoothing ملایم تر که جزئیات بیشتری را حفظ می کند.
- σ بزرگ: Smoothing شدید، حذف جزئیات ریز و ایجاد تارری
- انتخاب σ یک trade off بین کاهش نویز و حفظ ویژگی و جزئیات سیگنال است.

این رابطه معکوس برای بسیاری از کاربردهای پردازش سیگنال اساسی است و نشان دهنده trade off ذاتی بین localization در حوزه های زمان و فرکانس است.

$$\sigma \text{ small} \rightarrow g(t) \text{ is narrow} \rightarrow G(\omega) \text{ is wide}$$

$$\sigma \text{ large} \rightarrow g(t) \text{ is wide} \rightarrow G(\omega) \text{ is narrow}$$

Shahed