



امنیت و حریم خصوصی در یادگیری ماشین (۴۰۸۱۶)
نیمسال اول سال تحصیلی ۱۴۰۴-۱۴۰۵
استاد درس: دکتر امیرمهدی صادقزاده

طراحان: فیروزه ابریشمی، علیرضا فرج تبریزی

مهلت تحویل: ساعت ۲۳:۵۹:۵۹ ۵ آذر ۱۴۰۴

پاسخنامه تمرین شماره ۱

نکات و قواعد

۱. سوالات خود را زیر پیام مربوطه در Quera با گروه درس مطرح نمایید.
۲. لطفا مطابق تاکید پیشین، حتما آدابنامه‌ی انجام تمرین‌های درسی را رعایت نمایید. در صورت تخطی از آیین‌نامه، در بهترین حالت مجبور به حذف درس خواهید شد.
۳. از تحویل تمرین نظری به شکل تایپ شده (فایل Word-Latex یا هر نوع تایپ شده دیگری) بهره‌ییزید و حتما پاسخ دست نویس تحویل دهید.
۴. در صورتی که پاسخ‌های سوالات نظری را به صورت دست‌نویس آماده کرده‌اید، لطفا تصاویر واضحی از پاسخ‌های خود ارسال کنید. در صورت ناخوانا بودن پاسخ ارسالی، نمره‌ای به پاسخ ارسال شده تعلق نمی‌گیرد.
۵. همه‌ی فایل‌های مربوط به پاسخ خود را در یک فایل فشرده و با نام SPML_HW1_StdNum_FirstName_LastName ذخیره کرده و ارسال نمائید.

سوال ۱ لیپشیتس (۷۰+۹۰ نمره)

بخش اول) خواص پایه‌ای توابع لیپشیتس (۳۰+۳۰ نمره)

در این بخش، چند خاصیت بنیادی توابع لیپشیتس را که به عنوان ابزارهای ریاضی برای تحلیل شبکه‌های عصبی به کار می‌روند، اثبات و بررسی می‌کنیم.

۱. جمع توابع لیپشیتس (۱۰ نمره): ثابت کنید اگر $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ یک تابع L_f -لیپشیتس و $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ یک تابع L_g -لیپشیتس باشد، آنگاه تابع مجموع $h(x) = f(x) + g(x)$ نیز لیپشیتس است. کران بالای ثابت لیپشیتس آن (L_h) چیست؟

جواب سوال:

اثبات: برای بررسی شرط لیپشیتس برای تابع $h(x) = f(x) + g(x)$ ، نرم تفاضل خروجی‌ها را برای دو نقطه دلخواه x و y محاسبه می‌کنیم:

$$\|h(x) - h(y)\| = \|(f(x) + g(x)) - (f(y) + g(y))\|$$

با دسته‌بندی جملات مربوط به هر تابع:

$$= \|(f(x) - f(y)) + (g(x) - g(y))\|$$

طبق نامساوی مثلثی ($\|a + b\| \leq \|a\| + \|b\|$) داریم:

$$\leq \|f(x) - f(y)\| + \|g(x) - g(y)\|$$

اکنون از فرض لیشیتس بودن توابع f و g استفاده می‌کنیم:

$$\begin{aligned} &\leq L_f \|x - y\| + L_g \|x - y\| \\ &= (L_f + L_g) \|x - y\| \end{aligned}$$

نتیجه: تابع h در شرط لیشیتس صدق می‌کند و کران بالای ثابت لیشیتس آن برابر است با مجموع ثابت‌های دو تابع:

$$L_h = L_f + L_g$$

۲. ترکیب توابع لیشیتس (۱۰ نمره):

(الف) اثبات خاصیت ترکیب: ثابت کنید اگر $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ یک تابع L_g -لیشیتس و $f: \mathbb{R}^m \rightarrow \mathbb{R}^k$ یک تابع L_f -لیشیتس باشد، آنگاه تابع مرکب $h(x) = f(g(x))$ نیز یک تابع لیشیتس است. کران بالای ثابت لیشیتس آن (L_h) چیست؟

جواب سوال:

اثبات: برای بررسی شرط لیشیتس تابع مرکب $h(x) = f(g(x))$ ، مقدار $\|h(x) - h(y)\|$ را برای دو ورودی دلخواه x, y در نظر می‌گیریم:

$$\|h(x) - h(y)\| = \|f(g(x)) - f(g(y))\|$$

۱. ابتدا از خاصیت لیشیتس بودن تابع بیرونی (f) استفاده می‌کنیم. اگر ورودی‌های f را $u = g(x)$ و $v = g(y)$ فرض کنیم، داریم:

$$\|f(u) - f(v)\| \leq L_f \|u - v\| \implies \|f(g(x)) - f(g(y))\| \leq L_f \|g(x) - g(y)\|$$

۲. سپس از خاصیت لیشیتس بودن تابع درونی (g) استفاده می‌کنیم:

$$\|g(x) - g(y)\| \leq L_g \|x - y\|$$

۳. با جایگذاری رابطه دوم در رابطه اول، به نامساوی نهایی می‌رسیم:

$$\|h(x) - h(y)\| \leq L_f (L_g \|x - y\|) = (L_f \cdot L_g) \|x - y\|$$

نتیجه: تابع ترکیب h نیز یک تابع لیشیتس است و ثابت لیشیتس آن برابر با حاصل ضرب ثابت‌های دو تابع است:

$$L_h = L_f \cdot L_g$$

(ب) کران ثابت لیشیتس یک لایه: یک لایه شبکه عصبی به صورت $f_k(x) = \sigma(W_k x)$ را در نظر بگیرید که در آن σ یک تابع فعال‌سازی^۱ L_σ -لیشیتس و W_k ماتریس وزن است. با استفاده از خاصیت ترکیب توابع که در بند (الف) اثبات کردید، نشان دهید که ثابت لیشیتس این لایه (L_k) توسط $L_k \leq L_\sigma \cdot \|W_k\|_2$ کران‌دار می‌شود. (یادآوری: ثابت لیشیتس تبدیل خطی $x \mapsto Wx$ برابر با نورم طیفی ماتریس، یعنی $\|W\|_2$ است).

جواب سوال:

اثبات: تابع لایه $f_k(x)$ را می‌توان به صورت ترکیب دو تابع در نظر گرفت:

$$f_k(x) = \sigma(g(x)) \quad \text{که در آن} \quad g(x) = W_k x$$

۱. تحلیل تبدیل خطی (g): تابع $g(x)$ یک تبدیل خطی است. طبق تعریف نورم ماتریسی القایی (و یادآوری سوال)، برای هر x, y داریم:

$$\|W_k x - W_k y\|_2 = \|W_k(x - y)\|_2 \leq \|W_k\|_2 \|x - y\|_2$$

^۱ Activation Function

بنابراین ثابت لیشیتس تابع g برابر است با $L_g = \|W_k\|_2$.
۲. استفاده از خاصیت ترکیب: طبق فرض، تابع بیرونی σ دارای ثابت لیشیتس L_σ است. بنابر خاصیت ترکیب توابع (اثبات شده در بند قبل)، ثابت لیشیتس کل تابع برابر با حاصل ضرب ثابت‌های اجزای آن است:

$$L_k \leq L_\sigma \cdot L_g$$

با جایگذاری مقدار L_g به نتیجه مورد نظر می‌رسیم:

$$L_k \leq L_\sigma \cdot \|W_k\|_2$$

۳. ارتباط با مشتق (۱۰+۳۰ نمره):

(الف) حالت یک‌بعدی: برای یک تابع مشتق‌پذیر $f: \mathbb{R} \rightarrow \mathbb{R}$ ، ثابت کنید که f یک تابع L -لیشیتس است اگر و تنها اگر برای تمام مقادیر x داشته باشیم $|f'(x)| \leq L$.

جواب سوال:

اثبات دو طرفه:

i. ($\Leftarrow$) شرط کافی: فرض کنیم برای تمام x ها، $|f'(x)| \leq L$ باشد. برای هر دو نقطه متمایز $x, y \in \mathbb{R}$ ، بنابر قضیه مقدار میانگین (MVT)، نقطه‌ای مانند c بین x و y وجود دارد که:

$$f(y) - f(x) = f'(c)(y - x)$$

با گرفتن قدرمطلق از طرفین و استفاده از کران مشتق ($|f'(c)| \leq L$):

$$|f(y) - f(x)| = |f'(c)| \cdot |y - x| \leq L|y - x|$$

که همان شرط لیشیتس است.

ii. ($\Rightarrow$) شرط لازم: فرض کنیم f یک تابع L -لیشیتس باشد. یعنی برای هر $x \neq y$:

$$|f(y) - f(x)| \leq L|y - x| \implies \left| \frac{f(y) - f(x)}{y - x} \right| \leq L$$

حال حد $x \rightarrow y$ را محاسبه می‌کنیم. چون تابع مشتق‌پذیر است و نامساوی بالا برای تمام y ها برقرار است، برای حد نیز برقرار می‌ماند:

$$|f'(x)| = \lim_{y \rightarrow x} \left| \frac{f(y) - f(x)}{y - x} \right| \leq L$$

(ب) شرط کافی برای لیشیتس بودن در حالت کلی: (امتیازی، اما در صورت استفاده در بخش‌های بعدی باید آن را ثابت کنید).

ثابت کنید اگر تابع $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ در یک مجموعه محدب^۲ D مشتق‌پذیر باشد و نرم طیفی^۳ ماتریس ژاکوبین^۴ آن برای تمام $x \in D$ کران‌دار باشد (یعنی $\|J_f(x)\|_2 \leq L$)، آنگاه f در آن مجموعه یک تابع L -لیشیتس است. راهنمایی اثبات:

- (گام ۱) تابع کمکی $g(t) = f(y + t(x - y))$ را برای $t \in [0, 1]$ تعریف کنید.
- (گام ۲) با استفاده از قضیه اساسی حسابان نشان دهید $f(x) - f(y) = \int_0^1 g'(t) dt$.
- (گام ۳) مشتق $g'(t)$ را با قاعده زنجیره‌ای بر حسب ژاکوبین J_f بیابید. سپس از طرفین انتگرال نورم بگیرید و با استفاده از نامساوی مثلثی برای انتگرال‌ها $(\| \int h(t) dt \|_2 \leq \int \|h(t)\|_2 dt)$ و فرض کران‌دار بودن $\|J_f\|_2 \leq L$ اثبات را کامل کنید.

جواب سوال:

اثبات: فرض کنیم $x, y \in D$ دو نقطه دلخواه باشند. چون مجموعه D محدب است، پاره‌خط واصل بین x و y

^۲Convex Set

^۳Spectral Norm

^۴Jacobian Matrix

کاملاً درون دامنه قرار دارد.

گام ۱: تعریف تابع کمکی تابع مسیر $g : [0, 1] \rightarrow \mathbb{R}^m$ را به صورت زیر تعریف می‌کنیم:

$$g(t) = f(y + t(x - y))$$

در اینجا $y + t(x - y)$ نقاط روی پاره‌خط هستند. توجه داریم که $g(0) = f(y)$ و $g(1) = f(x)$.

گام ۲: استفاده از قضیه اساسی حسابان چون f مشتق‌پذیر است، $g(t)$ نیز مشتق‌پذیر است. طبق قضیه اساسی حسابان برای توابع برداری داریم:

$$g(1) - g(0) = \int_0^1 g'(t) dt \implies f(x) - f(y) = \int_0^1 g'(t) dt$$

گام ۳: محاسبه مشتق و اعمال نرم طبق قاعده زنجیره‌ای، مشتق $g(t)$ برابر است با ضرب ماتریس ژاکوبین در مشتق آرگومان نسبت به t :

$$g'(t) = J_f(y + t(x - y)) \cdot \frac{d}{dt}(y + t(x - y)) = J_f(y + t(x - y)) \cdot (x - y)$$

حال از طرفین رابطه انتگرالی نرم می‌گیریم:

$$\|f(x) - f(y)\|_2 = \left\| \int_0^1 J_f(y + t(x - y))(x - y) dt \right\|_2$$

طبق نامساوی مثلثی برای انتگرال‌ها $(\| \int f h \| \leq \int \| h \|)$:

$$\leq \int_0^1 \|J_f(y + t(x - y))(x - y)\|_2 dt$$

طبق خاصیت سازگاری نرم ماتریس و بردار $(\|Ax\| \leq \|A\| \|x\|)$:

$$\leq \int_0^1 \|J_f(y + t(x - y))\|_2 \cdot \|x - y\|_2 dt$$

طبق فرض سوال، نرم طیفی ژاکوبین در تمام نقاط دامنه محدود به L است $(\|J_f(\cdot)\|_2 \leq L)$:

$$\leq \int_0^1 L \cdot \|x - y\|_2 dt$$

چون مقادیر L و $\|x - y\|_2$ نسبت به متغیر انتگرال‌گیری (t) ثابت هستند، از انتگرال بیرون می‌آیند:

$$= L \|x - y\|_2 \int_0^1 dt = L \|x - y\|_2 \cdot (1 - 0)$$

نتیجه:

$$\|f(x) - f(y)\|_2 \leq L \|x - y\|_2$$

بنابراین تابع f در مجموعه D ، یک تابع L -لیپشیتس است.

(بخش دوم) تحلیل ثابت لیپشیتس برای اجزای شبکه عصبی (۶۰+۴۰ نمره)

با استفاده از خواص بخش قبل، ثابت لیپشیتس را برای چند جزء متداول در شبکه‌های عصبی عمیق تحلیل می‌کنیم.

۱. تحلیل لایه‌های نرمال‌سازی (۲۰+۲۰ نمره): در این سوال، خواص لیپشیتس دو مکانیزم نرمال‌سازی رایج را بررسی می‌کنیم.

(الف) نرمال سازی دسته ای^۵: در زمان استنتاج^۶، آماره های میانگین $(\mu \in \mathbb{R}^d)$ و واریانس $(\sigma^2 \in \mathbb{R}^d)$ ثابت هستند. فرض کنید ورودی لایه یک ماتریس دسته $X \in \mathbb{R}^{B \times d}$ باشد (که B اندازه دسته و d تعداد ویژگی ها است). تبدیل نرمال سازی برای این ماتریس به صورت درایه به درایه روی ویژگی ها اعمال می شود:

$$\text{BN}(X) = \text{Scale}(X, \gamma) + \beta$$

که در آن $\gamma, \beta \in \mathbb{R}^d$ پارامترهای برداری هستند.

i. نشان دهید که این تبدیل را می توان به فرم ماتریسی فشرده ی زیر (که یک تبدیل آفین روی فضای ماتریس هاست) نوشت:

$$\text{BN}(X) = X\Lambda + \mathbf{1}_B \mathbf{b}^T$$

در این رابطه $\Lambda \in \mathbb{R}^{d \times d}$ و $\mathbf{b} \in \mathbb{R}^d$ را بر حسب پارامترهای $(\gamma, \beta, \mu, \sigma^2)$ تعیین کنید و ساختار ماتریس Λ را مشخص نمایید. ($\mathbf{1}_B$ بردار ستونی شامل تمام یک ها به طول B است).

ii. ثابت لپشیتس دقیق این تبدیل را نسبت به نرم فروبنیوس $(\|\cdot\|_F)$ بیابید. به عبارتی کوچکترین مقدار K را پیدا کنید که برای هر دو ماتریس ورودی X و Y داشته باشیم:

$$\|\text{BN}(X) - \text{BN}(Y)\|_F \leq K \|X - Y\|_F$$

iii. با توجه به پاسخ قسمت قبل، اگر واریانس تخمین زده شده برای یکی از ویژگی ها (مثلاً ویژگی j -ام) بسیار کوچک باشد

$(\sigma_j^2 \rightarrow 0)$ ، این موضوع چه تأثیری بر پایداری عددی و حساسیت خروجی نسبت به تغییرات ورودی دارد؟

جواب سوال:

۱. فرم ماتریسی فشرده: رابطه اسکالر نرمال سازی دسته ای برای نمونه i ام و ویژگی j ام به صورت زیر است:

$$y_{ij} = \gamma_j \frac{x_{ij} - \mu_j}{\sqrt{\sigma_j^2 + \epsilon}} + \beta_j$$

(مقدار ϵ معمولاً برای پایداری عددی اضافه می شود، اما در اینجا فرض بر ساده سازی است). با بازنویسی رابطه داریم:

$$y_{ij} = x_{ij} \underbrace{\left(\frac{\gamma_j}{\sqrt{\sigma_j^2}} \right)}_{\lambda_j} + \underbrace{\left(\beta_j - \frac{\gamma_j \mu_j}{\sqrt{\sigma_j^2}} \right)}_{b_j}$$

این رابطه نشان می دهد که ستون j ام ماتریس ورودی در اسکالر λ_j ضرب شده و سپس با اسکالر b_j جمع می شود. در فرم ماتریسی:

• ضرب ستون ها در اسکالره های متفاوت معادل ضرب راست در یک ماتریس قطری است. پس Λ یک ماتریس قطری است که درایه های قطر اصلی آن ضرایب مقیاس دهی هستند:

$$\Lambda = \text{diag} \left(\frac{\gamma_1}{\sqrt{\sigma_1^2}}, \dots, \frac{\gamma_d}{\sqrt{\sigma_d^2}} \right)$$

• جمله بایاس (b_j) برای تمام نمونه های یک ستون ثابت است، بنابراین بردار بایاس $\mathbf{b}$ به صورت زیر تعریف می شود:

$$\mathbf{b} = \beta - \Lambda \mu$$

(که در آن ضرب $\Lambda \mu$ ضرب ماتریس در بردار است یا ضرب درایه به درایه γ و μ با نرمال سازی).

بنابراین رابطه ماتریسی نهایی:

$$\text{BN}(X) = X\Lambda + \mathbf{1}_B \mathbf{b}^T$$

⁵Batch Normalization

⁶inference time

۲. محاسبه ثابت لپشیتس: برای یافتن ثابت لپشیتس K ، باید نرم فروبنیوس تفاضل خروجی‌ها را بررسی کنیم:

$$\begin{aligned}\|\text{BN}(X) - \text{BN}(Y)\|_F &= \|(X\Lambda + \mathbf{1}_B \mathbf{b}^T) - (Y\Lambda + \mathbf{1}_B \mathbf{b}^T)\|_F \\ &= \|(X - Y)\Lambda\|_F\end{aligned}$$

فرض کنیم $Z = X - Y$. می‌خواهیم ماکسیمم مقدار نسبت $\frac{\|Z\Lambda\|_F}{\|Z\|_F}$ را بیابیم. می‌دانیم $\|Z\Lambda\|_F^2 = \sum_{j=1}^d \lambda_j^2 \|z_j\|_2^2$ (که z_j ستون j ام ماتریس Z است). برای ماکسیمم کردن این مقدار (با فرض ثابت بودن $\|Z\|_F^2 = \sum \|z_j\|_2^2$)، باید تمام وزن ماتریس Z را روی ستونی متمرکز کنیم که متناظر با بزرگترین $|\lambda_j|$ است. بنابراین ثابت لپشیتس دقیق برابر است با بزرگترین درایه قدرمطلق ماتریس Λ (نرم طیفی ماتریس قطری):

$$K = \max_j |\lambda_j| = \max_j \left| \frac{\gamma_j}{\sqrt{\sigma_j^2}} \right|$$

۳. تحلیل پایداری ($\sigma_j^2 \rightarrow 0$): اگر واریانس یک ویژگی (σ_j^2) بسیار کوچک باشد و به سمت صفر میل کند، مقدار λ_j متناظر با آن به سمت بی‌نهایت میل می‌کند ($\lambda_j \rightarrow \infty$). این یعنی ثابت لپشیتس (K) بسیار بزرگ می‌شود. تأثیر: حساسیت خروجی لایه نسبت به تغییرات کوچک در ورودی به شدت افزایش می‌یابد. این پدیده باعث ناپایداری عددی (Numerical Instability) و انفجار گرادیان در حین آموزش یا خطای زیاد در حین استنتاج در برابر نویزهای کوچک می‌شود. (به همین دلیل در عمل همیشه از یک مقدار کوچک ϵ در مخرج استفاده می‌شود).

(ب) نرمال‌سازی لایه^۷: (امتیازی) تابع نرمال‌سازی لایه با ترم $\epsilon > 0$ در مخرج به صورت $\text{LN}_\epsilon(x) = \frac{x - \mu_x}{\sqrt{\sigma_x^2 + \epsilon}}$ تعریف می‌شود. ثابت کنید که این تابع $1/\sqrt{\epsilon}$ -لیپشیتس است. یعنی:

$$\|\text{LN}_\epsilon(x) - \text{LN}_\epsilon(y)\|_2 \leq \frac{1}{\sqrt{\epsilon}} \|x - y\|_2$$

جواب سوال:

اثبات: برای اثبات، از این ویژگی استفاده می‌کنیم که اگر نرم طیفی ماتریس ژاکوبین تابع f در همه جا کمتر از L باشد، آن تابع L -لیپشیتس است.

۱. تعریف ماتریس مرکزکننده P : می‌دانیم $x - \mu_x \mathbf{1} = Px$ که در آن $P = I - \frac{1}{d} \mathbf{1}\mathbf{1}^T$ ماتریس مرکزکننده است. همچنین $\sigma_x^2 = \frac{1}{d} \|Px\|_2^2$. پس می‌توان نوشت: $\text{LN}_\epsilon(x) = \frac{Px}{\sqrt{\frac{1}{d} \|Px\|_2^2 + \epsilon}}$.

۲. محاسبه ژاکوبین: فرض کنیم $u = Px$ و $g(u) = \frac{u}{\sqrt{\frac{1}{d} \|u\|_2^2 + \epsilon}}$. آنگاه $\text{LN}_\epsilon(x) = g(Px)$. طبق قاعده زنجیره‌ای، ژاکوبین نسبت به x برابر است با $J_x = J_g(u) \cdot P$. چون P یک ماتریس تصویر است، $\|P\|_2 = 1$ می‌باشد. پس کفایت نرم $\|J_g(u)\|_2$ را بررسی کنیم. با مشتق‌گیری از $g(u)$ نسبت به u :

$$J_g(u) = \frac{1}{\alpha} \left(I - \frac{uu^T}{d\alpha^2} \right)$$

$$\alpha = \sqrt{\frac{\|u\|_2^2}{d} + \epsilon}$$

۳. محاسبه نرم طیفی: ماتریس داخل پرانتز به فرم $(I - cuu^T)$ است. مقادیر ویژه این ماتریس برابرند با 1 (برای بردارهای عمود بر u) و $1 - c\|u\|_2^2$ (در راستای u). در اینجا $c = \frac{\sigma^2}{\sigma^2 + \epsilon}$ و $\|u\|_2^2 = \frac{\|u\|_2^2}{d\alpha^2}$. از آنجا که $\epsilon > 0$ ، این مقدار همواره بین 0 و 1 است ($0 \leq \frac{\sigma^2}{\sigma^2 + \epsilon} < 1$). بنابراین بزرگترین مقدار ویژه ماتریس داخل پرانتز برابر با 1 است. در نتیجه:

$$\|J_g(u)\|_2 = \frac{1}{\alpha} \cdot 1 = \frac{1}{\sqrt{\sigma^2 + \epsilon}}$$

⁷Layer Normalization

۴. یافتن ماکسیمم: عبارت $\frac{1}{\sqrt{\sigma^2 + \epsilon}}$ زمانی ماکسیمم می‌شود که مخرج مینیمم باشد (یعنی $\sigma^2 = 0$).

$$\max_x \|J_{LN}(x)\|_2 \leq \frac{1}{\sqrt{0 + \epsilon}} = \frac{1}{\sqrt{\epsilon}}$$

پس تابع $1/\sqrt{\epsilon}$ -لیپشیتس است.

۲. لایه کانولوشنی^۸ (۲۰ نمره):

(الف) کانولوشن یک‌بعدی: نشان دهید که یک لایه کانولوشن یک‌بعدی با کرنل به طول k لیپشیتس است (محاسبه ضریب لازم نیست).

جواب سوال:

اثبات: عملگر کانولوشن با یک کرنل ثابت w ، یک ****تبدیل خطی**** نسبت به ورودی است. برای هر ورودی برداری x ، عملیات کانولوشن $y = x * w$ را می‌توان به صورت ضرب یک ماتریس در بردار نوشت:

$$f(x) = Mx$$

که در آن M ماتریسی است که از وزن‌های کرنل تشکیل شده است (معمولاً یک ماتریس توبلیتز یا ماتریس دوار).

برای بررسی شرط لیپشیتس، تفاضل خروجی برای دو ورودی x_1 و x_2 را در نظر می‌گیریم:

$$\|f(x_1) - f(x_2)\| = \|Mx_1 - Mx_2\| = \|M(x_1 - x_2)\|$$

طبق تعریف نرم عملگر (نرم القایی ماتریس)، داریم:

$$\|M(x_1 - x_2)\| \leq \|M\| \|x_1 - x_2\|$$

از آنجا که درایه‌های ماتریس M (وزن‌های کرنل) اعداد حقیقی متناهی هستند، نرم ماتریس $\|M\|$ یک عدد حقیقی ثابت و کران‌دار است (مثلاً $L = \|M\|$). بنابراین کانولوشن یک‌بعدی لیپشیتس است.

(ب) کانولوشن دوبعدی: نشان دهید که یک لایه کانولوشن دوبعدی با کرنل k نیز لیپشیتس است (محاسبه ضریب لازم نیست).

جواب سوال:

اثبات: عملگر کانولوشن دوبعدی نیز دقیقاً مانند حالت یک‌بعدی، یک تبدیل خطی است. هر تصویر ورودی X را می‌توان به صورت یک بردار مسطح (Flattened Vector) نمایش داد. در این نمایش، عملیات کانولوشن معادل ضرب یک ماتریس بزرگ (که درایه‌های آن از وزن‌های کرنل تشکیل شده‌اند) در بردار ورودی است:

$$\text{Conv}(x) = Wx$$

برای هر تبدیل خطی با ماتریس ضرایب متناهی، شرط لیپشیتس برقرار است:

$$\|\text{Conv}(x_1) - \text{Conv}(x_2)\| = \|W(x_1 - x_2)\| \leq \|W\| \|x_1 - x_2\|$$

از آنجا که وزن‌های کرنل اعداد حقیقی و متناهی هستند، نرم ماتریس $\|W\|$ نیز عددی متناهی است. بنابراین تابع لیپشیتس است.

۳. مکانیزم توجه در ترنسفورمر^۹ (۲۰+۲۰ نمره): در این سوال، مکانیزم توجه را به صورت تابعی از یک ورودی x در نظر می‌گیریم. فرض کنید بردارهای query و key از ورودی x توسط ماتریس‌های وزن W_q و W_k به صورت $q = W_q x$ و $k = W_k x$ تولید می‌شوند. تابع امتیازدهی $f(x) = q^T k$ را در نظر بگیرید.

(الف) نمایش به صورت فرم درجه دو: ابتدا نشان دهید که $f(x)$ یک فرم درجه دو^{۱۰} بر حسب x است. یعنی آن را به صورت $f(x) = x^T M x$ بنویسید و ماتریس M را بر حسب W_k و W_q مشخص کنید.

^۸Convolutional Layer (CNN)

^۹Transformer

^{۱۰}Quadratic Form

جواب سوال:

اثبات: برای نشان دادن فرم درجه دو، تعاریف q و k را در تابع امتیازدهی جایگذاری می‌کنیم:

$$f(x) = q^T k = (W_q x)^T (W_k x)$$

از خاصیت ترانواده ضرب ماتریس‌ها $((AB)^T = B^T A^T)$ استفاده می‌کنیم تا پرانتز اول را باز کنیم:

$$(W_q x)^T = x^T W_q^T$$

حالا این عبارت را در رابطه اصلی قرار می‌دهیم:

$$f(x) = x^T W_q^T W_k x$$

با استفاده از خاصیت شرکت‌پذیری ضرب ماتریس‌ها، می‌توانیم پرانتز را دور بخش میانی قرار دهیم:

$$f(x) = x^T (W_q^T W_k) x$$

این رابطه دقیقاً تعریف یک فرم درجه دو $(x^T M x)$ است. با مقایسه این رابطه با فرم استاندارد، ماتریس واسط M برابر است با:

$$M = W_q^T W_k$$

(ب) اثبات غیر لپشیتس بودن (کلی): با استفاده از فرم درجه دو که به دست آوردید، ثابت کنید که تابع $f(x)$ به صورت کلی^{۱۱} لپشیتس نیست.

جواب سوال:

اثبات: یک تابع مشتق‌پذیر f روی دامنه نامتناهی $(\mathbb{R}^n)$ تنها در صورتی به طور کلی لپشیتس است که نرم گرادیان آن در تمام فضا کران‌دار باشد (یعنی $\|\nabla f(x)\| \leq L$ برای تمام x).
۱. محاسبه گرادیان: برای تابع فرم درجه دو $f(x) = x^T M x$ ، گرادیان برابر است با:

$$\nabla f(x) = (M + M^T)x$$

۲. بررسی کران‌دار بودن: نرم گرادیان برابر است با:

$$\|\nabla f(x)\| = \|(M + M^T)x\|$$

این مقدار تابعی خطی از x است. اگر اندازه ورودی به سمت بی‌نهایت میل کند ($\|x\| \rightarrow \infty$)، اندازه گرادیان نیز به بی‌نهایت میل می‌کند (مگر در حالت خاص $M = -M^T$ که f صفر می‌شود). از آنجا که شیب تابع (گرادیان) با دور شدن از مبدأ دائماً افزایش می‌یابد و هیچ سقف مشخصی (L) ندارد، تابع $f(x)$ به صورت کلی لپشیتس نیست.

(ج) اثبات لپشیتس بودن (محلی): (امتیازی) ثابت کنید که $f(x)$ به صورت محلی^{۱۲} لپشیتس است. یعنی نشان دهید که برای هر ناحیه کران‌دار (مانند یک گوی $\|x\|_2 \leq R$)، یک ثابت L_R (وابسته به R) وجود دارد که تابع در آن ناحیه L_R -لپشیتس است.

جواب سوال:

اثبات: برای نشان دادن خاصیت لپشیتس محلی، کافی است نشان دهیم که نرم گرادیان تابع در هر ناحیه کران‌دار (مانند گوی $\|x\|_2 \leq R$) توسط یک عدد ثابت محدود می‌شود.

۱. بررسی گرادیان: در قسمت قبل محاسبه کردیم که $\nabla f(x) = (M + M^T)x$.

۲. محاسبه کران بالا: نرم گرادیان را محاسبه کرده و از خاصیت سازگاری نرم ماتریس و بردار $\|Ax\| \leq \|A\| \|x\|$ استفاده می‌کنیم:

¹¹globally

¹²locally

$\|A\| \|x\|$ استفاده می‌کنیم:

$$\|\nabla f(x)\|_2 = \|(M + M^T)x\|_2 \leq \|M + M^T\|_2 \cdot \|x\|_2$$

چون فرض کرده‌ایم x در ناحیه $\|x\|_2 \leq R$ قرار دارد، می‌توان نوشت:

$$\|\nabla f(x)\|_2 \leq \|M + M^T\|_2 \cdot R$$

۳. نتیجه‌گیری: مقدار $L_R = \|M + M^T\|_2 \cdot R$ یک عدد حقیقی و متناهی است که به R وابسته است. بنابراین، برای هر دو نقطه x_1, x_2 در این گوی، طبق قضیه مقدار میانگین:

$$\|f(x_1) - f(x_2)\| \leq \left(\max_{\|z\| \leq R} \|\nabla f(z)\| \right) \|x_1 - x_2\| \leq L_R \|x_1 - x_2\|$$

پس تابع به صورت محلی لیپشیتس است.

سوال ۲ بررسی حمله DeepFool (۹۰ نمره)

هدف DeepFool یافتن کوچک‌ترین اغتشاش در نرم ۲ است که classifier را وادار می‌کند کلاس خروجی را تغییر دهد:

$$\Delta(x; \hat{k}) = \min_{r \in \mathbb{R}^d} \frac{1}{2} \|r\|_2^2, \quad \text{s.t.} \quad \hat{k}(x+r) \neq \hat{k}(x).$$

بخش اول) داده دو کلاسه (۴۰ نمره)

در این بخش، دسته‌بند باینری را بررسی می‌کنیم: ابتدا برای مدل خطی جواب فرم بسته را بدست می‌آوریم، سپس با تقریب تیلور برای هر تابع دلخواه این محاسبه را تکرار می‌کنیم.

۱. مدل خطی دو کلاسه (۲۰ نمره): با فرض $\hat{k}(x) = \text{sign}(f(x))$ و $f(x) = w^\top x + b$ و $F = \{x \in \mathbb{R}^d : w^\top x + b = 0\}$ مسئله بهینه‌سازی زیر را حل کنید. (راهنمایی: برای حل جبری از روش لاگرانژ و برای حل هندسی از تصویر کردن نقطه بر ابر صفحه استفاده کنید.)

$$r^*(x_0) = \arg \min_{r \in \mathbb{R}^d} \frac{1}{2} \|r\|_2^2 \quad \text{s.t.} \quad \text{sign}(f(x_0 + r)) \neq \text{sign}(f(x_0)).$$

۲. مدل دلخواه دو کلاسه (۲۰ نمره): فرض کنید $f: \mathbb{R}^d \rightarrow \mathbb{R}$ در x_i مشتق پذیر است. با فرض برقرار بودن تقریب مرتبه اول تیلور در هر گام برای تغییرات کوچک، مسئله بهینه‌سازی در گام i را حل کنید:

$$f(x_i + r_i) \approx f(x_i) + \nabla f(x_i)^\top r_i, \quad \arg \min_{r_i \in \mathbb{R}^d} \frac{1}{2} \|r_i\|_2^2 \quad \text{s.t.} \quad f(x_i) + \nabla f(x_i)^\top r_i = 0$$

بخش دوم) دسته‌بند خطی و داده چند کلاسه (۵۰ نمره)

در اینجا فقط به بررسی حالت خطی می‌پردازیم، مشابه بخش قبل می‌توان با فرض برقراری تقریب مرتبه اول تیلور برای هر مدل دسته‌بند دلخواه نیز جواب فرم بسته بدست آورد که خروجی محاسبات در الگوریتم ۲ مقاله مربوطه موجود است.

۱. مدل خطی (ماتریسی) چند کلاسه (۴۰ نمره): بگذارید $f(x) = W^\top x + b \in \mathbb{R}^C$ با $W = [w_1, \dots, w_C] \in \mathbb{R}^{d \times C}$ و $b \in \mathbb{R}^C$ و همچنین $\hat{k}(x) = \arg \max_k f_k(x)$ و $c_0 := \hat{k}(x_0)$.

(الف) صورت‌بندی (۱۰ نمره): ابتدا صورت مسئله بهینه‌سازی مقید مناسب برای این حالت را بنویسید.

(ب) نزدیک‌ترین ابر صفحه تصمیم‌گیری (۲۰ نمره): اگر $\hat{\ell}(x_0)$ را نزدیک ترین مرز تصمیم‌گیری به نقطه x_0 در نظر بگیریم نشان دهید

$$\hat{\ell}(x_0) = \arg \min_{k \neq c_0} \frac{|f_k(x_0) - f_{c_0}(x_0)|}{\|w_k - w_{c_0}\|_2}.$$

(ج) پیدا کردن اغتشاش بهینه (۲۰ نمره): اگر $H_{\hat{\ell}(x_0)} = \{x : f_{\hat{\ell}(x_0)}(x) = f_{c_0}(x)\}$ ، نتیجه بگیرید

$$r^*(x_0) = \frac{|f_{\hat{\ell}(x_0)}(x_0) - f_{c_0}(x_0)|}{\|w_{\hat{\ell}(x_0)} - w_{c_0}\|_2^2} (w_{\hat{\ell}(x_0)} - w_{c_0}),$$

موفق باشید.