



امنیت و حریم خصوصی در یادگیری ماشین (۴۰۸۱۶)
نیم‌سال اول سال تحصیلی ۱۴۰۴-۱۴۰۵
استاد درس: دکتر امیرمهدی صادق‌زاده

طراحان: فیروزه ابریشمی، علیرضا فرج تبریزی

نکات و قواعد

۱. سوالات خود را زیر پیام مربوطه در Quera با گروه درس مطرح نمایید.
۲. لطفا مطابق تاکید پیشین، حتما آداب‌نامه‌ی انجام تمرین‌های درسی را رعایت نمایید. در صورت تخطی از آیین‌نامه، در بهترین حالت مجبور به حذف درس خواهید شد.
۳. از تحویل تمرین نظری به شکل تایپ شده (فایل Word-Latex یا هر نوع تایپ شده دیگری) بهره‌ییزید و حتما پاسخ دست نویس تحویل دهید.
۴. در صورتی که پاسخ‌های سوالات نظری را به صورت دست‌نویس آماده کرده‌اید، لطفا تصاویر واضحی از پاسخ‌های خود ارسال کنید. در صورت ناخوانا بودن پاسخ ارسالی، نمره‌ای به پاسخ ارسال شده تعلق نمی‌گیرد.
۵. همه‌ی فایل‌های مربوط به پاسخ خود را در یک فایل فشرده و با نام SPML_HW1_StdNum_FirstName_LastName ذخیره کرده و ارسال نمائید.

سوال ۱ لیپشیتس (۷۰+۹۰ نمره)

بخش اول) خواص پایه‌ای توابع لیپشیتس (۳۰+۳۰ نمره)

در این بخش، چند خاصیت بنیادی توابع لیپشیتس را که به عنوان ابزارهای ریاضی برای تحلیل شبکه‌های عصبی به کار می‌روند، اثبات و بررسی می‌کنیم.

۱. جمع توابع لیپشیتس (۱۰ نمره): ثابت کنید اگر $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ یک تابع لیپشیتس و $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ یک تابع لیپشیتس باشد، آنگاه تابع مجموع $h(x) = f(x) + g(x)$ نیز لیپشیتس است. کران بالای ثابت لیپشیتس آن (L_h) چیست؟
 $L_h + L_g$
۲. ترکیب توابع لیپشیتس (۱۰ نمره):

(الف) اثبات خاصیت ترکیب: ثابت کنید اگر $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ یک تابع لیپشیتس و $f: \mathbb{R}^m \rightarrow \mathbb{R}^k$ یک تابع لیپشیتس باشد، آنگاه تابع مرکب $h(x) = f(g(x))$ نیز یک تابع لیپشیتس است. کران بالای ثابت لیپشیتس آن (L_h) چیست؟
 $L_h \leq L_f \cdot L_g$

(ب) کران ثابت لیپشیتس یک لایه: یک لایه شبکه عصبی به صورت $f_k(x) = \sigma(W_k x)$ را در نظر بگیرید که در آن σ یک تابع فعال‌سازی^۱ L_{σ} -لیپشیتس و W_k ماتریس وزن است. با استفاده از خاصیت ترکیب توابع که در بند (الف) اثبات کردید، نشان دهید که ثابت لیپشیتس این لایه (L_k) توسط $\|W_k\|_2 \cdot L_{\sigma}$ کران‌دار می‌شود. (یادآوری: ثابت لیپشیتس تبدیل خطی $x \mapsto Wx$ برابر با نورم طیفی ماتریس، یعنی $\|W\|_2$ است).

^۱ Activation Function

۳۶. ارتباط با مشتق (۳۰+۱۰) (نمره):

(الف) حالت یک بعدی: برای یک تابع مشتق پذیر $f: \mathbb{R} \rightarrow \mathbb{R}$ ، ثابت کنید که f یک تابع L -لیپشیتس است اگر و تنها اگر برای تمام مقادیر x داشته باشیم $|f'(x)| \leq L$.

(ب) شرط کافی برای لیپشیتس بودن در حالت کلی: (امتیازی، اما در صورت استفاده در بخش های بعدی باید آن را ثابت کنید). ثابت کنید اگر تابع $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ در یک مجموعه محدب^۲ D مشتق پذیر باشد و نرم طیفی^۳ ماتریس ژاکوبین^۴ آن برای تمام $x \in D$ کران دار باشد (یعنی $\|J_f(x)\|_2 \leq L$)، آنگاه f در آن مجموعه یک تابع L -لیپشیتس است. راهنمایی اثبات:

- (گام ۱) تابع کمکی $g(t) = f(y + t(x - y))$ را برای $t \in [0, 1]$ تعریف کنید.
- (گام ۲) با استفاده از قضیه اساسی حسابان نشان دهید $f(x) - f(y) = \int_0^1 g'(t) dt$.
- (گام ۳) مشتق $g'(t)$ را با قاعده زنجیره ای بر حسب ژاکوبین J_f بیابید. سپس از طرفین انتگرال نورم بگیرید و با استفاده از نامساوی مثلثی برای انتگرال ها $\| \int h(t) dt \|_2 \leq \int \| h(t) \|_2 dt$ و فرض کران دار بودن $\|J_f\|_2 \leq L$ اثبات را کامل کنید.

بخش دوم) تحلیل ثابت لیپشیتس برای اجزای شبکه عصبی (۴۰+۶۰) (نمره)

با استفاده از خواص بخش قبل، ثابت لیپشیتس را برای چند جزء متداول در شبکه های عصبی عمیق تحلیل می کنیم.

۱. تحلیل لایه های نرمال سازی (۲۰+۲۰) (نمره): در این سوال، خواص لیپشیتس دو مکانیزم نرمال سازی رایج را بررسی می کنیم.

(الف) نرمال سازی دسته ای^۵: تبدیل نرمال سازی دسته ای در زمان استنتاج^۶، که در آن میانگین (μ) و واریانس (σ^2) ثابت و از پیش محاسبه شده اند، به صورت زیر تعریف می شود:

$$\text{BN}(x) = \gamma \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta$$

در این رابطه، γ و β پارامترهای قابل آموزش مقیاس دهی و انتقال هستند.

i. ثابت کنید که این تبدیل (BN) در زمان استنتاج یک تبدیل آفین^۷ است.

اسلاید

ii. ثابت لیپشیتس دقیق این تبدیل را بر حسب پارامترهای آن $(\epsilon, \sigma^2, \gamma)$ بیابید.

iii. این نتیجه در مورد تأثیر لایه BN (در زمان استنتاج) بر پایداری و استواری شبکه چه می گوید؟

(ب) نرمال سازی لایه^۸: (امتیازی) تابع نرمال سازی لایه با ترم $\epsilon > 0$ در مخرج به صورت $\text{LN}_\epsilon(x) = \frac{x - \mu_x}{\sqrt{\sigma_x^2 + \epsilon}}$ تعریف می شود. ثابت کنید که این تابع $1/\sqrt{\epsilon}$ -لیپشیتس است. یعنی:

$$\|\text{LN}_\epsilon(x) - \text{LN}_\epsilon(y)\|_2 \leq \frac{1}{\sqrt{\epsilon}} \|x - y\|_2$$

۲. لایه کانولوشنی^۹ (۲۰) (نمره):

(الف) کانولوشن یک بعدی: نشان دهید که یک لایه کانولوشن یک بعدی با کرنل به طول k لیپشیتس است (محاسبه ضریب لازم نیست).

(ب) کانولوشن دوبعدی: نشان دهید که یک لایه کانولوشن دوبعدی با کرنل k نیز لیپشیتس است (محاسبه ضریب لازم نیست).

۳. مکانیزم توجه در ترنسفورمر^{۱۰} (۲۰+۲۰) (نمره): در این سوال، مکانیزم توجه را به صورت تابعی از یک ورودی x در نظر می گیریم. فرض کنید بردارهای query و key از ورودی x توسط ماتریس های وزن W_k و W_q به صورت $q = W_q x$ و $k = W_k x$ تولید می شوند. تابع امتیازدهی $f(x) = q^T k$ را در نظر بگیرید.

^۲Convex Set^۳Spectral Norm^۴Jacobian Matrix^۵Batch Normalization^۶inference time^۷Affine^۸Layer Normalization^۹Convolutional Layer (CNN)^{۱۰}Transformer

- (الف) نمایش به صورت فرم درجه دو: ابتدا نشان دهید که $f(x)$ یک فرم درجه دو^{۱۱} بر حسب x است. یعنی آن را به صورت $f(x) = x^T M x$ بنویسید و ماتریس M را بر حسب W_q و W_k مشخص کنید.
- (ب) اثبات غیر لپشیتس بودن (کلی): با استفاده از فرم درجه دو که به دست آوردید، ثابت کنید که تابع $f(x)$ به صورت کلی^{۱۲} لپشیتس نیست.
- (ج) اثبات لپشیتس بودن (محلی): (امتیازی) ثابت کنید که $f(x)$ به صورت محلی^{۱۳} لپشیتس است. یعنی نشان دهید که برای هر ناحیه کراندار (مانند یک گوی $\|x\|_2 \leq R$)، یک ثابت L_R (وابسته به R) وجود دارد که تابع در آن ناحیه L_R -لپشیتس است.

سوال ۲ بررسی حمله DeepFool (۹۰ نمره)

هدف DeepFool یافتن کوچک‌ترین اغتشاش در نرم ۲ است که classifier را وادار می‌کند کلاس خروجی را تغییر دهد:

$$\Delta(x; \hat{k}) = \min_{r \in \mathbb{R}^d} \frac{1}{2} \|r\|_2^2, \quad \text{s.t.} \quad \hat{k}(x+r) \neq \hat{k}(x).$$

بخش اول (داده دو کلاسه (۴۰ نمره)

در این بخش، دسته‌بند باینری را بررسی می‌کنیم: ابتدا برای مدل خطی جواب فرم بسته را بدست می‌آوریم، سپس با تقریب تیلور برای هر تابع دلخواه این محاسبه را تکرار می‌کنیم.

۱. مدل خطی دو کلاسه (۲۰ نمره): با فرض $f(x) = w^\top x + b$ ، $\hat{k}(x) = \text{sign}(f(x))$ و $F = \{x \in \mathbb{R}^d : w^\top x + b = 0\}$ مسئله بهینه‌سازی زیر را حل کنید. (راهنمایی: برای حل جبری از روش لاگرانژ و برای حل هندسی از تصویر کردن نقطه بر ابر صفحه استفاده کنید.)

$$r^*(x_0) = \arg \min_{r \in \mathbb{R}^d} \frac{1}{2} \|r\|_2^2 \quad \text{s.t.} \quad \text{sign}(f(x_0 + r)) \neq \text{sign}(f(x_0)).$$

۲. مدل دلخواه دو کلاسه (۲۰ نمره): فرض کنید $f: \mathbb{R}^d \rightarrow \mathbb{R}$ در x_i مشتق پذیر است. با فرض برقرار بودن تقریب مرتبه اول تیلور در هر گام برای تغییرات کوچک، مسئله بهینه‌سازی در گام i ام را حل کنید:

$$f(x_i + r_i) \approx f(x_i) + \nabla f(x_i)^\top r_i, \quad \arg \min_{r_i \in \mathbb{R}^d} \frac{1}{2} \|r_i\|_2^2 \quad \text{s.t.} \quad f(x_i) + \nabla f(x_i)^\top r_i = 0$$

بخش دوم (دسته‌بند خطی و داده چند کلاسه (۵۰ نمره)

در اینجا فقط به بررسی حالت خطی می‌پردازیم، مشابه بخش قبل می‌توان با فرض برقراری تقریب مرتبه اول تیلور برای هر مدل دسته‌بند دلخواه نیز جواب فرم بسته بدست آورد که خروجی محاسبات در الگوریتم ۲ مقاله مربوطه موجود است.

۱. مدل خطی (ماتریسی) چند کلاسه (۴۰ نمره): بگذارید $f(x) = W^\top x + b \in \mathbb{R}^C$ با $W = [w_1, \dots, w_C] \in \mathbb{R}^{d \times C}$ و $b \in \mathbb{R}^C$ و همچنین $\hat{k}(x) = \arg \max_k f_k(x)$ و $c_0 := \hat{k}(x_0)$.

(الف) صورت‌بندی (۱۰ نمره): ابتدا صورت مسئله بهینه‌سازی مقید مناسب برای این حالت را بنویسید.

(ب) نزدیک‌ترین ابر صفحه تصمیم‌گیری (۲۰ نمره): اگر $\hat{\ell}(x_0)$ را نزدیک ترین مرز تصمیم‌گیری به نقطه x_0 در نظر بگیریم نشان دهید

$$\hat{\ell}(x_0) = \arg \min_{k \neq c_0} \frac{|f_k(x_0) - f_{c_0}(x_0)|}{\|w_k - w_{c_0}\|_2}.$$

(ج) پیدا کردن اغتشاش بهینه (۲۰ نمره): اگر $H_{\hat{\ell}(x_0)} = \{x : f_{\hat{\ell}(x_0)}(x) = f_{c_0}(x)\}$ ، نتیجه بگیرید

$$r^*(x_0) = \frac{|f_{\hat{\ell}(x_0)}(x_0) - f_{c_0}(x_0)|}{\|w_{\hat{\ell}(x_0)} - w_{c_0}\|_2^2} (w_{\hat{\ell}(x_0)} - w_{c_0}),$$

موفق باشید.

¹¹Quadratic Form

¹²globally

¹³locally