

بخش اول) ۱.

$$\begin{cases} f: \mathbb{R}^n \rightarrow \mathbb{R}^m \text{ is } L_f\text{-Lipschitz} \\ g: \mathbb{R}^n \rightarrow \mathbb{R}^m \text{ is } L_g\text{-Lipschitz} \end{cases}$$

طبق تعریف لیپشیتس $\rightarrow$

$$\begin{cases} \|f(x) - f(y)\|_p \leq L_f \|x - y\|_p \\ \|g(x) - g(y)\|_p \leq L_g \|x - y\|_p \end{cases}$$

(برای هر x و y دلخواه)

حال توجه کنید بر هر $x, y \in \mathbb{R}^n$ طبق تعریف جمع داریم:

$$\begin{aligned} \|h(x) - h(y)\|_p &= \|f(x) + g(x) - f(y) - g(y)\|_p \\ &= \|[f(x) - f(y)] + [g(x) - g(y)]\|_p \end{aligned}$$

حال طبق خاصیتی مثلثی داریم: $\|a + b\|_p \leq \|a\|_p + \|b\|_p$

$$\begin{aligned} \|[f(x) - f(y)] + [g(x) - g(y)]\|_p &\leq \|f(x) - f(y)\|_p + \|g(x) - g(y)\|_p \\ &\leq L_f \|x - y\|_p + L_g \|x - y\|_p \\ &= (L_f + L_g) \|x - y\|_p \end{aligned}$$

از جملاتی لیپشیتس استفاده کردیم $\rightarrow$

$$\Rightarrow \|h(x) - h(y)\|_p \leq (L_f + L_g) \|x - y\|_p$$

$$\Rightarrow \boxed{L_h \leq L_f + L_g}$$

کرن بالای ثابت لیپشیتس h

یک تابع لیپشیتس است $\rightarrow$

Shahed

۲. (الف) $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ is L_g -Lipschitz
 $f: \mathbb{R}^m \rightarrow \mathbb{R}^k$ is L_f -Lipschitz

برای هر $x, y \in \mathbb{R}^n$ داریم:

$$\|h(x) - h(y)\|_p = \|f(g(x)) - f(g(y))\|_p$$

چون f یک تابع L_f -لیپشیتس است.

$$\|h(x) - h(y)\|_p \leq L_f \|g(x) - g(y)\|_p$$

چون g یک تابع L_g -لیپشیتس است.

$$\|h(x) - h(y)\|_p \leq L_f \cdot (L_g \|x - y\|_p)$$

طبق تعریف تابع
لیپشیتس

Lipschitz
definition

$$\|h(x) - h(y)\|_p \leq (L_f \cdot L_g) \|x - y\|_p$$

$$L_h \leq L_f \cdot L_g$$

بنابراین $L_f \cdot L_g$ یک حدا بالا برای ثابت لیپشیتس تابع h است و تابع h

upper bound

یک تابع لیپشیتس است.

(ب) فرض کنید $g(x) = W_k x$. این یک تبدیل خطی است. ثابت
 $Lipshitz$ یک تبدیل خطی برابر نرم طیفی آن است پس $L_g = \|W_k\|_p$
 فرض کنید تابع فعال سازی $f(u) = \sigma(u)$ یا σ که دارای ثابت $Lipshitz$
 برابر با L_σ است. بنابراین با استفاده از خاصیت ترکیب که در (الف)
 اثبات کردیم داریم:

$$g(x) = W_k x, L_g = \|W_k\|_p$$

$$f(u) = \sigma(u), L_f = L_\sigma$$

$$f(g(x)) \text{ is } L_f \cdot L_g \text{ Lipschitz}$$

$$L_k \leq L_\sigma \cdot \|W_k\|_p$$

Shahed

۳. (الف) ابتدا $(\Rightarrow)$ را اثبات می‌کنیم و سپس $(\Leftarrow)$

$(\Rightarrow)$: If f is L -Lipschitz, then $|f'(x)| \leq L$ for all x .

طبق تعریف لایپشیتس داریم: برای هر x و $h \neq 0$ کوچکی داریم:

$$|f(x+h) - f(x)| \leq \underbrace{|(x+h) - x|}_h \times L = |h| \times L$$

پس با تقسیم طرفین بر $|h|$ که عدد نامنفی و نامصغر است داریم: $|h| > 0$

$$\frac{|f(x+h) - f(x)|}{|h|} \leq L \xrightarrow{h \rightarrow 0} \boxed{|f'(x)| \leq L}$$

حال با میل دادن $h \rightarrow 0$ و محاسبه $\lim$ به تعریف خواسته شده می‌رسیم.

$$\lim_{h \rightarrow 0} \frac{|f(x+h) - f(x)|}{|h|} = \lim_{h \rightarrow 0} \left| \frac{f(x+h) - f(x)}{h} \right| = |f'(x)| \leq L$$

$(\Leftarrow)$: If $|f'(x)| \leq L$ for all x , then f is L -Lipschitz

طبق قضیه مقدار میانی (Mean Value Theorem) برای هر $a, b \in \mathbb{R}$

وجود دارد یک $c \in (a, b)$ به گونه‌ای که: (چون f پیوسته و مشتق پذیر است)

$$f'(c) = \frac{f(b) - f(a)}{b - a} \rightarrow f(b) - f(a) = f'(c)(b - a)$$

حال از دو طرف قدر مطلق می‌گیریم:

$$|f(b) - f(a)| = |f'(c)(b - a)| = |f'(c)| \cdot |b - a|$$

$$\leq L \cdot |b - a| \quad \leftarrow \text{چون } \forall x, |f'(x)| \leq L$$

$$\boxed{|f(b) - f(a)| \leq L \cdot |b - a|}$$

تابع f یک تابع L -Lipschitz است.

③

(ب) فرض کنید $x, y \in D$ نقاطی دلخواه در D باشند.
گام ۱: تابع کمکی $g: [0, 1] \rightarrow \mathbb{R}^m$ به شکل زیر تعریف می‌کنیم:

$$g(t) = f(y + t(x - y))$$

چون مجموعه D محدب است، برای هر $t \in [0, 1]$ عبارت $y + t(x - y)$ عضو D است. $(y + t(x - y) \in D)$

گام ۲: استفاده از قضیه اساسی حسابان:

$$g(1) - g(0) = \int_0^1 g'(t) dt$$

توجه کنید که $g(1) = f(x)$ و $g(0) = f(y)$ است بنابراین:

$$f(x) - f(y) = \int_0^1 g'(t) dt$$

گام ۳: یافتن $g'(t)$ به وسیله قاعده زنجیره‌ای:

فرض کنید $z(t) = y + t(x - y)$ پس $\frac{dz}{dt} = x - y$ بنابراین طبق قاعده زنجیره‌ای:

$$g'(t) = \underbrace{J_f(z(t))}_{\frac{df}{dz}} \cdot \frac{dz}{dt} = J_f(y + t(x - y)) \cdot (x - y)$$

که بدان J_f همان ماتریس ژاکوبین f است.
حال از طرفین نورم می‌گیریم:

$$\|f(x) - f(y)\|_p = \left\| \int_0^1 g'(t) dt \right\|_p = \left\| \int_0^1 J_f(y + t(x - y)) \cdot (x - y) dt \right\|_p$$

حال از نامساوی مثلثی برای انتگرال‌ها استفاده می‌کنیم: $\left\| \int_0^1 h(t) dt \right\|_p \leq \int_0^1 \|h(t)\|_p dt$

$$\|f(x) - f(y)\|_p \leq \int_0^1 \|J_f(y + t(x - y)) \cdot (x - y)\|_p dt$$

(۴)

حال طبق تعریف spectral norm داریم: $(\|Av\|_p \leq \|A\|_p \|v\|_p)$

$$\|f(x) - f(y)\|_p \leq \int_0^1 \|J_f(y + t(x-y))\|_p \cdot \|x - y\|_p dt$$

حال از فرض کران دار بودن $\|J_f(z)\|_p \leq L$ برای هر $z \in D$ داریم:

$$\|f(x) - f(y)\|_p \leq \int_0^1 L \cdot \|x - y\|_p dt = L \cdot \|x - y\|_p \underbrace{\int_0^1 dt}_1$$

$$\Rightarrow \|f(x) - f(y)\|_p \leq L \cdot \|x - y\|_p$$

بنابراین f یک تابع L -لیپشیتس است. $\square$

(در مجموعه محدب D)

Shahed

(5)

$$b = \beta - \Lambda \mu = \begin{bmatrix} \beta_1 - \frac{\delta_1 M_1}{\sqrt{\sigma_1^2 + \epsilon}} \\ \beta_2 - \frac{\delta_2 M_2}{\sqrt{\sigma_2^2 + \epsilon}} \\ \vdots \\ \beta_d - \frac{\delta_d M_d}{\sqrt{\sigma_d^2 + \epsilon}} \end{bmatrix} \in \mathbb{R}^d$$

آن را از خاصیت affine بودن در قسمت ۱ استفاده می کنیم طبق تعریف
می دانیم که $BN(x) = x\Lambda + \frac{1}{B}b^T$ پس:

$$BN(x) - BN(y) = x\Lambda + \frac{1}{B}b^T - y\Lambda - \frac{1}{B}b^T = x\Lambda - y\Lambda$$

$$\rightarrow BN(x) - BN(y) = (x - y)\Lambda$$

حال از ~~فرم~~ فرم فروبنیوس استفاده می کنیم.

$$\|A\|_F = \sqrt{\sum_{i,j} A_{ij}^2} \quad \|BN(x) - BN(y)\|_F = \|(x - y)\Lambda\|_F$$

توجه کنید Λ ماتریس قطری است پس:

$$\|(x - y)\Lambda\|_F^2 = \sum_{i=1}^B \sum_{j=1}^d \left(\sum_{k=1}^d (x - y)_{ik} \Lambda_{kj} \right)^2$$

چون Λ قطری است $(\Lambda_{kj} = 0 \text{ for } k \neq j)$:

$$\begin{aligned} \|(x - y)\Lambda\|_F^2 &= \sum_{i=1}^B \sum_{j=1}^d ((x - y)_{ij} \Lambda_{jj})^2 = \sum_{i=1}^B \sum_{j=1}^d \Lambda_{jj}^2 (x - y)_{ij}^2 \\ &= \sum_{j=1}^d \Lambda_{jj}^2 \sum_{i=1}^B (x - y)_{ij}^2 \end{aligned}$$

فرض کنید $\lambda_{\max} = \max_{j=1, \dots, d} |\Lambda_{jj}|$ آنگاه:

$$\|BN(X) - BN(Y)\|_F^2 \leq \lambda_{\max}^2 \sum_{j=1}^d \sum_{i=1}^B (X_{ij} - Y_{ij})^2 = \lambda_{\max}^2 \|X - Y\|_F^2$$

پس

$$K = \max_{j=1, \dots, d} \left| \frac{\lambda_j}{\sqrt{\sigma_j^2 + \epsilon}} \right| = \max_{j=1, \dots, d} \frac{|\lambda_j|}{\sqrt{\sigma_j^2 + \epsilon}}$$

این عبارت ثابت لیمیتس دقیق است (نه فقط یک کران بالا) زیرا برابر زمانی حاصل می شود که $(X - Y)$ فقط در ستون مربوط به $\lambda_{\max}$ ورودی های غیر صفر داشته باشد.

آنچه وقتی $\sigma_j^2 \rightarrow 0$ آنگاه رفتار ثابت لیمیتس چنین می شود:

$$\Lambda_{jj} = \frac{\lambda_j}{\sqrt{\sigma_j^2 + \epsilon}} \rightarrow \frac{\lambda_j}{\sqrt{\epsilon}}$$

بنابراین اگر λ کوچک نباشد آنگاه: $K = \max_i \frac{|\lambda_i|}{\sqrt{\sigma_i^2 + \epsilon}} \gg \frac{|\lambda_i|}{\sqrt{\epsilon}}$ در نتیجه:

ریسک ناپایداری عددی: وقتی $\sigma_j^2 \rightarrow 0$ آنگاه عنصر نام ماتریس قطری Λ خیلی بزرگ می شود اگر ϵ کوچک باشد. بنابراین ثابت لیمیتس کل K خیلی بزرگ خواهد شد. لذا، تغییرات کوچک در ویژگی نام ورودی به طور قابل توجهی آقویت می شود.

حساسیت زیاد: خروجی به شدت به $perturbation$ در ویژگی‌ها حساس می‌شود. این می‌تواند منجر به گرایان‌های ناپایدار در طول آموزش شود و خطاهای عددی کوچک یا $adversarial perturbation$ ها در ویژگی‌ها نام بزرگ شوند.

نقش ϵ : چارامتر $\epsilon > 0$ به عنوان یک $regularizer$ عمل می‌کند تا از تقسیم به صفر جلوگیری کند. همچنین این پارامتر یک کران پایین برای پایداری فراهم می‌کند: $\frac{1}{\sqrt{\epsilon}} \leq \frac{1}{\epsilon}$. ϵ بزرگ‌تر پایداری را بهبود می‌بخشد اما ممکن است اثر

زیبال سازی را کاهش دهد.

مفاهیم کاربردی: ویژگی‌های با واریانس نزدیک به صفر می‌توانند شبکه را بی ثبات کنند. لذا مقداردهی اولیه و نظارت مناسب بر آماره‌های زیبال سازی (استرایی مهم) است. در $inference$ استفاده از آماره‌های آموزش با داده‌های کافی به جلوگیری از موارد انحراف کمک می‌کند.

$$LN_{\epsilon}(x) = \frac{x - \mu_x}{\sqrt{\sigma_x^2 + \epsilon}} \quad \text{(ب) نرمال سازی لایه ای}$$

$$\mu_x = \frac{1}{n} \sum_{i=1}^n x_i \quad , \quad \sigma_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)^2$$

گام ۱: باز نویسی LN_{ϵ} به شکل ماتریسی!

فرض کنید $1 \in \mathbb{R}^n$ $1 = (1, 1, \dots, 1, 1)^T$ و تعریف می کنیم:

Centering Operator: $C = I - \frac{1}{n} 1 1^T$ (project کننده بر زیر فضای که بر 1 عمود است.)

$$LN_{\epsilon}(x) = \frac{Cx}{\sqrt{\frac{\|Cx\|_2^2}{n} + \epsilon}} \quad \text{نفس} \quad x - \mu_x 1 = Cx \quad \text{نفس}$$

گام ۲: از فرمول به دست آمده برای محاسبه مشتق LN استفاده می کنیم.

Shahed

7



ژاکوبین J_{LN_ϵ} در نقطه x می شود:

$$J_{LN_\epsilon}(x) = \frac{1}{\sqrt{\sigma_x^2 + \epsilon}} \left(C - \frac{C x (C x)^T}{n(\sigma_x^2 + \epsilon)} \right)$$

گام ۳: کران دار کردن نورم طیفی ژاکوبین: $\|J_{LN_\epsilon}(x)\|_2 \leq \frac{1}{\sqrt{\epsilon}}$ باید نشان دهیم که برای هر x داریم:

توجه کنید که: $\|C\|_2 = 1$ (چون C ماتریس projection است) و $\|C x\|_2^2 = n \sigma_x^2$

بنابراین نورم طیفی می تواند که آن دار باشد به شکل زیر:

$$\begin{aligned} \|J_{LN_\epsilon}(x)\|_2 &\leq \frac{1}{\sqrt{\sigma_x^2 + \epsilon}} \left(\|C\|_2 + \frac{\|C x\|_2^2}{n(\sigma_x^2 + \epsilon)} \right) \\ &= \frac{1}{\sqrt{\sigma_x^2 + \epsilon}} \left(1 + \frac{\sigma_x^2}{\sigma_x^2 + \epsilon} \right) \\ &= \frac{1}{\sqrt{\sigma_x^2 + \epsilon}} \cdot \frac{2\sigma_x^2 + \epsilon}{\sigma_x^2 + \epsilon} = \frac{2\sigma_x^2 + \epsilon}{\sqrt{(\sigma_x^2 + \epsilon)^3}} \end{aligned}$$

برای ماکزیمم کردن این عبارت، از آن مشتق نسبت به σ_x^2 می گیریم و با بهینه سازی آن می بینیم که $\sigma_x^2 = 0$ اتفاق می افتد.

$$\max_{\sigma_x^2 \geq 0} \|J_{LN_\epsilon}(x)\|_2 = \frac{\epsilon}{\sqrt{\epsilon^3}} = \frac{\epsilon}{\epsilon \cdot \sqrt{\epsilon}} = \frac{1}{\sqrt{\epsilon}}$$

گام ۴: استفاده از قضیه شرط کافی برای لیبشیتس بودن در حالت کلی از بخش اول (سوال ۳ قسمت ب) $\leftarrow$ چون $\|J_{LN_\epsilon}(x)\|_2 \leq \frac{1}{\sqrt{\epsilon}}$ برای هر x پس LN_ϵ یک تابع لیبشیتز است.

Shahed

⑧ $\|J_{LN_\epsilon}(x)\|_2 \leq \frac{1}{\sqrt{\epsilon}} \rightarrow LN_\epsilon$ is $\frac{1}{\sqrt{\epsilon}}$ Lipschitz

۲. (الف) یک کانولوشن یک بعدی می تواند به شکل یک ضرب ماتریسی

مانند $y = Cx$ نمایش داده شود که C یک ماتریس Toeplitz با مقادیر bounded linear operator (چون فضا محدود است و ضرایب اعداد حقیقی)

کرنل است. چون ضرب ماتریسی یک تبدیل خطی است بنابراین یک تابع

لیپشیتس با ثابت $\|C\|_2$ است. $\|C\|_2$ همان نورم طیفی ماتریس spectral norm

کانولوشن است.)

مثلاً: $W = [W_1, W_2, W_3]$, no padding, کرنل $x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix}$ سیگنال ورودی

$y = W * x$ محاسبه است یا $y = Cx$ (C is a Toeplitz matrix)

$$C = \begin{bmatrix} W_3 & W_2 & W_1 & 0 & 0 \\ 0 & W_3 & W_2 & W_1 & 0 \\ 0 & 0 & W_3 & W_2 & W_1 \end{bmatrix} \text{ و } y = Cx = \begin{bmatrix} W_3x_1 + W_2x_2 + W_1x_3 \\ W_3x_2 + W_2x_3 + W_1x_4 \\ W_3x_3 + W_2x_4 + W_1x_5 \end{bmatrix}$$

(ب) مشابه قسمت الف، یک کانولوشن دو بعدی می تواند به شکل یک

تبدیل خطی (ضرب ماتریسی) به صورت $y = Cx$ نمایش داده شود که در bounded linear operator (فضا محدود و ضرایب اعداد حقیقی)

آن بر اساس کرنل دو بعدی ساخته می شود. به عنوان یک عملگر خطی

این تبدیل یک تابع لیپشیتس با ثابت نورم طیفی $\|C\|_2$ است.

Shahed هم چنین به مانند مثال بالا می توانیم برای حالت دو بعدی نیز ماتریس آن را شکل دهیم. مثلاً ابتدا آن را flat کنیم و سپس مشابه بالا.

⑨




۳. (الف) فرم درجه دو:

$$f(x) = q^T k = (W_q x)^T (W_k x) = x^T \underbrace{W_q^T W_k}_M x = x^T M x$$

$$M = W_q^T W_k \quad \text{و} \quad f(x) = x^T M x$$

(ب) برای فرم درجه دو $f(x) = x^T M x$ و نقاط روی یک خط را در



نظر بگیرید: $x = tv$ for unit vector v (t is a scalar)

$$f(tv) = (tv)^T M (tv) = t^2 v^T M v \quad \text{چون} \quad f(tv) = t^2 v^T M v \\ = (t)(t) v^T M v = t^2 (v^T M v)$$

حال فرض کنید $t_1 = t$ و $t_2 = 0$ آنده: $0^T M 0 = 0$

$$|f(tv) - f(0)| = |t^2 v^T M v| = t^2 |v^T M v|$$

$$\|t_1 v - t_2 v\|_2 = \|tv - 0\|_2 = t \|v\|_2 = t \quad \text{چون } v \text{ یک unit vector است} \rightarrow \|v\|_2 = 1$$

$$\text{بنابراین نسبت} \quad \frac{|f(tv) - f(0)|}{\|tv - 0\|_2} = t |v^T M v| \quad \text{به شکل بی کران}$$

رشته‌ی کند زمانی که $t \rightarrow \infty$. پس با فرض $M \neq 0$ تابع $f(x)$

به سرعت کلی لیپشیتس نیست. (همچنین توجه کنید که $\nabla f(x) = (M + M^T)x$ و چون $\nabla f(x)$ به x وابسته است زمانی که $\|x\|_2 \rightarrow \infty$ آنده $\|\nabla f(x)\| \rightarrow \infty$ در صورتی که $M \neq 0$ و تابع $f(x)$ گرا دیان بی کران دارد.)

(10)

(ج) برای فرم درجه دو $f(x) = x^T M x$ ، مشتق برابر است با:

$$\nabla f(x) = (M + M^T)x$$

برای هر $x \in B_R = \{x : \|x\|_p \leq R\}$ داریم:

$$\|\nabla f(x)\|_p = \|(M + M^T)x\|_p \leq \|M + M^T\|_p \cdot \|x\|_p \leq \|M + M^T\|_p \cdot R$$

طبق تعریف نورم طبیعی

چون که ناحیه B_R محدب است و تابع f مشتق پذیر است، ما می‌توانیم نتیجه حاصل از بخش اول - سوال ۳ - قسمت (ب) استفاده

کنیم. ماتریس ژاکوبین در اینجا همان گرادیان $\nabla f(x)$ است (چرا که $f: \mathbb{R}^n \rightarrow \mathbb{R}$ است) بنابراین

$$\|J_f(x)\|_p = \|\nabla f(x)\|_p \leq \|M + M^T\|_p \cdot R$$

بنابراین f یک تابع L_R -لیپشیتس در ناحیه B_R با ضریب L_R است:

$$L_R = R \cdot \|M + M^T\|_p = R \cdot \|W_q^T W_k + W_k^T W_q\|_p$$

Shahed

بخش اول) ۱. حل جبری (روش لاکرانژ)

شرط $\text{sign}(f(x_0 + r)) \neq \text{sign}(f(x_0))$ یعنی باید از مرز تصمیم گیری

F عبور کنیم. پس کوچکترین آشفتنی r^* زمانی رخ می دهد که دقیقاً به مرز برسیم. بنابراین داریم:

$$w^T(x_0 + r) + b = 0$$

این به ما شرط زیر را می دهد:

$$w^T x_0 + w^T r + b = 0$$

$$w^T r = -(w^T x_0 + b) = -f(x_0) \rightarrow \boxed{w^T r + f(x_0) = 0} \quad (*)$$

بنابراین Lagrangian برابر است با:

$$\cancel{r^*(x_0)} = \arg \min_{r \in \mathbb{R}^d} \frac{1}{p} \|r\|_p^p \quad \text{s.t.} \quad w^T r = -f(x_0)$$

$$\mathcal{L}(r, \lambda) = \frac{1}{p} \|r\|_p^p + \lambda (w^T r + f(x_0)) = \frac{1}{p} r^T r + \lambda w^T r + \lambda f(x_0)$$

حال از $\mathcal{L}(r, \lambda)$ نسبت به r مشتق می گیریم و برابر صفر قرار می دهیم:

$$\nabla_r \mathcal{L} = r + \lambda w = 0 \rightarrow \boxed{r = -\lambda w} \quad (*)$$


حال (*) را در شرط خواسته شده جایگزین می کنیم:

$$\underbrace{w^T(-\lambda w)}_{-\lambda w^T w} + f(x_0) = 0 \rightarrow -\lambda \|w\|_p^p + f(x_0) = 0$$

$$\rightarrow \lambda = \frac{f(x_0)}{\|w\|_p^p} \xrightarrow{r = -\lambda w} \boxed{r^*(x_0) = -\frac{f(x_0)}{\|w\|_p^p} w}$$

Shahed

(12)



حل هندسی: کوچکترین آشتی r^* همان تصویر متعامد x_0 روی ابرصفحه F است. بی‌دایم فاصله نقطه تا ابرصفحه برابر است با:

$$d = \frac{|w^T x_0 + b|}{\|w\|_2} = \frac{|f(x_0)|}{\|w\|_2}$$

جهت عمود بر ابرصفحه F برابر است با $\frac{w}{\|w\|_2}$. چون بی‌خواهیم به سمت

$$r^*(x_0) = -\frac{f(x_0)}{\|w\|_2^2} w$$

ابرفضه (خلاف جهت) حرکت کنیم پس آشتی کمینه r^* برابر است با:

۲. در گام ۱ ام و با فرض تقریب تیلور مرتبه اول (خطی بودن) داریم:

$$f(x_i + r_i) \approx f(x_i) + \nabla f(x_i)^T r_i$$

$$\arg \min_{r_i} \frac{1}{2} \|r_i\|_2^2 \quad \text{s.t.} \quad f(x_i) + \nabla f(x_i)^T r_i \leq 0$$

با استفاده از روش لاگرانژ عبارت Lagrangian برای مسئله بهینه‌سازی می‌شود:

$$\mathcal{L}(r_i, \lambda) = \frac{1}{2} \|r_i\|_2^2 + \lambda (f(x_i) + \nabla f(x_i)^T r_i)$$

حال $\mathcal{L}$ نسبت به r_i مشتق می‌گیریم و صفر می‌گذاریم:

$$\nabla_{r_i} \mathcal{L} = r_i + \lambda \nabla f(x_i) = 0 \rightarrow r_i = -\lambda \nabla f(x_i)$$

حال $\star$ را در شرط لاگرانژ جایگزین می‌کنیم:

$$f(x_i) + \nabla f(x_i)^T (-\lambda \nabla f(x_i)) = 0$$

$$f(x_i) - \lambda \nabla f(x_i)^T \nabla f(x_i) = 0 \rightarrow f(x_i) - \lambda \|\nabla f(x_i)\|_2^2 = 0$$

Shahed

$$\rightarrow \lambda = \frac{f(x_i)}{\|\nabla f(x_i)\|_p^2} \quad r_i = -\lambda \nabla f(x_i)$$

$$r_i = - \frac{f(x_i)}{\|\nabla f(x_i)\|_p^2} \nabla f(x_i)$$

که دقیقاً همان عبارت موجود در فط $\hat{C}_0$ الگوریتم ۱ مقاله است.

بخش دوم (الف). برای یک دسته بندی چند کلاسی با $\hat{k}(x) = \arg \max_k f_k(x)$ ما کوچکترین آشفتگی r^* را می‌خواهیم که کلاس پیش بین شده را از C_0 به هر کلاس دیگری تغییر دهد. مسئله بهینه سازی می‌شود:

(One-vs-all scheme)

$$r^*(x_0) = \arg \min_{r \in \mathbb{R}^d} \frac{1}{p} \|r\|_p \quad \text{s.t.} \quad \exists_{k \neq C_0} : f_k(x_0 + r) \geq f(x_0 + r)$$

$$C_0 = \hat{k}(x_0)$$


به طور معادل (برای عبور از هر مرتبه تصمیم گیری) داریم:

$$r^*(x_0) = \arg \min_{r \in \mathbb{R}^d} \frac{1}{p} \|r\|_p \quad \text{s.t.} \quad \exists_{k \neq \hat{k}(x_0)} : w_k^T(x_0 + r) + b_k \geq w_{\hat{k}(x_0)}^T(x_0 + r) + b_{\hat{k}(x_0)}$$

$$r^*(x_0) = \arg \min_{r \in \mathbb{R}^d} \frac{1}{p} \|r\|_p \quad \text{s.t.} \quad \hat{k}(x_0 + r) \neq C_0$$

(ب) از نظر هندسی، این معادل محاسبه فاصله بین x_0 و مکمل چندوجهی محرب P است، که در آن P ناحیه ای را تعریف می‌کند که در آن دسته بندی فرجسب $C_0 = \hat{k}(x_0)$ را در آن خروجی می‌دهد.

$$P = \bigcap_{k=1}^C \{x : f_{\hat{k}(x_0)}(x) \geq f_k(x)\}$$



مرتبه تصمیم گیری بین کلاس های C_0 و k یک ابرصفحه F_k به شکل زیر است:

$$F_k = \{x : f_k(x) = f_{C_0}(x)\} \rightarrow F_k = \{x : w_k^T x + b_k = w_{C_0}^T x + b_{C_0}\}$$

$$\rightarrow F_k = \{x : \underbrace{(w_k - w_{C_0})^T x + (b_k - b_{C_0})}_{\text{فاصله ابرصفحه از مبدأ}} = 0\} \leftarrow \text{(معادله ابرصفحه)}$$


$$d_k = \text{dist}(x_0, F_k) = \frac{|(w_k - w_{C_0})^T x_0 + (b_k - b_{C_0})|}{\|w_k - w_{C_0}\|_p} = \frac{|f_k(x_0) - f_{C_0}(x_0)|}{\|w_k - w_{C_0}\|_p}$$

بنابراین، نزدیکترین مرتبه تصمیم گیری $\hat{\ell}(x_0)$ با به حداقل رساندن (minimization) این فاصله روی

$$\hat{\ell}(x_0) = \arg \min_{k \neq C_0} \frac{|f_k(x_0) - f_{C_0}(x_0)|}{\|w_k - w_{C_0}\|_p}$$

همه $k \neq \hat{k}(x_0)$ یافت می‌شود:

(ج) توجه: در قسمت (ب) ما از تصمیم گیری رابا F_k نشان دادیم و در این قسمت با H_k نشان



می دهیم یعنی $H_k = F_k$ به شکل مقابل توجه کنید:

بالتوجه به شکل مقابل و قسمت (ب) کوچکترین آشفتنگی

$r^*(x_0)$ برداری است که نقطه x_0 را روی نزدیکترین ابرصفحه

$H_{\hat{\ell}(x_0)}$ تصویر (project) کند. ابرصفحه $H_{\hat{\ell}(x_0)}$ به شکل زیر تعریف

می شود:

$$H_{\hat{\ell}(x_0)} = \{x : f_{\hat{\ell}(x_0)}(x) = f_{C_0}(x)\}$$

$$\rightarrow H_{\hat{\ell}(x_0)} = \{x : w_{\hat{\ell}}^T x + b_{\hat{\ell}} = w_{C_0}^T x + b_{C_0}\} = \{x : (w_{\hat{\ell}} - w_{C_0})^T x + (b_{\hat{\ell}} - b_{C_0}) = 0\}$$

بنابراین طبق نتیجه بخش اول سوال ۱ آشفتنگی بهینه برابر است با:

$$r^*(x_0) = - \frac{(w_{\hat{\ell}} - w_{C_0})^T x_0 + (b_{\hat{\ell}} - b_{C_0})}{\|w_{\hat{\ell}} - w_{C_0}\|_2} = - \frac{f_{\hat{\ell}}(x_0) - f_{C_0}(x_0)}{\|w_{\hat{\ell}} - w_{C_0}\|_2} (w_{\hat{\ell}} - w_{C_0})$$

چون $f_{\hat{\ell}}(x_0) > f_{C_0}(x_0)$ (چرا که C_0 کلاس پیش بینی شده است) داریم $f_{\hat{\ell}}(x_0) - f_{C_0}(x_0) < 0$

بنابراین منفی این عبارت همان قدر مطلق آن است پس

$$-(f_{\hat{\ell}}(x_0) - f_{C_0}(x_0)) = |f_{\hat{\ell}}(x_0) - f_{C_0}(x_0)|$$

$$r^*(x_0) = \frac{|f_{\hat{\ell}}(x_0) - f_{C_0}(x_0)|}{\|w_{\hat{\ell}}(x_0) - w_{C_0}\|_2} (w_{\hat{\ell}}(x_0) - w_{C_0})$$

پس