

سوال ۱ - (الف) ما باید مسئله زیر را حل کنیم:

$$\max_{\|v\|_2 \leq \epsilon} \mathbb{E}_{g \sim D} [\langle g(n), v \rangle]$$

چون عملگر $\mathbb{E}$ خطی است (linearity of expectation) پس داریم:

$$\mathbb{E}_{g \sim D} [\langle g(n), v \rangle] = \langle \mathbb{E}_{g \sim D} [g(n)], v \rangle = \langle \mu, v \rangle$$

که تعریف کردیم $\mu = \mathbb{E}_{g \sim D} [g(n)]$ پس مسئله بهینه سازی می شود:

$$\max_{\|v\|_2 \leq \epsilon} \langle \mu, v \rangle$$

طبق نامساوی کوش - شوارتز داریم: (و اینکه شرط $\|v\|_2 \leq \epsilon$)

$$\langle \mu, v \rangle \leq \|\mu\|_2 \cdot \|v\|_2 \leq \|\mu\|_2 \cdot \epsilon$$

مساوی در رابطه بالا زمانی حاصل می شود که:

۱. بردار v موازی با بردار μ باشد یعنی $v = \alpha \mu$ برای یک مقدار $\alpha \geq 0$
۲. $\epsilon = \|v\|_2$ یعنی از تمام بودجه برای حدا استفاده کنیم:

$$\|v\|_2 = \|\alpha \mu\|_2 = |\alpha| \cdot \|\mu\|_2 = \epsilon$$

بنابراین داریم:

چون می خواهیم $\alpha \geq 0$ باشد تا ضرب داخلی بیشینه شود داریم:

$$|\alpha| = \frac{\epsilon}{\|\mu\|_2} \xrightarrow{\alpha \geq 0} \alpha = \frac{\epsilon}{\|\mu\|_2}$$

بنابراین بردار اختلاف بهینه می شود:

$$v^* = \alpha \mu = \varepsilon \frac{\mu}{\|\mu\|_2}$$

و مقدار بیشینه می شود:

$$\mathbb{E}_{x \sim D} [\langle g(x), v \rangle] = \langle \mu, v^* \rangle = \langle \mu, \varepsilon \frac{\mu}{\|\mu\|_2} \rangle = \varepsilon \frac{\mu^T \mu}{\|\mu\|_2}$$

$$\mathbb{E}_{x \sim D} [\langle g(x), v \rangle] = \varepsilon \frac{\|\mu\|_2^2}{\|\mu\|_2} = \varepsilon \|\mu\|_2$$

SOBHAN

(۲)

(ب.ج) طبق فرض مسئله و بخش (الف) داریم:

$$Z = \langle g(n), v^* \rangle \text{ where } v^* = \varepsilon \frac{\mu}{\|\mu\|_2}$$

ابتدایاً بخواهیم Z را محاسبه می‌کنیم: linearity of expectation

$$\mathbb{E}[Z] = \mathbb{E}_{n \sim D}[\langle g(n), v^* \rangle] = \langle \mathbb{E}[g(n)], v^* \rangle = \langle \mu, v^* \rangle$$

$$\mathbb{E}[Z] = \langle \mu, \varepsilon \frac{\mu}{\|\mu\|_2} \rangle = \varepsilon \frac{\mu^T \mu}{\|\mu\|_2} = \varepsilon \frac{\|\mu\|_2^2}{\|\mu\|_2} = \varepsilon \|\mu\|_2$$

بنابراین $\mathbb{E}[Z] = \varepsilon \|\mu\|_2$ همان طور که در (الف) هم دیدیم.

حال واریانس Z را محاسبه می‌کنیم:

$$\text{Var}(Z) = \mathbb{E}[Z^2] - (\mathbb{E}[Z])^2$$

$$\text{Var}(Z) = \mathbb{E}[\langle g(n), v^* \rangle^2] - (\langle \mathbb{E}[g(n)], v^* \rangle)^2$$

در بالا نشان دادیم که برابر با $\langle \mu, v^* \rangle$ است که $\mu = \mathbb{E}[g(n)]$

$$\text{Var}(Z) = \mathbb{E}[\langle g(n), v^* \rangle^2] - (\langle \mu, v^* \rangle)^2$$

$$\text{Var}(Z) = \mathbb{E}[(v^*)^T g(n) g(n)^T v^*] - (v^*)^T \mu \mu^T v^*$$

$$\text{Var}(Z) = (v^*)^T \mathbb{E}[g(n) g(n)^T] v^* - (v^*)^T \mu \mu^T v^*$$

$$\text{Var}(Z) = (v^*)^T (\mathbb{E}[g(n) g(n)^T] - \mu \mu^T) v^* = (v^*)^T \text{Cov}(g(n)) v^*$$

SOBHAN

توضیحات بیشتر در ادامه → طبق تعریف $\text{Cov}(g(n))$

چرا $\mu = E[g(n)]$ که $Cov(g(n)) = E[g(n)g(n)^T] - \mu\mu^T$

$$Cov(g(n)) = E[(g(n) - \mu)(g(n) - \mu)^T] = E[(g(n) - \mu)(g(n)^T - \mu^T)]$$

$$\begin{aligned} Cov(g(n)) &= E[g(n)g(n)^T - g(n)\mu^T - \mu g(n)^T + \mu\mu^T] \\ &= E[g(n)g(n)^T] - E[g(n)\mu^T] - E[\mu g(n)^T] + \mu\mu^T \\ &= E[g(n)g(n)^T] - \mu\mu^T - \mu\mu^T + \mu\mu^T \\ &= E[g(n)g(n)^T] - \mu\mu^T \end{aligned}$$

سوال ۲ (الف) برای یک نمونه ثابت (n, y) و وزن های ثابت w می خواهیم تغییر جزئی بهینه را پیدا کنیم:

$$\delta^* = \arg \max_{\|\delta\|_p \leq \epsilon} \underbrace{\max(0, 1 - yw^T(n + \delta))}_{\text{hinge loss}}$$

عبارت $\max$ داخلی به دنبال ماکزیمم کردن تابع ضرر است که به این معنی است

که ما می خواهیم عبارت $1 - yw^T(n + \delta)$ مینیمم کنیم چرا که علامت منفی دارد.

$$yw^T(n + \delta) = \underbrace{yw^T n}_{\text{عدد ثابت}} + \underbrace{yw^T \delta}_{\text{متغیر}}$$

همچنین داریم:

$$yw^T \delta = y \sum_{i=1}^n w_i \delta_i$$

بنابراین برای مینیمم کردن این عبارت باید عبارت را مینیمم کنیم.

باتوجه به شرط $\|\delta\|_\infty \leq \epsilon$ پس برای هر i داریم $|\delta_i| \leq \epsilon$

$$\text{برای مینیمم کردن } y \sum_{i=1}^n w_i \delta_i \text{ باید}$$

برای مینیم کردن $\sum_{i=1}^d w_i \delta_i$ داریم:

- اگر $y w_i > 0$ ما باید داشته باشیم $\delta_i = -\epsilon$ (بیشترین مقدار منفی ممکن)

- اگر $y w_i < 0$ ما باید داشته باشیم $\delta_i = +\epsilon$ (بیشترین مقدار مثبت ممکن)

- اگر $y w_i \geq 0$ آنده δ_i می تواند هر مقداری داخل بازه $[-\epsilon, +\epsilon]$ باشد.

عبارات بالا به فرم فشرده می توان تبدیل شکل زیر نوشته شود:

$$\delta_i^* = -\epsilon \cdot \text{sign}(y w_i) = -y \epsilon \cdot \text{sign}(w_i)$$

بنابراین به شکل برداری داریم:

$$\delta^* = -y \epsilon \cdot \text{sign}(w)$$

(ب) با استفاده از نتیجه بخش (الف) ما عبارت $\delta^* = -y \epsilon \cdot \text{sign}(w)$ را که جواب بهینه سازی است در عبارت دده جایگذاری می کنیم:

$$\begin{aligned} w^T(x + \delta) &= w^T x + w^T \delta = w^T x + w^T (-y \epsilon \cdot \text{sign}(w)) \\ &= w^T x - y \epsilon \underbrace{w^T \text{sign}(w)}_{\sum_{i=1}^d |w_i|} = w^T x - y \epsilon \sum_{i=1}^d |w_i| \end{aligned}$$

باتوجه به تعریف $\|w\|_1 = \sum_{i=1}^d |w_i|$ داریم:

$$y w^T(x + \delta^*) = y w^T x - y^2 \epsilon \|w\|_1 = y w^T x - \epsilon \|w\|_1$$

چون $y^2 \in \{-1, +1\}$ پس می توان
آن همیشه 1 است.

همین پس دس چینی قرار می‌دهیم:

$$\max_{\| \delta \|_p \leq \epsilon} \left[\max(0, 1 - y w^T (x + \delta)) \right] = \max(0, 1 - y w^T x + \epsilon \|w\|_1)$$

بنابراین مسئله بهینه‌سازی به شکل زیر ساده می‌شود:

$$\min_w \mathbb{E}_{x, y} \left[\max(0, 1 - y w^T x + \epsilon \|w\|_1) \right]$$

Standard hinge loss

که این معادل تابع ضرر استاندارد hinge با عبارت جریمه اضافی $\epsilon \|w\|_1$ است.

$\epsilon \|w\|_1$ که margin را افزایش می‌دهد.

$$\max(0, 1 - y w^T x) = \text{hinge loss}(y w^T x)$$

(ج) با استفاده از خاصیت نورم دوگان (dual norm) این مسئله قابل حل است.

برای هر $p \geq 1$ فرض کنید که q نورم دوگان (dual norm) p است.

به طوری که $\frac{1}{p} + \frac{1}{q} = 1$ بنابراین در مقادیر ثابت (x, y, w) عبارت

بهینه‌سازی فقط وابسته به $y w^T \delta$ است همان‌طور که در بخش (الف) دیدیم پس $\max$ داخلی به این شکل قرار می‌گیرد:

$$\max_{\| \delta \|_p \leq \epsilon} -y w^T \delta = \epsilon \| -y w \|_q = \epsilon |y| \cdot \| -w \|_q = \epsilon \cdot \|w\|_q$$

$|y| = 1$

چونکه $y \in \{-1, +1\}$ است. از قضیه Hölder dual norm استفاده کنیم.

SOBHAN

⑥ $\max_{\| \delta \|_p \leq \epsilon} -y w^T \delta = \max_{\| \delta \|_p \leq \epsilon} \langle -y w^T, \delta \rangle$

توجه کنید که از قضیه Holder dual norm استفاده کردیم:

$$\frac{1}{p} + \frac{1}{q} = 1 \Rightarrow \max_{\|\delta\|_p \leq \epsilon} \langle a, \delta \rangle = \epsilon \|a\|_q$$

بنابراین:

$$\max_{\|\delta\| \leq \epsilon} \max (0, 1 - y w^T (x + \delta)) = \max (0, 1 - y w^T x + \epsilon \|w\|_q)$$

در نتیجه مسئله بهینه سازی به شکل زیر ساده می شود:

$$\min_w \mathbb{E}_{x, y} [\max (0, 1 - y w^T x + \epsilon \|w\|_q)], q = \frac{p}{p-1}$$

که در واقع q همان dual norm p است یعنی $\frac{1}{p} + \frac{1}{q} = 1$

توجه کنید حالت های خاص به شکل زیر هستند:

برای $p = \infty \leftarrow q = 1$ که می دهد $\|w\|_1$ همان طور که در بخش (ب) دیدیم

برای $p = 2 \leftarrow q = 2$ که می دهد $\|w\|_2$ که همان نرم اقلیدسی است.

برای $p = 1 \leftarrow q = \infty$ که می دهد $\max_i |w_i| = \|w\|_\infty$

سوال ۳ (الف) عملگر تصویر بر l_∞ -ball یا همان $p = \Pi_C(u)$ عبارت

$$\|u - c\|_p^2 \text{ را روی } c \in C \text{ کمینه می کند}$$

$\min$

چون C یک l_∞ ball است پس یک convex set است بنابراین برای

هر $z \in C$ و $\lambda \in [0, 1]$ نقطه $p + \lambda(z - p) = (1 - \lambda)p + \lambda z \in C$

در مجموعه محدب C است. (by Convexity)

چون p کمینه و optimal است پس هر بردارد دیگری در C فاصله بیشتری از u دارد یعنی:

$$\|u - p\|_p^2 \leq \|u - (p + \lambda(z - p))\|_p^2$$

با استریش طرف راست داریم:

$$\|u - p\|_p^2 \leq \underbrace{\|u - p\|_p^2}_a + \underbrace{\lambda^2 \|z - p\|_p^2}_b - 2\lambda \langle u - p, z - p \rangle$$

$$\cancel{\|u - p\|_p^2} \leq \cancel{\|u - p\|_p^2} + \lambda^2 \|z - p\|_p^2 - 2\lambda \langle u - p, z - p \rangle$$

$$0 \leq \lambda^2 \|z - p\|_p^2 - 2\lambda \langle u - p, z - p \rangle$$

$$0 \leq \lambda \|z - p\|_p^2 - 2 \langle u - p, z - p \rangle$$

$$0 \leq 2 \langle u - p, z - p \rangle - \lambda \|z - p\|_p^2 \quad \times (-1)$$

حال با گرفتن حد با میل دادن $\lambda \rightarrow 0^+$ داریم:

$$2 \langle u - p, z - p \rangle \leq 0 \xrightarrow{\text{تقسیم بر ۲}} \langle u - p, z - p \rangle \leq 0$$

Subject:

Year: Month: Date:

(ب) ا. بیاید عبارت $\|\delta_t - \delta^*\|_p^2$ را بسط دهیم:

$$\|\delta_t - \delta^*\|_p^2 = \|\delta_t - \delta_{t+1} + \delta_{t+1} - \delta^*\|_p^2$$

$$= \|(\delta_t - \delta_{t+1}) + (\delta_{t+1} - \delta^*)\|_p^2$$

$$= \|\delta_t - \delta_{t+1}\|_p^2 + \|\delta_{t+1} - \delta^*\|_p^2 + 2 \langle \delta_t - \delta_{t+1}, \delta_{t+1} - \delta^* \rangle$$

این دو عبارت را به طرف دیگر تساوی می بریم:

$$2 \langle \delta_t - \delta_{t+1}, \delta_{t+1} - \delta^* \rangle = \|\delta_t - \delta^*\|_p^2 - \|\delta_t - \delta_{t+1}\|_p^2 - \|\delta_{t+1} - \delta^*\|_p^2$$

همان طور که می خواستیم این عبارت اثبات شد. $\square$

(ب) ۲. با توجه به الگوریتم PGA در هر گام داریم $\delta_{t+1} = \Pi_C(\delta_t + \alpha \nabla F(\delta_t))$

فرض کنید: $u = \delta_t + \alpha \nabla F(\delta_t)$ و $p = \delta_{t+1}$

بنابراین طبق نامساوی (۲) در بخش (الف) داریم: فرض کنید $z = \delta^*$

$$\langle u - p, z - p \rangle \leq 0 \quad \begin{matrix} z = \delta^*, p = \delta_{t+1} \\ u = \delta_t + \alpha \nabla F(\delta_t) \end{matrix}$$

$$\langle \delta_t + \alpha \nabla F(\delta_t) - \delta_{t+1}, \delta^* - \delta_{t+1} \rangle \leq 0$$

$$\langle (\delta_t - \delta_{t+1}) + \alpha \nabla F(\delta_t), \delta^* - \delta_{t+1} \rangle \leq 0 \quad \left. \begin{array}{l} \text{طبق خاصیت} \\ \text{خطی بودن} \\ \text{ضرب داخلی} \end{array} \right\}$$

$$\langle \delta_t - \delta_{t+1}, \delta^* - \delta_{t+1} \rangle + \alpha \langle \nabla F(\delta_t), \delta^* - \delta_{t+1} \rangle \leq 0$$

$$\alpha \langle \nabla F(\delta_t), \delta^* - \delta_{t+1} \rangle \leq - \langle \delta_t - \delta_{t+1}, \delta^* - \delta_{t+1} \rangle \quad \text{پس داریم:}$$

$$\langle \delta_{t+1} - \delta_t, \delta^* - \delta_{t+1} \rangle \quad \text{عبارت اول را} \\ \text{قریبی کنیم.}$$

حال از مساوی (۳) در قسمت ۱ همین سوال استفاده می کنیم توجه کنید سمت راست نامساوی بالا نصف طرف چپ ~~نشان~~ تساوی ۱ هست.

$$\langle \delta_{t+1} - \delta_t, \delta^* - \delta_{t+1} \rangle = \frac{1}{2} (\|\delta_t - \delta^*\|_2^2 - \|\delta_t - \delta_{t+1}\|_2^2 - \|\delta_{t+1} - \delta^*\|_2^2)$$

$$\text{ترکیب } * \text{ یا } **$$

$$\alpha \langle \nabla F(\delta_t), \delta^* - \delta_{t+1} \rangle \leq \frac{1}{2} (\|\delta_t - \delta^*\|_2^2 - \|\delta_t - \delta_{t+1}\|_2^2 - \|\delta_{t+1} - \delta^*\|_2^2)$$

$$\langle \nabla F(\delta_t), \delta^* - \delta_{t+1} \rangle \leq \frac{1}{2\alpha} (\|\delta_t - \delta^*\|_2^2 - \|\delta_t - \delta_{t+1}\|_2^2 - \|\delta_{t+1} - \delta^*\|_2^2) \quad \text{تفسیر بر} \\ \alpha > 0$$

II

بخش (ج) ام با توجه به تعریف تابع مقعر (Concavity) ~~برای هر~~

$$F(\lambda x + (1-\lambda)y) \geq \lambda F(x) + (1-\lambda)F(y) \quad \lambda \in [0,1] \text{ داریم:}$$

حال نسبت به λ مشتق می گیریم و مقدار عبارت را در $\lambda=0$ حساب می کنیم:

مشتق نسبت

در $\lambda=0$

$$\rightarrow \langle \nabla F(y), x-y \rangle \geq F(x) - F(y)$$

بنابراین داریم:

$$F(x) - F(y) \leq \langle \nabla F(y), x-y \rangle$$

اثبات شد. $\square$

توجه: می توانستیم از first order condition برای تابع مقعر F استفاده کنیم یعنی:

$$F(x) \leq F(y) + \langle \nabla F(y), x-y \rangle$$

(ج) ۲. از معادله (۵) با برابر قرار دادن $y = \delta_t^*$ و $x = \delta_t$ داریم:

$$(*) \quad F(\delta^*) - F(\delta_t) \leq \langle \nabla F(\delta_t), \delta^* - \delta_t \rangle$$

همچنین از معادله (۶) با برابر قرار دادن $u = \delta_{t+1}$ و $v = \delta_t$ داریم:

$$F(\delta_{t+1}) \geq F(\delta_t) + \langle \nabla F(\delta_t), \delta_{t+1} - \delta_t \rangle - \frac{L}{2} \|\delta_{t+1} - \delta_t\|_2^2$$

با rearrange کردن داریم:

$$F(\delta_t) - F(\delta_{t+1}) \leq -\langle \nabla F(\delta_t), \delta_{t+1} - \delta_t \rangle + \frac{L}{2} \|\delta_{t+1} - \delta_t\|_2^2$$

$$F(\delta_t) - F(\delta_{t+1}) \leq \langle \nabla F(\delta_t), \delta_t - \delta_{t+1} \rangle + \frac{L}{2} \|\delta_{t+1} - \delta_t\|_2^2 \quad (**)$$

با جمع کردن نامساوی‌های (*) و (**) داریم:

$$F(\delta^*) - F(\delta_{t+1}) \leq \underbrace{\langle \nabla F(\delta_t), \delta^* - \delta_t \rangle}_{\text{فاکتوری بگیریم}} + \underbrace{\langle \nabla F(\delta_t), \delta_t - \delta_{t+1} \rangle}_{\text{از } \nabla F(\delta_t) \text{ فاکتوری بگیریم}} + \frac{L}{2} \|\delta_{t+1} - \delta_t\|_2^2$$

$$\leq \langle \nabla F(\delta_t), \delta^* - \cancel{\delta_t} + \cancel{\delta_t} - \delta_{t+1} \rangle + \frac{L}{2} \|\delta_{t+1} - \delta_t\|_2^2$$

بنابراین داریم:

$$F(\delta^*) - F(\delta_{t+1}) \leq \langle \nabla F(\delta_t), \delta^* - \delta_{t+1} \rangle + \frac{L}{2} \|\delta_{t+1} - \delta_t\|_2^2$$

$$(*) \quad \text{از بخش (ج) می‌دانیم که:} \quad F(\delta^*) - F(\delta_{t+1}) \leq \langle \nabla F(\delta_t), \delta^* - \delta_{t+1} \rangle + \frac{L}{2} \|\delta_{t+1} - \delta_t\|_2^2$$

همچنین از بخش (ب) معادله (۴) داریم:

$$\langle \nabla F(\delta_t), \delta^* - \delta_{t+1} \rangle \leq \frac{1}{2\alpha} (\|\delta_t - \delta^*\|_2^2 - \|\delta_t - \delta_{t+1}\|_2^2 - \|\delta_{t+1} - \delta^*\|_2^2)$$

بنابراین با ترکیب دو رابطه اخیر داریم:

$$F(\delta^*) - F(\delta_{t+1}) \leq \frac{1}{2\alpha} (\|\delta_t - \delta^*\|_2^2 - \|\delta_t - \delta_{t+1}\|_2^2 - \|\delta_{t+1} - \delta^*\|_2^2) + \frac{L}{2} \|\delta_{t+1} - \delta_t\|_2^2$$

$$= \frac{1}{2\alpha} (\|\delta_t - \delta^*\|_2^2 - \|\delta_{t+1} - \delta^*\|_2^2) + \left(\frac{L}{2} - \frac{1}{2\alpha} \right) \|\delta_{t+1} - \delta_t\|_2^2$$

$$\frac{1}{2} \left(L - \frac{1}{\alpha} \right) \|\delta_{t+1} - \delta_t\|_2^2 \leq 0 \quad \|\delta_{t+1} - \delta_t\|_2^2 \geq 0$$

آنگاه $\alpha \leq \frac{1}{L}$ باشد آنگاه عبارت $(L - \frac{1}{\alpha}) < 0$ و منفی است و با توجه به اینکه $\|\delta_{t+1} - \delta_t\|_2^2 \geq 0$ است پس عبارت

آن فرد نامساوی بالا منفی است. بنابراین می‌توانیم آن را حذف (drop) کنیم.

بنابراین با حذف عبارت منفی $(\frac{L}{2} - \frac{1}{2\alpha}) \|\delta_{t+1} - \delta_t\|_2^2$ از مساوی حکم خواسته شده اثبات می شود:

$$F(\delta^*) - F(\delta_{t+1}) \leq \frac{1}{2\alpha} (\|\delta_t - \delta^*\|_2^2 - \|\delta_{t+1} - \delta^*\|_2^2)$$

با فرض $\alpha \leq \frac{1}{L}$

~~تکامل می یابد~~

~~تکامل می یابد~~

(ه) ۱. برای حل مسئله معادله (۷) از قسمت (۵) را از $t=0$ تا $t=T-1$ جمع می‌کنیم:

$$\sum_{t=0}^{T-1} (F(\delta^*) - F(\delta_{t+1})) \leq \frac{1}{2\alpha} \sum_{t=0}^{T-1} (\|\delta_t - \delta^*\|_V^2 - \|\delta_{t+1} - \delta^*\|_V^2)$$

توجه کنید که این عبارت یک جمع تلسکوپی (telescoping sum) است و عبارت‌های میانی ساده می‌شوند و فقط عبارت اول و آخر باقی می‌مانند.

$$\sum_{t=0}^{T-1} (F(\delta^*) - F(\delta_{t+1})) \leq \frac{1}{2\alpha} (\|\delta_0 - \delta^*\|_V^2 - \|\delta_T - \delta^*\|_V^2) \leq \frac{1}{2\alpha} \|\delta_0 - \delta^*\|_V^2 \quad (*)$$

چون $\|\delta_0 - \delta^*\|_V^2 \leq 0$ همیشه یک عبارت نامنفی است پس $\|\delta_T - \delta^*\|_V^2 \leq 0$ و می‌توان آن را برابر ۰ گرفت.

همچنین توجه کنید چون $\delta_0 = 0$ و $\|\delta^*\|_V \leq \epsilon$ داریم:

$$\|\delta_0 - \delta^*\|_V^2 = \|- \delta^*\|_V^2 = \|\delta^*\|_V^2 = \sum_{i=1}^d (\delta_i^*)^2 \leq \sum_{i=1}^d \epsilon^2 = d\epsilon^2 \quad (**)$$

در واقع bound بالا دقیق‌تر و tight تر از bound داده‌شده در راهنمایی سوال است $d\epsilon^2 \leq 4d\epsilon^2$
 $\|\delta^*\|_V^2 \leq d\epsilon^2$

$$\sum_{t=0}^{T-1} (F(\delta^*) - F(\delta_{t+1})) \leq \frac{1}{2\alpha} \|\delta^*\|_V^2 \leq \frac{1}{2\alpha} (d\epsilon^2)$$

با ترکیب (*) و (**) داریم:

تقسیم طرفین بر T

$$\frac{1}{T} \sum_{t=0}^{T-1} (F(\delta^*) - F(\delta_{t+1})) \leq \frac{d\epsilon^2}{2\alpha T} \leq 4 \times \left(\frac{d\epsilon^2}{2\alpha T} \right) = \frac{2\epsilon^2 d}{\alpha T}$$

چون عدد مثبت است می‌توان در ۴ ضرب کرد.

$$\frac{1}{T} \sum_{t=0}^{T-1} (F(\delta^*) - F(\delta_{t+1})) \leq \frac{2\epsilon^2 d}{\alpha T}$$

۲. در معادله (۶) در بخش (ج) مقادیر $u = \delta_{t+1}$ و $v = \delta_t$ را جایگذاری می‌کنیم:

$$(*) \quad F(\delta_{t+1}) \geq F(\delta_t) + \langle \nabla F(\delta_t), \delta_{t+1} - \delta_t \rangle - \frac{L}{2} \|\delta_{t+1} - \delta_t\|_V^2$$

حل با توجه به تعریف PGA و نامساوی projection در معادله (۲) بخش (الف) داریم:

$$Z = \delta_t \quad P = \delta_{t+1} \quad \langle \alpha \nabla F(\delta_t) + \delta_t - \delta_{t+1}, \delta_t - \delta_{t+1} \rangle \leq 0$$

$$u = \alpha \nabla F(\delta_t) + \delta_t \quad \langle \alpha \nabla F(\delta_t), \delta_t - \delta_{t+1} \rangle + \langle \delta_t - \delta_{t+1}, \delta_t - \delta_{t+1} \rangle \leq 0$$

$$\alpha \cdot \langle \nabla F(\delta_t), \delta_t - \delta_{t+1} \rangle \leq - \langle \delta_t - \delta_{t+1}, \delta_t - \delta_{t+1} \rangle = -\|\delta_t - \delta_{t+1}\|_V^2$$

~~الکسیرم طرفین میں~~

$$** \quad \langle \nabla F(\delta_t), \delta_{t+1} - \delta_t \rangle \geq \frac{1}{\alpha} \|\delta_{t+1} - \delta_t\|_2^2$$

طرفین رابر α - تقسیم میں کیں۔

باترکیب رابطہ ~~**~~ یا ~~*~~ داریم:

$$F(\delta_{t+1}) \geq F(\delta_t) + \langle \nabla F(\delta_t), \delta_{t+1} - \delta_t \rangle - \frac{L}{2} \|\delta_{t+1} - \delta_t\|_2^2 \geq F(\delta_t) + \underbrace{\frac{1}{\alpha} \|\delta_{t+1} - \delta_t\|_2^2 + \frac{1}{2} \|\delta_{t+1} - \delta_t\|_2^2}_{\text{خاکتوری کیریم}}$$

$$F(\delta_{t+1}) \geq F(\delta_t) + \left(\frac{1}{\alpha} - \frac{L}{2} \right) \|\delta_{t+1} - \delta_t\|_2^2$$

$$F(\delta_{t+1}) \geq F(\delta_t) + c, \quad c \geq 0$$

$\frac{1}{\alpha} - \frac{L}{2} \geq 0 \quad \|\cdot\|_2^2 \geq 0$

چون طبق فرض مسئلہ داریم $\frac{1}{L} \leq \alpha$ پس $\frac{1}{\alpha} - \frac{L}{2} \geq 0$ بتایم

$$F(\delta_{t+1}) \geq F(\delta_t)$$

$$\alpha \leq \frac{1}{L} \Rightarrow \frac{1}{\alpha} \geq L \Rightarrow \frac{1}{\alpha} - \frac{L}{2} \geq \frac{L}{2} \geq 0 \Rightarrow \frac{1}{\alpha} - \frac{L}{2} \geq 0 \quad \text{توجہ: } \star$$

۱. (9) چون ثابت کردیم که تابع F ناگهشی است (بخش هـ) $\Rightarrow$

برای هر $t \leq T$ داریم $F(\delta_T) \geq F(\delta_t)$ بنابراین:

$$t \leq T \rightarrow F(\delta_t) \leq F(\delta_T) \rightarrow -F(\delta_t) \geq -F(\delta_T)$$

$$\rightarrow F(\delta^*) - F(\delta_t) \geq F(\delta^*) - F(\delta_T) \quad (*)$$

for any $t \leq T$

$$\frac{1}{T} \sum_{t=1}^{T-1} (F(\delta^*) - F(\delta_{t+1})) \leq \frac{C}{T} \text{ where } C = \frac{2\epsilon^2 d}{\alpha} \quad \text{همچنین از قسمت (هـ) می دانیم که:}$$

حال رابطه (*) را برای $t = 1, \dots, T$ نوشته و باهم جمع می کنیم:

$$\left. \begin{aligned} t=1 &\rightarrow F(\delta^*) - F(\delta_T) \leq F(\delta^*) - F(\delta_1) \\ t=2 &\rightarrow F(\delta^*) - F(\delta_T) \leq F(\delta^*) - F(\delta_2) \\ &\vdots \\ t=T &\rightarrow F(\delta^*) - F(\delta_T) \leq F(\delta^*) - F(\delta_T) \end{aligned} \right\} \text{ باهم جمع می کنیم} \Rightarrow T(F(\delta^*) - F(\delta_T)) \leq \sum_{t=1}^{T-1} (F(\delta^*) - F(\delta_{t+1}))$$

تقسیم طرفین بر T

$$F(\delta^*) - F(\delta_T) \leq \frac{1}{T} \sum_{t=1}^{T-1} (F(\delta^*) - F(\delta_{t+1})) \leq \frac{C}{T} \text{ where } C = \frac{2\epsilon^2 d}{\alpha}$$

طبق رابطه (**)

$$F(\delta^*) - F(\delta_T) \leq \frac{C}{T} \leq O\left(\frac{1}{T}\right) \quad C = \frac{2\epsilon^2 d}{\alpha} \quad \text{بنابراین داریم:}$$

۲. تفسیر: برای یک تابع هدف L -smooth و مقعر و روی یک convex set الگوریتم PGA

با طول کام $\frac{1}{L} \leq \alpha$ با مرتبه زمانی $O\left(\frac{1}{\epsilon}\right)$ و به شکل sublinearly همگرا می شود. یعنی کران

$F(\delta^*) - F(\delta_T) \leq O\left(\frac{1}{T}\right)$ بیان می کند که PGA با نرخ $\frac{1}{T}$ همگرا می شود. بعد از T بار تکرار

فاصله بین optimal value و مقدار فعلی δ_T متناسب با $\frac{1}{T}$ کاهش می یابد. بنابراین برای رسیدن

به جواب ϵ -optimal (یعنی $F(\delta^*) - F(\delta_T) \leq \epsilon$) ما به $T = O\left(\frac{1}{\epsilon}\right)$ تکرار الگوریتم

PGA نیاز داریم.

۱. non-concavity: تابع ضرر $L(x+\delta, y; \theta)$ که تابعی از δ است

است یک تابع مقعر در شبکه های عصبی به صورت کلی نیست. بلکه به شدت non-convex و non-concave است و

دارای local max, local min و saddle point های بسیاری است.

بنابراین نامساوی هایی که بر اساس معنی ~~لاصحت~~ بودن هستند و استفاده کردیم قابل استفاده نیستند.


۲. lack of smoothness: ثابت صواری L (smooth L) ممکن است در عمل بسیار بزرگ (بنابراین نیاز به ϵ بسیار کوچک!) یا بد تعریف (ill defined) باشد. به ویژه با استفاده از توابع فعال سازی مثل ReLU یا max pooling. بنابراین فرض L smooth که از آن در اثبات ها استفاده کردیم برقرار نیست.

۳. Complex Geometry of loss landscape: شبکه های عصبی به شدت غیر مقعر (یا غیر محدب) هستند و دارای تعداد زیادی local optima, saddle point و flat region هستند که صیقلی راسختی کنه و ممکن است PGA در local maxima گیر کنه و به optimal maxima نرسد. بنابراین گمان های ناگهانی بودن F و گمان های تلنگری ~~قابل استفاده~~ نیستند.

۴. Empirical observation: در عمل adversarial attacks روی شبکه های عصبی رفتار Non-monotonic در اغلب موارد دارند و در local max ها گیر می افتند و نیاز به multiple random restart یا روش های بهینه سازی پیچیده ای دارند. بنابراین $O(1/\epsilon)$ فقط تئوریتی برای ~~این~~ شرایط convex-concave است و برای DNN ها انتظاری رود.

$$f(x) < 0 \quad w^T x + b = 0 \quad f(x) > 0$$

سوال ۳ (الف)



برای دسته‌بندی خطی $f(x) = \text{sign}(w^T x + b)$ ما باید $f(x)$ را با کمترین اغتشاش (perturbation) δ را که علامت classification را تغییر دهد پیدا کنیم.

$$r(x) = \frac{|w^T x + b|}{\|w\|_2}$$

توجه کنید که دسته‌بندی وقتی $w^T x + b > 0$ باشد + را خروجی می‌دهد و اگر $w^T x + b < 0$ باشد - خروجی می‌دهد.

فاصله هندسی نقطه x از مرز تصمیم‌گیری $w^T x + b = 0$

بنابراین برای یک نقطه ثابت x با w ثابت $f(x) = \text{sign}(w^T x + b)$ باشد آنگاه $f(x)$ که تابع ما را دسته‌بندی می‌کند اگر δ را تغییر دهیم علامت را عوض می‌کند.

$$\text{sign}(w^T (x + \delta) + b) \neq \text{sign}(w^T x + b)$$

بنابراین کوچکترین آشفتنی δ (Smallest perturbation) که علامت را عوض می‌کند باید ویژگی زیر را داشته باشد:

$$w^T (x + \delta) + b = 0 \rightarrow w^T x + w^T \delta + b = 0 \rightarrow w^T \delta = -(w^T x + b)$$

$$|w^T \delta| = |w^T x + b|$$

قدر مطلق از طرفین

در واقع δ کوچکترین آشفتنی با مینیمم کردن $\|\delta\|_2$ به طوری که $w^T \delta = -(w^T x + b)$ باشد حاصل می‌شود.

$$|w^T \delta| \leq \|w\|_2 \|\delta\|_2$$

کوشی-شوارتز

$$\|\delta\|_2 \geq \frac{|w^T \delta|}{\|w\|_2} \rightarrow \|\delta\|_2 \geq \frac{|w^T x + b|}{\|w\|_2}$$

بنابراین کوچکترین آشفتنگی μ $\| \delta \|$ (با اندازه minimum) که بتواند علامت را
اندازه

$$r(x) = \frac{|w^T x + b|}{\|w\|_2}$$

تغییر دهنده برابر است با

بنابراین هر آشفتنگی δ با اندازه $r(x) < \| \delta \|_2$ نمی تواند علامت فزونی
را عوض کند.

همچنین همان طور که در تمرین های قبل دیدیم با استفاده از لاگرانژ یارید
هندسی مقدار دقیق δ^* که برابر است با:

$$\delta^* = - \frac{w^T x + b}{\|w\|_2^2} \cdot w$$

(ب) برای $\epsilon \sim N(0, \sigma^2 I)$ داریم:

$$f(x + \epsilon) = \text{sign}(\underbrace{w^T(x + \epsilon) + b}_Z) = \text{sign}(\underbrace{w^T x + b}_Z + w^T \epsilon)$$

فرض کنید $Z = w^T x + b$ باشد (margin of original input)

چون $\epsilon \sim N(0, \sigma^2 I)$ داریم:

$$w^T \epsilon \sim N(0, \sigma^2 \|w\|_2^2)$$

پس:

$$w^T x + b + w^T \epsilon = Z + w^T \epsilon \sim N(Z, \sigma^2 \|w\|_2^2)$$

حال باید احتمال هارا محاسبه کنیم: (تقسیم دو طرف به عبارت مثبت $\sigma \|w\|_2$)

$$\mathbb{P}[f(x + \epsilon) = +1] = \mathbb{P}[Z + w^T \epsilon > 0] = \mathbb{P}\left[\frac{w^T \epsilon}{\sigma \|w\|_2} > -\frac{Z}{\sigma \|w\|_2}\right]$$

فرض کنید $Z \sim N(0, 1)$ پس:

$$\mathbb{P}[f(x + \epsilon) = +1] = \mathbb{P}\left[Z > -\frac{Z}{\sigma \|w\|_2}\right] = \Phi\left(\frac{Z}{\sigma \|w\|_2}\right)$$

Φ همان CDF و توزیع نورمال استاندارد است.

SOBHAN

Φ is CDF of standard normal distribution

$$P(A) + P(A') = 1 \quad \text{متن احتمال}$$

Subject:

Year: Month: Date:

به طور مشابه

$$P[f(x+\epsilon) = -1] = 1 - \Phi\left(\frac{z}{\sigma \|w\|_2}\right)$$

توجه کنید تابع Φ الیتراسعدی است و اگر $z > 0$ آنگاه $\Phi(z) > \frac{1}{2}$ و اگر $z < 0$ آنگاه $\Phi(z) < \frac{1}{2}$

$$P[f(x+\epsilon) = -1] = \Phi\left(-\frac{z}{\sigma \|w\|_2}\right)$$

$$\Phi\left(\frac{z}{\sigma \|w\|_2}\right) > \underbrace{\Phi(0)}_{\frac{1}{2}} \quad \text{آنگاه } (f(x) = +1) \quad z = w^T x + b > 0$$

$$P[f(x+\epsilon) = +1] > \frac{1}{2} \quad \text{بنابراین} \quad \Phi\left(\frac{z}{\sigma \|w\|_2}\right) > \frac{1}{2}$$

$$\text{اگر } z = w^T x + b < 0 \quad (f(x) = -1) \quad \text{آنگاه} \quad \Phi\left(\frac{z}{\sigma \|w\|_2}\right) < \frac{1}{2} \quad \text{یا}$$

$$P[f(x+\epsilon) = +1] < P[f(x+\epsilon) = -1] \quad \text{بنابراین} \quad \Phi\left(-\frac{z}{\sigma \|w\|_2}\right) > \frac{1}{2}$$

بنابراین

$$g(x) = \arg \max_{c \in \{-1, +1\}} P[f(x+\epsilon) = c] = \text{sign}(z) = \text{sign}(w^T x + b) = f(x)$$

پس برای هر $\sigma > 0$ محتمل ترین کلاس پس از اضافه کردن نویز گاوسی

با میانگین صفر و واریانس σ^2 همان خروجی دسته بندی ازای ورودی

اصلی است.

توجه کنید حالت $z = w^T x + b = 0$ حالت عدم قطعیت است و محتمل ترین کلاس پس از اضافه کردن نویز $z = 0$ باشد هر دو احتمال برابر $\frac{1}{2}$ است و در این حالت تساوی خود $f(x)$ مبهم است (محتمل ترین کلاس معلوم نیست) و هر دو دسته به یک اندازه محتمل

SOBHAN

هر قاعده شکست تساوی نتیجه یکسانی می دهد.