



امنیت و حریم خصوصی در یادگیری ماشین (۴۰۸۱۶)
نیمسال اول سال تحصیلی ۱۴۰۴-۱۴۰۵
استاد درس: دکتر امیرمهدی صادقزاده

طراح: عرفان صبحانی

مهلت تحویل: ساعت ۵۹:۵۳:۲۳ دی ۱۴۰۴

تمرین شماره ۳

نکات و قواعد

۱. سوالات خود را زیر پیام مربوطه در Quera مطرح نمایید.
۲. لطفا مطابق تاکید پیشین، حتما آداب نامه‌ی انجام تمرین‌های درسی را رعایت نمایید. در صورت تخطی از آیین نامه، در بهترین حالت مجبور به حذف درس خواهید شد.
۳. از تحویل تمرین نظری به شکل تایپ شده (فایل Word-Latex یا هر نوع تایپ شده دیگری) بهره‌ییزید و حتما پاسخ دست نویس تحویل دهید.
۴. در صورتی که پاسخ‌های سوالات نظری را به صورت دست‌نویس آماده کرده‌اید، لطفا تصاویر واضحی از پاسخ‌های خود ارسال کنید. در صورت ناخوانا بودن پاسخ ارسالی، نمره‌ای به پاسخ ارسال شده تعلق نمی‌گیرد.
۵. همه‌ی فایل‌های مربوط به پاسخ خود را در یک فایل فشرده و با نام SPML_HW3_StdNum_FirstName_LastName ذخیره کرده و ارسال نمائید.

سوال ۱ تضمین انصاف فردی^۱ (۳۰ نمره)

✓ بخش الف)

فرض کنید مدل $M = h_{\psi} \circ f_{\theta}$ را داریم که در آن تابع $f_{\theta}: \mathbb{R}^n \rightarrow \mathbb{R}^k$ استخراج‌گر ویژگی و تابع $h_{\psi}: \mathbb{R}^k \rightarrow \mathbb{R}^o$ دسته‌بند است. همچنین تابعی برای تعریف شباهت به شکل $\phi: \mathbb{R}^n \times \mathbb{R}^n \rightarrow \{0, 1\}$ مفروض است. برای یک نمونه‌ی مشخص x ، ویژگی‌های آن را با نماد $z = f_{\theta}(x)$ و مجموعه نمونه‌های مشابه آن را به شکل $S_{\phi}(x) = \{x' \in \mathbb{R}^n \mid \phi(x, x')\}$ نشان می‌دهیم. فرض کنید

$$\epsilon = \max_{x' \in S_{\phi}(x)} \|z - f_{\theta}(x')\|_{\infty}.$$

عنصر y -ام بردار h_{ψ} با نماد $h_{\psi}^{(y)}$ نمایش داده می‌شود. اگر به‌ازای تمام مقادیری از y' که متفاوت با $y = M(x)$ هستند، داشته باشیم

$$\max_{z' \in \mathbb{B}_{\infty}(z, \epsilon)} h_{\psi}^{(y')}(z') - h_{\psi}^{(y)}(z') < 0, \quad (1)$$

آنگاه نشان دهید برای هر $x' \in S_{\phi}(x)$ تساوی $M(x) = M(x')$ برقرار است.

✓ بخش ب)

به‌طور خلاصه و به زبان ساده توضیح دهید چرا نتیجه اثبات‌شده در بخش الف) تضمین می‌کند مدل دسته‌بند برای تمام داده‌ها از فضای ورودی عملکردی منصفانه خواهد داشت؟

بخش ج

با فرض بالا بودن ابعاد فضای ویژگی‌ها، توضیح دهید چه نقطهٔ ضعیفی در این نوع از ضمانت وجود خواهد داشت؟

سوال ۲ حملهٔ تخصصی با دستهٔ پیش‌بینی‌شده (۷۰ + ۱۰۰ نمره)

الگوریتم‌های حملات تخصصی در سطوح دسترسی مختلفی تعریف می‌شوند. الگوریتم‌های جعبه‌سفید^۲ به اطلاعات مدل از جمله گرادینت‌های آن دسترسی دارند. از سوی دیگر، الگوریتم‌های جعبه‌سیاه^۳ تنها به خروجی مدل دسترسی دارند. این خروجی می‌تواند بردار احتمالی لایهٔ آخر شبکه باشد یا در حالتی پیچیده‌تر تنها دستهٔ پیش‌بینی‌شده توسط مدل باشد. در این سوال الگوریتمی برای حالت آخر معرفی می‌کنیم و سپس نتایج جالبی برای آن اثبات خواهیم کرد.

برای یک مسئلهٔ دسته‌بندی m -دسته‌ای، تابع تفکیک‌کننده^۴ $F: \mathbb{R}^d \rightarrow \mathbb{R}^m$ مفروض است. برای یک ورودی خاص به شکل $x \in [0, 1]^d$ بردار خروجی حاصل از اعمال تابع تفکیک‌کننده برابر با $y \in \Delta_m := \{y \in [0, 1]^m: \sum_{i=1}^m y_i = 1\}$ است. پس $y = (F_1(x), \dots, F_m(x))$ است که در آن $F_c(x)$ نشان‌دهندهٔ احتمال تعلق ورودی x به دستهٔ c -ام تحت تابع $F(\cdot)$ است. تابع دسته‌بند $C: \mathbb{R}^d \rightarrow [m]$ را نیز در نظر بگیرید به‌طوری که

$$C(x) = \arg \max_{c \in [m]} F_c(x).$$

حال می‌خواهیم برای یک نمونهٔ مشخص x^* حمله‌ای غیرهدفمند^۵ طراحی کنیم به‌طوری که اگر دستهٔ مربوط به x^* برابر با c^* باشد، آنگاه برای نمونهٔ تخصصی x' دسته‌ای به شکل $c \in [m] \setminus \{c^*\}$ توسط مدل پیش‌بینی شود. به منظور ارزیابی موفقیت حمله، تابع پیوسته و دوبار مشتق‌پذیر $S_{x^*}(x'): \mathbb{R}^d \rightarrow \mathbb{R}$ را به شکل زیر تعریف می‌نماییم:

$$S_{x^*}(x') := \max_{c \neq c^*} F_c(x') - F_{c^*}(x').$$

هنگامی که نمونهٔ x' یک حملهٔ موفق باشد، داریم $S_{x^*}(x') > 0$. در نتیجه، مسئلهٔ یافتن نمونهٔ تخصصی را می‌توان به شکل مسئلهٔ بهینه‌سازی مقید زیر بازنویسی کرد:

$$\min_{x'} \|x' - x^*\|_2 \quad \text{s.t.} \quad S_{x^*}(x') > 0. \quad (2)$$

در این سوال ابتدا در قسمت (I) با فرض دسترسی داشتن به گرادینت ∇S_{x^*} ، الگوریتمی تکرارشونده^۶ برای یافتن یک نمونهٔ تخصصی پیشنهاد می‌کنیم و هم‌گرایی آن را اثبات می‌کنیم. سپس در قسمت (II) مشکل عدم دسترسی به ∇S_{x^*} در یک حملهٔ جعبه‌سیاه را با ارائهٔ تخمینی برای آن حل خواهیم کرد.

بخش اول (بررسی همگرایی) (۷۰ نمره)

در الگوریتم پیشنهادی، ابتدا بردار x_0 طوری انتخاب می‌شود که $S_{x^*}(x_0) > 0$ باشد؛ این انتخاب می‌تواند از میان نمونه‌های سایر دسته‌ها یا به‌طور تصادفی انتخاب شود اما بایستی حتماً دسته‌ای متفاوت با x^* داشته باشد. برای x_0 و دنبالهٔ گام‌های $\{\xi_t\}_{t \geq 0}$ ، برای تولید نمونهٔ تخصصی از قاعدهٔ به‌روزرسانی زیر استفاده می‌کنیم:

$$x_{t+1} = \alpha_t x^* + (1 - \alpha_t) \left[x_t + \xi_t \frac{\nabla S_{x^*}(x_t)}{\|\nabla S_{x^*}(x_t)\|_2} \right], \quad (3)$$

که در آن پارامتر $\alpha_t \in [0, 1]$ طوری انتخاب می‌شود که $S_{x^*}(x_{t+1}) = 0$ باشد. برای ارزیابی دنبالهٔ معادلهٔ (۳) معیار زیر را در نظر می‌گیریم:

$$r_t = r(x_t, x^*) := \frac{\langle x_t - x^*, \nabla S_{x^*}(x_t) \rangle}{\|x_t - x^*\|_2 \|\nabla S_{x^*}(x_t)\|_2}. \quad (4)$$

white-box^۱
black-box^۳
function discriminant^۴
untargeted^۵
iterative^۶

همچنین می‌دانیم تحت شرایط ساده‌ای، x_t یک نقطه سکون^۷ برای مسئله^(۲) است، اگر و تنها اگر $r_t = 1$ باشد. برای سادگی نوشتار، فرض کنید $\tau_t := \frac{\xi_t}{\|\nabla S_{x^*}(x_t)\|_2}$ پس رابطه^(۳) به شکل زیر بازنویسی می‌شود:

$$x_{t+1} = \alpha_t x^* + (1 - \alpha_t) [x_t + \tau_t \nabla S_{x^*}(x_t)]. \quad (۵)$$

بخش الف ✓

برای پارامتر طول گام انتخابی مناسب تابعی کاهشی است زیرا انتظار می‌رود در صورت کارا بودن الگوریتم به‌مرور به x^* نزدیک شویم؛ انتخابی که برای آن انجام می‌دهیم به شکل

$$\xi_t = \eta_t \|x_t - x^*\|_2$$

که در آن $\eta_t := t^{-q}$ برای مقدار $q \in (\frac{1}{2}, 1)$ است. حال با فرض $d_t := x_t - x^*$ و به کمک رابطه^(۵) نشان دهید تساوی زیر برقرار است:

$$\|d_{t+1}\|_2^2 = (1 - \alpha_t)^2 \|\tau_t \nabla S_{x^*}(x_t) + d_t\|_2^2 \quad (۶)$$

بخش ب ✓

با فرض آنکه گرادیان تابع S_{x^*} ، یک تابع Lipschitz با ضریب L است و $\kappa_t := \frac{3L}{2} \left(\frac{\|d_t\|_2}{\|\nabla S_{x^*}(x_t)\|_2} \right)$ باشد، با استفاده از بسط تیلور مرتبه دوم می‌توان نشان داد که رابطه زیر برقرار است (نیازی به اثبات نیست):

$$(1 - \alpha_t)^2 \leq \left(\frac{r_t + \eta_t \kappa_t}{r_t + \eta_t (1 + \kappa_t)} \right)^2. \quad (۷)$$

با استفاده از روابط (۶) و (۷) نشان دهید:

$$\frac{\|d_{t+1}\|_2^2}{\|d_t\|_2^2} \leq \left(\frac{r_t + \eta_t \kappa_t}{r_t + \eta_t (1 + \kappa_t)} \right)^2 (\eta_t^2 + 2\eta_t r_t + 1) =: \theta_t. \quad (۸)$$

رابطه^(۸) کران بالایی برای نسبت مربع فواصل دو گام پیاپی تا x^* ارائه می‌کند. در ادامه می‌خواهیم این کران را در دو حالت تحلیل کنیم.

بخش ج

حالت اول زمانی است که $\eta_t > r_t$ باشد. اگر فرض کنیم به ازای هر z که خاصیت $S_{x^*}(z) = 0$ را دارد، اندازه گرادیان آن حاشیه‌ای تا $\cdot$ دارد؛ یعنی وجود دارد مقدار ثابت $\bar{C} > 0$ به‌طوری که $\|\nabla S_{x^*}(z)\|_2 > \bar{C}$ باشد، آنگاه طبق تعریف مقدار κ_t نیز مقداری مثبت و کران‌دار خواهد بود.

۱. توضیح دهید چرا می‌توان در $t \rightarrow \infty$ ادعا کرد که مقدار ثابت $c_1 > 0$ وجود دارد، به‌طوری که $\theta_t < 1 - c_1$.

۲. با توجه به تعریف مسئله بحث کنید که چرا نامساوی زیر برقرار است:

$$\prod_{t=1}^{\infty} \theta_t > 0. \quad (۹)$$

۳. اثبات کنید چرا فقط تعدادی متناهی اندیس وجود دارند که در حالت اول صدق می‌کنند. (راهنمایی: با برهان خلف نشان دهید که $\prod_{t=1}^{\infty} \theta_t$ به صفر هم‌گرا می‌شود.)

بخش د

حالت دوم زمانی است که $\eta_t \leq r_t$ باشد.

point stationary^۷

۱. فرض کنید $\lambda_t := \frac{\eta_t}{r_t} \leq 1$ است. با بسط دادن رابطه (۸) نشان دهید:

$$\theta_t \leq 1 - c_1 \lambda_t (1 - r_t^2) + c_2 \eta_t^2 \quad (10)$$

که در آن مقادیر $c_1, c_2 > 0$ ثابت‌های مشخصی هستند.

۲. با لگاریتم گرفتن از رابطه (۹) می‌توان نشان داد که $\sum_{t=1}^{\infty} \log \theta_t > -\infty$ که نمادی برای وجود کران پایین برای این سری است. با توجه به این مورد و با استفاده از نامساوی $\log(1+x) \geq x$ برای $x \geq -1$ نشان دهید سری زیر واگرا نمی‌شود، یعنی داریم:

$$\sum_{t=1}^{\infty} c_1 \eta_t \frac{1 - r_t^2}{r_t^2} - c_2 \eta_t^2 < \infty. \quad (11)$$

بخش هـ

با توجه به خواص سری مذکور در رابطه (۱۱)، هم‌گرا شدن آن، نرخ هم‌گرایی $o(t^{-1})$ را نتیجه می‌دهد زیرا می‌دانیم سری هارمونیک (سری با جملات مرتبه $\frac{1}{t}$) واگرا می‌شود و شرط هم‌گرایی داشتن مرتبه $O\left(\frac{1}{t^{1+\epsilon}}\right)$ به‌ازای مقادیر $\epsilon > 0$ است؛ پس با توجه به آنکه

$$c_1 \eta_t \frac{1 - r_t^2}{r_t^2} - c_2 \eta_t^2 = o(t^{-1}),$$

و فرض $\eta = t^{-q}$ برای مقدار $q \in (\frac{1}{2}, 1)$ ، نشان دهید

$$1 - r_t = o(t^{q-1}). \quad (12)$$

از رابطه (۱۲) می‌توان نتیجه گرفت که اگر انتخاب مناسبی برای پارامتر η_t انجام شود الگوریتم حتماً به نقطه‌ای می‌رسد که دو بردار $x_t - x^*$ و $\nabla S_{x^*}(x_t)$ هم‌راستا می‌شوند. پس طبق قاعدهٔ روزرسانی رابطه (۳) حرکت در جهت $\nabla S_{x^*}(x_t)$ و سپس پیدا کردن نقطه x_{t+1} روی خط واصل x_t^* و x_t که در آن S_{x^*} برابر با صفر است به همان نقطه x_t ختم می‌شود.

بخش دوم (تخمین گرادیان) (۱۰۰ نمره)

در قسمت قبلی ثابت کردیم که الگوریتم پیشنهادی تحت شرایطی با نرخ $o(t^{q-1})$ هم‌گرا می‌شود. اما چالشی مهم آن است که در حملات جعبه‌سیاه دسترسی به ∇S_{x^*} وجود ندارد پس برای حل این چالش، تخمینی از آن به شکل زیر در نظر می‌گیریم:

$$\widehat{\nabla S_{x^*}}(x_t, \delta) := \frac{1}{B} \sum_{b=1}^B \phi_{x^*}(x_t + \delta u_b) u_b, \quad (13)$$

که در آن $\phi_{x^*}(x) := \text{sign}(S_{x^*}(x))$ و پارامتر $B > 0$ و $\{u_b\}_{b=1}^B$ بردارهای d -بعدی هستند که به‌طور i.i.d. از توزیع یکنواخت بر روی کرهٔ واحد آمده‌اند و پارامتر δ نیز عدد مثبت کوچکی است. در ادامه قصد داریم نشان دهیم در نزدیکی مرز تابع S_{x^*} جهت این تخمین‌گر نزدیک به گرادیان واقعی است.

بخش الف

فرض کنید u یک بردار تصادفی است که از یک توزیع یکنواخت بر روی کرهٔ واحد می‌آید. می‌دانیم که ∇S_{x^*} یک تابع Lipschitz با ضریب L است؛ یعنی برای هر دو برابر x و y داریم.

$$\|\nabla S_{x^*}(x) - \nabla S_{x^*}(y)\|_2 \leq L \|x - y\|_2. \quad (14)$$

از سوی دیگر، برای تابع S_{x^*} بسط تیلور به‌طور دقیق برای هر $\delta \in (0, 1)$ به‌شکل زیر است:

$$S_{x^*}(x_t + \delta u) = \underbrace{S_{x^*}(x_t)}_0 + \delta \nabla S_{x^*}(x_t)^\top u + \frac{1}{2} \delta^2 u^\top \nabla^2 S_{x^*}(x') u, \quad (15)$$

که در آن x' نقطه‌ای روی خط مابین x_t و $x_t + \delta u$ است.
با استفاده از رابطه (۱۴) نشان دهید که داریم:

$$\left| \frac{1}{2} \delta^2 u^\top \nabla^2 S_{x^*}(x') u \right| \leq \frac{1}{2} L \delta^2 \quad (16)$$

(راهنمایی: از تعریف Lipschitz و نامساوی Cauchy-Schwarz و تعریف مشتق دوم در جهت u به شکل

$$\frac{d}{dh} (u^\top \nabla S_{x^*}(x + hu)) = u^\top \nabla^2 S_{x^*}(x) u,$$

استفاده کنید.)

بخش ب ✓

فرض کنید $w := \frac{1}{2} L \delta$ ، با استفاده از روابط (۱۵) و (۱۶) نشان دهید:

۱. با فرض $w < \nabla S_{x^*}(x_t)^\top u$ داریم:

$$S_{x^*}(x_t + \delta u) > 0. \quad (17)$$

۲. با فرض $-w < \nabla S_{x^*}(x_t)^\top u$ داریم:

$$S_{x^*}(x_t + \delta u) < 0. \quad (18)$$

بخش ج ✓

با توجه به تعریف تخمین‌گر در رابطه (۱۳) می‌دانیم هنگامی که بردار تصادفی هم‌راستا با گرادیان باشد رویدادی مطلوب و در غیراینصورت این رویداد نامطلوب خواهد بود. کره واحد را به رویدادهای زیر افراز می‌کنیم:

$$E_1 := \{ \nabla S(x_t)^\top u > w \}, \quad (19)$$

$$E_2 := \{ |\nabla S(x_t)^\top u| < w \}, \quad (20)$$

$$E_3 := \{ \nabla S(x_t)^\top u < -w \}. \quad (21)$$

بحث کنید اتفاق افتادن هر رویداد به‌طور شهودی چه معنایی دارد؟

بخش د

برای فضای $\mathbb{R}^d$ یک مجموعه پایه‌های یک‌ه‌متعامد $\{v_i\}_{i=1}^d$ در نظر بگیرید. با فرض $S_{x^*}(\cdot) \equiv S(\cdot)$ و بدون از دست دادن کلیت مسئله، فرض می‌کنیم تساوی $v_1 = \frac{\nabla S(x_t)}{\|\nabla S(x_t)\|_2}$ برقرار است. پس می‌توان بردار تصادفی u با توزیع یکنواخت را به شکل $u = \sum_{i=1}^d \beta_i v_i$ نمایش داد.

۱. به کمک تعاریف E_1 و E_3 و v_1 نشان دهید:

$$\mathbb{E}[\beta_1 | E_1] = -\mathbb{E}[\beta_1 | E_3] > 0 \quad (22)$$

۲. توضیح دهید چرا رابطه زیر برای هر $i \geq 2$ برقرار است:

$$\mathbb{E}[\beta_i | E_1] = \mathbb{E}[\beta_i | E_3] = 0 \quad (23)$$

بخش ه ✓

فرض کنید $p := \mathbb{P}[E_2]$ است. با استفاده از قانون امید کل^۸، امید تابع $\phi_{x^*}(x + \delta u)$ را به شکل کلی زیر به دست آورید:

$$\mathbb{E}[\phi_{x^*}(x + \delta u)] = pA + B \quad (24)$$

که در آن A و B توابعی از پارامترهای مسئله هستند. همچنین به کمک نتایج بخش د مقدار امید را ساده کنید.

^۸law of total expectation

بخش و

۱. برای هر دو بردار a و b در فضایی مشخص، نشان دهید نامساوی زیر برقرار است:

$$\cos \angle(a, b) = \frac{a^\top b}{\|a\|_2 \|b\|_2} \geq 1 - \frac{\|a - b\|_2^2}{2\|b\|_2^2} \quad (25)$$

۲. با استفاده از نامساوی مثلث می‌توان نشان داد که

$$\|\mathbb{E}[\phi_x(x_t + \delta u)u] - \mathbb{E}[|\beta_1|v_1]\|_2 \leq 2p + p = 3p, \quad (26)$$

با توجه به خطی بودن امید ریاضی و به کمک روابط (۲۵) و (۲۶) کران پایینی برای کسینوس زاویه بین گرادیان و امید تخمین‌گر بیابید.

بخش ز

۱. با فرض آنکه $\langle v_1, u \rangle^2 \sim \text{Beta}\left(\frac{1}{2}, \frac{d-2}{2}\right)$ باشد. نشان دهید:

$$\cos \angle\left(\mathbb{E}[\widehat{\nabla S}(x_t, \delta)], \nabla S(x_t)\right) \geq 1 - \frac{9L^2\delta^2(d-1)^2}{8\|\nabla S(x_t)\|_2^2}. \quad (27)$$

(راهنمایی: ابتدا کرانی بالا برای p بیابید و سپس از تساوی

$$E[|\beta_1|] \cdot \text{Beta}\left(\frac{1}{2}, \frac{d-1}{2}\right) = \frac{2}{d-1},$$

استفاده کنید.)

۲. توضیح دهید هنگامی که $\delta \rightarrow 0$ باشد، نتیجه حاصل شده در رابطه (۲۷) به چه معنا است؟

موفق باشید.