

سوال ۱ بخش (الف)

فرض کنیم $x' \in S_\phi(x)$ یک نمونه مشابه دلخواه باشد. و $z' = f_\theta(x')$ بازتابی ویژگی آن

باشد. طبق تعریف ϵ داریم:

$$\|z - z'\|_\infty = \|z - f_\theta(x')\|_\infty \leq \epsilon$$

که این یعنی $z' \in B_\infty(z, \epsilon)$

z' عضو ℓ_∞ ball با شعاع ϵ و به مرکزیت z است.

همچنین پیش بینی مدل برای x' برابر است با: $M(x') = \arg \max_i \{h_\psi^{(i)}(z')\}$

همچنین مای دانیم که $M(x) = y$ که یعنی:

$$y = \arg \max_i \{h_\psi^{(i)}(z)\}$$

از شرط (۱) که در فرض سوال داده شده است برای

تمامی $y' \neq y$ و تمامی $z' \in B_\infty(z, \epsilon)$ داریم:

$$h_\psi^{(y')}(z') - h_\psi^{(y)}(z') < 0$$

$$h_\psi^{(y')}(z') < h_\psi^{(y)}(z')$$

حال چون $z' = f_\theta(x') \in B_\infty(z, \epsilon)$ داریم:

$$h_\psi^{(y')}(f_\theta(x')) < h_\psi^{(y)}(f_\theta(x')) \text{ for all } y' \neq y$$

بنابراین چون امتیاز کلاس y اکیداً بزرگتر از هر کلاس دیگری در نقطه x' است داریم:

$$M(x') = \arg \max_i \{h_\psi^{(i)}(f_\theta(x'))\} = y = M(x)$$

بنابراین حکم ثابت می شود چون برای هر ورودی $x' \in S_\phi(x)$ داریم $M(x') = M(x)$.

بخش (ب) نتیجه اثبات شده در بخش (الف) انصاف فردی را تضمین می کند چرا که ورودی های مشابه،

خروجی های مشابه دارند. (similar inputs receive similar (identical) outputs)

اگر دو نمونه x' و x'' توسط تابع شباهت ϕ (یعنی $x' \in S_\phi(x'')$) مشابه در نظر گرفته شوند،

مدل تضمین می کند که آنها طبقه بندی یکسانی دارند. این بدان معناست که مدل با افرادی که طبق

معیار انصاف ما مشابه هستند، به طور یکسان رفتار می کند و از تبعیض بر اساس تغییرات کوچک

در ویژگی‌ها جلوگیری می‌کند. این یک تضمین قوی برای انصاف است زیرا تضمین می‌کند که اختلافات یا تفاوت‌های جزئی بین افراد مشابه منجر به رفتار متفاوت توسط دسته‌بندی نمی‌شود که لازم انصاف فردی است. در واقع اگر هر بردار ویژگی درون $a - b$ - l_∞ حول $z = f_\theta(x)$ باشد ~~ع~~ امتیاز مدل را برای کلاس اصلی $\neq$ کاملاً بزرگتر از تمام امتیازات کلاس‌های دیگر نگه دارد، آنگاه هر ورودی x که مشابه x باشد (پس بردار ویژگی آن درون آن $a - b$ قرار دارد) مانند x دسته‌بندی می‌شود. یعنی اگر دسته‌بندی حاشیه‌ای برای کلاس صحیح ~~باشد~~ داشته باشد که کل ~~همسایگی~~ همسایگی ورودی‌های مشابه را حفظ کند، ورودی‌های مشابه را نمی‌توان به کلاس دیگری منتقل کرد.

بخش (ج) نقطه ضعف اصلی در فضای ویژگی با ابعاد بالا مشکل نگرین ابعاد یا همان

curse of dimensionality است: ناحیه verification یا همان ناحیه تایید به شکل فضای یا

exponentially بزرگ می شود. گوی $\mathcal{H}$ یا همان $B_\infty(z, \epsilon)$ در یک فضای k بعدی شامل حجمی

متناسب با $(2/\epsilon)^k$ است. با افزایش ابعاد k ، این ناحیه به صورت فضای بزرگ می شود و فضای

ویژگی بسیار بیشتری از ویژگی های نمونه های مشابه را پوشش می دهد. بنابراین ارضای شرط (۱) بسیار سخت تر می شود.

پایه ها: ۱. تضمین بیش از حد محافظه کارانه: این شرط باید برای همه نقاط در $B_\infty(z, \epsilon)$ از جمله بسیاری از

نقاطی که با هیچ نمونه مشابه واقعی مطابقت ندارند برقرار باشد. این امر برآورده کردن تضمین را بسیار دشوارتر می کند.

۲. عدم قطعیت محاسباتی: تایید شرط (۱) نیاز به بررسی یک ناحیه ϵ بزرگ را دارد که تایید را از نظر محاسباتی گران یا غیر ممکن می کند.

۳. کاهش کاربرد پذیری: با افزایش ابعاد، مدل های کمتری چنین شرط دقیقی را برآورده می کنند و کاربرد عملی این تضمین انصاف را محدود می کند.

۴. کاهش دقت و انعطاف پذیری مدل: برای حفظ نابرابری (۱) در $B_\infty(z, \epsilon)$ دسته بند باید بسیار robust باشد که طبق $accuracy \sim robustness tradeoff$ دقت را کاهش می دهد به خصوص در ابعاد بالا. حاشیه های بسیار زیرین کلاس ها انعطاف پذیری مدل را کم می کند و مرزهای تصمیم گیری محافظه کارانه ممکن است دقت را کاهش دهد. و در عمل نیز با افزایش k یافتن دسته بندی که شرط (۱) را ارضا کند در همین حال عملکرد خوبی داشته باشد به طور کلی فرآیندهای دشوار یا حتی غیر ممکن است.

۵. تمرکز در جهت های متضاد: در ابعاد بالا، جهت های زیادی وجود دارند که تغییرات کوچک در آنها می تواند دسته را تغییر دهد (concentration of measure) حاشیه ای که در ابعاد پایین ممکن است این باشد در ابعاد بالا ممکن است ناگهانی هم چنین توجه کنید که این گراهی به استخراج کننده ویژگی ϕ متکی است. اگر ϕ لایپشیتز نباشد یا در برخی مختصات تغییر پذیری محلی بالایی داشته باشد، آنگاه ϵ مناسب شده از شباهت ورودی ممکن است معیار ضعیفی از تغییر پذیری واقعی در فضای ویژگی باشد.

سوال ۲ بخش اول (الف) داریم: $d_t := x_t - x^*$ و $\xi_t = \eta_t \|x_t - x^*\|_2^2$

$$\epsilon_t = \eta_t \|d_t\|_2^2 \quad \text{و} \quad \tau_t = \frac{\epsilon_t}{\|\nabla S_{x^*}(x_t)\|_2} \rightarrow \tau_t = \frac{\eta_t \|d_t\|_2^2}{\|\nabla S_{x^*}(x_t)\|_2}$$

از معادله (۵) داریم: $x_{t+1} = \alpha_t x^* + (1 - \alpha_t) [x_t + \tau_t \nabla S_{x^*}(x_t)]$ بنابراین:

$$d_{t+1} = x_{t+1} - x^* = \alpha_t x^* + (1 - \alpha_t) [x_t + \tau_t \nabla S_{x^*}(x_t)] - x^*$$

$$\begin{aligned}
 d_{t+1} &= \alpha_t x^* - x^* + (1 - \alpha_t) x_t + (1 - \alpha_t) \tau_t \nabla S_{x^*}(x_t) \\
 &= -(1 - \alpha_t) x^* + (1 - \alpha_t) x_t + (1 - \alpha_t) \tau_t \nabla S_{x^*}(x_t) \\
 &= (1 - \alpha_t) \underbrace{[x_t - x^* + \tau_t \nabla S_{x^*}(x_t)]}_{d_t} = (1 - \alpha_t) [d_t + \tau_t \nabla S_{x^*}(x_t)]
 \end{aligned}$$

$\Downarrow \|\cdot\|_p^p$

توجه کنید τ_t زمان بندی اندازه
گام انتخاب شده را مشخص می کند و این
انتخابات جبری را تغییر نمی دهد.

حال از طرفین معادله نرم ℓ_2 به توان ℓ_2 می گیریم:

$$\|d_{t+1}\|_p^p = \underbrace{\|(1 - \alpha_t)\|_p^p}_{\text{scaler}} \|d_t + \tau_t \nabla S_{x^*}(x_t)\|_p^p$$

$$\|d_{t+1}\|_p^p = (1 - \alpha_t)^p \|\tau_t \nabla S_{x^*}(x_t) + d_t\|_p^p$$

توجه کنید scalar از عملگر $\|\cdot\|_p$ به شکل
قدر مطلق خارجی شود و چون توان
 ℓ_2 داریم می توان $\sqrt[p]{\cdot}$ علامت قدر
مطلق را حذف کرد. (4)

بخش (ب): برای اثبات عبارت $\|\gamma_t \nabla S_{x^*}(x_t) + d_t\|_p^p$ را بسط می دهیم:

$$\underbrace{\|\gamma_t \nabla S_{x^*}(x_t) + d_t\|_p^p}_{\text{Scaler}} = \gamma_t^p \|\nabla S_{x^*}(x_t)\|_p^p + 2\gamma_t \langle d_t, \nabla S_{x^*}(x_t) \rangle + \|d_t\|_p^p \quad (*)$$

توجه کنید که $\varepsilon_t = \eta_t \|x_t - x^*\|_p = \eta_t \|d_t\|_p$ چرا که $\gamma_t = \frac{\varepsilon_t}{\|\nabla S_{x^*}(x_t)\|_p} = \frac{\eta_t \|d_t\|_p}{\|\nabla S_{x^*}(x_t)\|_p}$

همچنین $r_t = \frac{\langle x_t - x^*, \nabla S_{x^*}(x_t) \rangle}{\|x_t - x^*\|_p \|\nabla S_{x^*}(x_t)\|_p} = \frac{\langle d_t, \nabla S_{x^*}(x_t) \rangle}{\|d_t\|_p \|\nabla S_{x^*}(x_t)\|_p}$ (**)

$\Rightarrow \langle d_t, \nabla S_{x^*}(x_t) \rangle = r_t \|d_t\|_p \|\nabla S_{x^*}(x_t)\|_p$ (***)

حال (*) و (***) را در (**) جایگذاری می کنیم:

$$\|\gamma_t \nabla S_{x^*}(x_t) + d_t\|_p^p = \frac{\eta_t^p \|d_t\|_p^p}{\|\nabla S_{x^*}(x_t)\|_p^p} \|\nabla S_{x^*}(x_t)\|_p^p + 2 \frac{\eta_t \|d_t\|_p}{\|\nabla S_{x^*}(x_t)\|_p} \cdot r_t \|d_t\|_p \|\nabla S_{x^*}(x_t)\|_p + \|d_t\|_p^p$$

$$\|\gamma_t \nabla S_{x^*}(x_t) + d_t\|_p^p = \eta_t^p \|d_t\|_p^p + 2\eta_t r_t \|d_t\|_p^p + \|d_t\|_p^p$$

$$\|\gamma_t \nabla S_{x^*}(x_t) + d_t\|_p^p = \|d_t\|_p^p (\eta_t^p + 2\eta_t r_t + 1)$$

حال آن را در داخل رابطه (۶) قرار می دهیم:

$$\|d_{t+1}\|_p^p = (1 - \alpha_t)^p \|\gamma_t \nabla S_{x^*}(x_t) + d_t\|_p^p = (1 - \alpha_t)^p \|d_t\|_p^p (\eta_t^p + 2\eta_t r_t + 1)$$

حال از رابطه (۷) استفاده می کنیم:

$$\frac{\|d_{t+1}\|_p^p}{\|d_t\|_p^p} = (1 - \alpha_t)^p (\eta_t^p + 2\eta_t r_t + 1)$$

تقسیم طرفین بر $\|d_t\|_p^p > 0$
 $\|x_t - x^*\|_p^p > 0$

$$\downarrow (1 - \alpha_t)^p \leq \left(\frac{r_t + \eta_t K_t}{r_t + \eta_t (1 + K_t)} \right)^p$$

$$\frac{\|d_{t+1}\|_p^p}{\|d_t\|_p^p} \leq \left(\frac{r_t + \eta_t K_t}{r_t + \eta_t (1 + K_t)} \right)^p (\eta_t^p + 2\eta_t r_t + 1) =: \theta_t$$

که دقیقاً رابطه (۸) است.



بخش ج) ۱. ترجمه کنید $\eta_t := t^{-q}$ برای $q \in (\frac{1}{p}, 1)$ حال $\eta_t > r_t$ باید فاکتور اول θ_t را آنالیز کنیم. فرض کنید $a = r_t + \eta_t k_t$ و $b = r_t + \eta_t(1+k_t)$:

$$\frac{a}{b} = \frac{r_t + \eta_t k_t}{r_t + \eta_t(1+k_t)} = \frac{r_t + \eta_t k_t}{r_t + \eta_t + \eta_t k_t} < 1 \Rightarrow \left(\frac{a}{b}\right)^2 < 1 \rightarrow \text{فاکتور اول کوچکتر از ۱ است.}$$

به بیان دقیقتر برای $\eta_t > r_t$ یا همان $\frac{\eta_t}{r_t} > 1$ داریم:

$$\frac{a}{b} = \frac{r_t(1 + \frac{\eta_t}{r_t} k_t)}{r_t(1 + \frac{\eta_t}{r_t}(1+k_t))} = \frac{1 + \lambda_t k_t}{1 + \lambda_t(1+k_t)} \quad \text{where } \lambda_t = \frac{\eta_t}{r_t} > 1$$

چون k_t محدود است ($k_t \leq K$ برای یک ثابت K) داریم:

$$\frac{a}{b} \leq \frac{1 + \lambda_t K}{1 + \lambda_t(1+K)} = \frac{1 + \lambda_t K}{1 + \lambda_t + \lambda_t K} < 1 \rightarrow \left(\frac{a}{b}\right)^2 < 1 \rightarrow \text{فاکتور اول}$$

چون $\lambda_t > 1$ و $K > 0$ پس صورت کوچکتر از مخرج است و در نتیجه $\frac{a}{b} < 1$ است.

حال باید فاکتور دوم θ_t یعنی $\eta_t^2 + 2\eta_t r_t + 1$ را آنالیز کنیم. ترجمه کنید چون $t \rightarrow \infty$ پس $\eta_t \rightarrow 0$ پس $r_t \rightarrow 0$ در نتیجه فاکتور دوم صفری شد.

$$\left. \begin{array}{l} \eta_t := t^{-q} \\ q \in (\frac{1}{p}, 1) \end{array} \right\} \Rightarrow \lim_{t \rightarrow \infty} \eta_t = 0 \quad \lim_{t \rightarrow \infty} \eta_t^2 + 2\eta_t r_t + 1 = 1$$

همچنین چون $r_t < \eta_t$ پس فاکتور دوم صفری شد.

پس داریم:

$$\theta_t = \underbrace{\left(\frac{r_t + \eta_t k_t}{r_t + \eta_t(1+k_t)} \right)^2}_{\text{مقدور کوچکتر از یک است (فاکتور اول)}} \underbrace{(\eta_t^2 + 2\eta_t r_t + 1)}_{\text{وقتی } t \rightarrow \infty \text{ به ۱ میل می کند (فاکتور دوم)}}$$

بنابراین چون فاکتور اول اکیداً کوچکتر از ۱ هست و فاکتور دوم به ۱ میل می کند وقتی $t \rightarrow \infty$ وجود دارد یک $C_1 > 0$ به طوری که

$$\theta_t < 1 - C_1$$

به طور دقیق تر از آنجایی که $\frac{a}{b} < 1$ با حاشیه ای که به $\eta_t - r_t$ بستگی دارد و k_t محدود است ($0 \leq k_t \leq K$) پس $(\frac{a}{b})^2 < 1 - \epsilon$ برای یک $\epsilon > 0$ ثابت C_1 را که $\theta_t < 1 - C_1$ می دهد.

۲. از آنجایی که $S_{\eta^*}(\eta_t) > 0$ برای همه iteration های الگوریتم (الگوریتم *feasibility* را حفظ می کند) و خواص $\|d_t\|_p$ محدود باقی می ماند (چرا که مادرال بسط سازی روی یک دامنه فشرده $d \in [0, 1]^d$ هستیم)، حاصل ضرب $\prod_{t=1}^{\infty} \theta_t$ نمی تواند به صفر همگرا شود زیرا این به معنای $\|d_t\|_p \rightarrow 0$ است یعنی $\eta_t \rightarrow \eta^*$ که $S_{\eta^*}(\eta_t) > 0$ را با پیوستگی نقض می کند.

⑥

ادامه بخش (د). ۱. که در آن تقریباً $C_1 \approx 2$ و C_2 برای جملات مرتبه بالا تر در نظر گرفته شده که با محاسبات جبری به دست می آید.

۱	۲	۳
۴	۵	۶
جمع نمرات		



دانشگاه صنعتی شریف

شماره دانشجویی:	
نام و نام خانوادگی:	
شماره صندلی:	
نام استاد:	

شماره سوال: ۳. با برهان خلف فرض کنید تعداد نامتناهی از اندیس وجود دارد که $\eta_t > r_t$ را برآورده می کند و در آن ها صدق می کند. آن ها:

$$\prod_{t \in T} \theta_t = \prod_{t \in T} \theta_t \cdot \prod_{t \notin T} \theta_t \rightarrow \prod_{t=1}^{\infty} \theta_t \leq \prod_{t \in T} (1 - c_1) \cdot \prod_{t \notin T} \theta_t = 0 \cdot \prod_{t \notin T} \theta_t = 0 \quad \text{با رابطه (۹)}$$

$t \in T$ برای $\theta_t < 1 - c_1$

که در آن T مجموعه نامتناهی از اندیس های با $\eta_t > r_t$ است. از آنجایی که $1 > (1 - c_1)$ و مایک حاصل ضرب نامتناهی در نظری لیمیت $\prod_{t \in T} (1 - c_1) = 0$ که با معادله (۹) در تناقض است. بنابراین فرض خلف باطل است و فقط تعداد نامتناهی از اندیس ها $\eta_t > r_t$ برآورده می کنند.

بخش (د). ۱. بسط دادن θ_t با $\lambda_t = \frac{\eta_t}{r_t} \leq 1$:
 حال از r_t در فاکتور اول فاکتوری لیمیت:

$$\theta_t = \left(\frac{r_t + \eta_t k_t}{r_t + \eta_t (1 + k_t)} \right)^2 (\eta_t^2 + 2\eta_t k_t + 1)$$

فاکتور ۱ فاکتور ۲

$$\frac{r_t + \eta_t k_t}{r_t + \eta_t (1 + k_t)} = \frac{r_t (1 + \lambda_t k_t)}{r_t (1 + \lambda_t (1 + k_t))} = \frac{1 + \lambda_t k_t}{1 + \lambda_t (1 + k_t)}$$

برای مقادیر کوچک $\lambda_t \leq 1$ با استفاده از بسط تیلور $(1+x)^{-1} \approx 1 - x + x^2$ مخرج داریم:

$$\frac{1 + \lambda_t k_t}{1 + \lambda_t (1 + k_t)} = (1 + \lambda_t k_t) (1 - \lambda_t (1 + k_t) + O(\lambda_t^2)) = 1 + \lambda_t k_t - \lambda_t (1 + k_t) + O(\lambda_t^2) = 1 - \lambda_t + O(\lambda_t^2)$$

حال به مربع گرفتن داریم:

$$\left(\frac{1 + \lambda_t k_t}{1 + \lambda_t (1 + k_t)} \right)^2 = (1 - \lambda_t + O(\lambda_t^2))^2 = 1 - 2\lambda_t + O(\lambda_t^2)$$

درجین برای فاکتور دوم داریم:

$$\eta_t^2 + 2\eta_t r_t + 1 = 1 + 2\eta_t r_t + \eta_t^2 = 1 + 2\lambda_t r_t^2 + \lambda_t^2 r_t^2$$

حال آنها را ترکیب می کنیم:

$$\theta_t = (1 - 2\lambda_t + O(\lambda_t^2)) (1 + 2\lambda_t r_t^2 + \lambda_t^2 r_t^2) = 1 + 2\lambda_t r_t^2 - 2\lambda_t + O(\lambda_t^2)$$

چون $\lambda_t = \frac{\eta_t}{r_t}$ پس $\lambda_t^2 r_t^2 = \eta_t^2$:

$$\theta_t = 1 - 2\lambda_t (1 - r_t^2) + O(\lambda_t^2) \rightarrow \theta_t \leq 1 - c_1 \lambda_t (1 - r_t^2) + c_2 \eta_t^2$$

ادامه فرضیه بالای صفحه

بخش د) ۲. $\prod_{t=1}^{\infty} \theta_t > 0 \xrightarrow{\log} \sum_{t=1}^{\infty} \log(\theta_t) > -\infty$ رابط (۹)

حال باید از نامساوی $\log(1+x) \geq x$ برای $x \geq -1$ استفاده کنیم:

$$\sum_{t=1}^{\infty} \log(\theta_t) \geq \sum_{t=1}^{\infty} (\theta_t - 1) \geq \sum_{t=1}^{\infty} (1 - c_1 \lambda_t (1 - r_t^r) + c_2 \eta_t^r - 1)$$

$1 + x = \theta_t$
 $\theta_t - 1 \geq -1$

استفاده از رابط (۹)

$$\sum_{t=1}^{\infty} \log(\theta_t) \geq \sum_{t=1}^{\infty} -c_1 \lambda_t (1 - r_t^r) + c_2 \eta_t^r$$

$$\sum_{t=1}^{\infty} \log(\theta_t) \geq - \sum_{t=1}^{\infty} (c_1 \lambda_t (1 - r_t^r) - c_2 \eta_t^r)$$

عبارت سمت چپ محدود است

$$\sum_{t=1}^{\infty} \log(\theta_t) > -\infty$$

$$-\sum_{t=1}^{\infty} \log(\theta_t) < \infty, \quad -\sum_{t=1}^{\infty} \log(\theta_t) \leq \sum_{t=1}^{\infty} (c_1 \lambda_t (1 - r_t^r) - c_2 \eta_t^r)$$

$$\sum_{t=1}^{\infty} c_1 \lambda_t (1 - r_t^r) - c_2 \eta_t^r < \infty$$

جایگذاری $\frac{\eta_t^r}{r_t^r}$

$$\sum_{t=1}^{\infty} c_1 \eta_t \frac{(1 - r_t^r)}{r_t^r} - c_2 \eta_t^r < \infty$$

اثبات شرط هم!

بخش ه) چون $\eta_t = t^{-q}$ with $q \in (\frac{1}{p}, 1)$ داریم

$$\sum_{t=1}^{\infty} \eta_t = \sum_{t=1}^{\infty} t^{-q} = \infty \quad (\text{سری هارمونیک واژمی شود})$$

$$\sum_{t=1}^{\infty} \left(c_1 \eta_t \frac{1-r_t^p}{r_t^p} - c_2 \eta_t^p \right) > \infty \quad \text{ولی از رابطه (11) آئر}$$

چون $\sum_{t=1}^{\infty} \eta_t^p = \sum_{t=1}^{\infty} t^{-pq} < \infty$ که برای $q > \frac{1}{p}$ همگرای شود و ما هم داریم

$q \in (1, 2)$ چون $2q \in (\frac{1}{p}, 1)$ بنا بر این نیاز داریم که

$$\sum_{t=1}^{\infty} \frac{\eta_t (1-r_t^p)}{r_t^p} < \infty \quad \eta_t = t^{-q} = O(t^{-q})$$

که بر این منجر می شود که:

$$\frac{(1-r_t^p)}{r_t^p} = O\left(\frac{1}{\eta_t}\right) = O(t^q)$$

حال چون $r_t \rightarrow 1$ پس $r_t^p \rightarrow 1$ همچنین می توان صورت را به این شکل

$$1-r_t^p = (1-r_t)(1+r_t) \approx 2(1-r_t) \quad \text{نویسند:}$$

بنابر این باید $1-r_t = O(t^{q-1})$ باشد.

$$1-r_t = O(t^{-(1+q+\varepsilon)}) = O(t^{q-1}) \quad \text{for some } \varepsilon > 0$$

چون ε کوچک است.

$$1-r_t = O(t^{q-1})$$

۷	۴	۱
جمع نمرات	۵	۲
	۶	۳



دانشگاه صنعتی شریف

شماره دانشجویی	
نام و نام خانوادگی	
شماره صندلی	
نام استاد	

صفحه ۱ از ۸

بخش دوم (تخصیص گرادیان) بخش الف

به علت داشتن خاصیت Lipschitz برای ∇S_{η^*} داریم:

$$\|\nabla S_{\eta^*}(\eta') - \nabla S_{\eta^*}(\eta_t)\|_p \leq L \|\eta' - \eta_t\|_p$$

فاصله δu

چون η_t نقطه‌ای روی خط مابین η_t و $\eta_t + \delta u$ است داریم:

$$\|\eta' - \eta_t\|_p \leq \|\delta u\|_p = \delta \|u\|_p = \delta$$

چون $\delta \in (0, 1)$ یک scalar است از عمل $\|\cdot\|_p$ بیرون می‌آید.

$$\|\eta' - \eta_t\|_p \leq \delta$$

توجه: چون بردار u روی کره واحد است

$$\|u\|_p = 1$$

$$\frac{d}{dh} (u^T \nabla S_{\eta^*}(\eta' + hu)) \Big|_{h=0} = u^T \nabla^2 S_{\eta^*}(\eta') u$$

برای این طبق نامساوی Cauchy-Schwarz و خاصیت Lipschitz داریم:

$$|u^T \nabla^2 S_{\eta^*}(\eta') u| \leq \|u\|_p \|\nabla^2 S_{\eta^*}(\eta') u\|_p$$

بخش دوم (تخصیص گرادیان) بخش الف طبق تعریف مشتق دوم درجهت u داریم:

$$u^T \nabla^2 S_{\eta^*}(\eta') u = \frac{d}{dh} (u^T \nabla S_{\eta^*}(\eta' + hu)) \Big|_{h=0}$$

چون ∇S_{η^*} یک تابع Lipschitz با ضریب L است داریم:

$$\|\nabla S_{\eta^*}(\eta' + hu) - \nabla S_{\eta^*}(\eta')\|_p \leq L \|\eta' + hu - \eta'\|_p = L \|hu\|_p = L h \|u\|_p = L h$$

$\|u\|_p = 1$ چرا که روی کره واحد است. فرض کنیم $h > 0$

$$\Rightarrow \|\nabla S_{\eta^*}(\eta' + hu) - \nabla S_{\eta^*}(\eta')\|_p \leq L h$$

حال طبق نامساوی Cauchy-Schwarz داریم:

$$|u^T (\nabla S_{\eta^*}(\eta' + hu) - \nabla S_{\eta^*}(\eta'))| \leq \|u\|_p \|\nabla S_{\eta^*}(\eta' + hu) - \nabla S_{\eta^*}(\eta')\|_p \leq L h$$

توجه کنید اگر $h < 0$ هم باشد تقارنی ندارد و فقط $|h| = -h$ و به همین شکل وبا $h \rightarrow 0$ به همین صورت اثبات می شود.



بنابراین با تقسیم طرفین بر $h > 0$ داریم: (توجه کنید که $|h| = h$ و فرضی ندارد که بر h یا $|h|$ تقسیم کنیم).

$$\left| \frac{u^T (\nabla S_{x^*}(x' + hu) - \nabla S_{x^*}(x'))}{h} \right| \leq L$$

حال با گرفتن حد در $h \rightarrow 0$ داریم:

$$\lim_{h \rightarrow 0} \left| \frac{u^T (\nabla S_{x^*}(x' + hu) - \nabla S_{x^*}(x'))}{h} \right| \leq L \rightarrow |u^T \nabla S_{x^*}(x') u| \leq L$$

حال چون $\delta \in (0, 1)$ پس $\frac{1}{\delta} \delta^2 > 0$ و با ضرب طرفین در $\frac{1}{\delta} \delta^2 > 0$ داریم:

$$\frac{1}{\delta} \delta^2 |u^T \nabla S_{x^*}(x') u| \leq \frac{1}{\delta} \delta^2 L \rightarrow \left| \frac{1}{\delta} \delta^2 u^T \nabla S_{x^*}(x') u \right| \leq \frac{1}{\delta} \delta^2 L$$

بخش ب). فرض سوال: $\nabla S_{x^*}(x_t)^T u > w = \frac{1}{\delta} L \delta$

طبق رابطه (۱۵) داریم: $S_{x^*}(x_t + \delta u) = \underbrace{S_{x^*}(x_t)}_0 + \delta \nabla S_{x^*}(x_t)^T u + \frac{1}{\delta} \delta^2 u^T \nabla^2 S_{x^*}(x') u$

$\rightarrow S_{x^*}(x_t + \delta u) = \delta \nabla S_{x^*}(x_t)^T u + \frac{1}{\delta} \delta^2 u^T \nabla^2 S_{x^*}(x') u$ از فرض سوال استفاده می کنیم.

طبق رابطه (۱۶) با بزرگترین قدر مطلق داریم:

$$S_{x^*}(x_t + \delta u) > \delta w - \frac{1}{\delta} L \delta^2$$

$$\delta w - \frac{1}{\delta} L \delta^2 \geq \delta w - \delta \left(\frac{1}{\delta} L \delta \right) = \delta w - \delta w = 0.$$

$$S_{x^*}(x_t + \delta u) > 0.$$

۲. فرض سوال: $\nabla S_{x^*}(x_t)^T u < -w = -\frac{1}{\delta} L \delta$

طبق رابطه (۱۵) داریم: $S_{x^*}(x_t + \delta u) = \delta \nabla S_{x^*}(x_t)^T u + \frac{1}{\delta} \delta^2 u^T \nabla^2 S_{x^*}(x') u$ از فرض سوال استفاده می کنیم.

$$S_{x^*}(x_t + \delta u) < -\delta w + \frac{1}{\delta} \delta^2 u^T \nabla^2 S_{x^*}(x') u$$

$$S_{x^*}(x_t + \delta u) < -\delta w + \frac{1}{\delta} L \delta^2 = -\delta \left(\frac{1}{\delta} L \delta \right) + \frac{1}{\delta} L \delta^2 = -\frac{1}{\delta} L \delta^2 + \frac{1}{\delta} L \delta^2 = 0.$$



بنابراین داریم: $S_{q^*}(q_t + \delta u) < 0$

بیش (ج) توجه: ضرب داخلی شباهت دو بردار را می‌سنجید. اگر مثبت باشد بردارها aligned و در یک جهت هستند. اگر منفی باشد بردارها anti aligned و در خلاف هم هستند و اگر صفر باشد بردارها به هم عمود هستند.

$$\nabla S(q_t)^T u = \|\nabla S(q_t)\|_2 \|u\|_2 \cos(\theta) = \|\nabla S(q_t)\|_2 \cos(\theta) \quad \theta \text{ زاویه بین دو بردار است.}$$

$$\nabla S(q_t)^T u > 0 \rightarrow \cos(\theta) > 0 \rightarrow 0 < \theta < 90^\circ \rightarrow u \text{ و } S(q_t) \text{ هم جهت اند}$$

$$\nabla S(q_t)^T u < 0 \rightarrow \cos(\theta) < 0 \rightarrow 90^\circ < \theta < 180^\circ \rightarrow u, S(q_t) \text{ خلاف هم اند}$$

$$\nabla S(q_t)^T u = 0 \rightarrow \cos(\theta) = 0 \rightarrow \theta = 90^\circ \rightarrow u \text{ و } S(q_t) \text{ بر هم عمودند.}$$

حال به بررسی هر ردیه ای پردازیم:

$$E_1 = \{ \nabla S(q_t)^T u > w \} \leftarrow \text{جهت تصادفی } u \text{ به شرت با گرایان همسو است چرا که}$$

ضرب داخلی از آستانه w بیشتر است. این بدان معناست که حرکت در جهت u باعث افزایش S_{q^*}

می‌شود که برای خاصیت تقاضی مطلوب است. همچنین $S > 0$ و در نتیجه این u منجر به $\Phi(q_t + \delta u) = +1$ می‌شود. در واقع u در تخمین گرایان به شکل مثبت مشارکت می‌کند.

$$E_2 = \{ -w < \nabla S(q_t)^T u < w \} \leftarrow \text{جهت تصادفی } u \text{ تقریباً متعامد بر گرایان است چون}$$

ضرب داخلی نزدیک صفر است. $(\nabla S(q_t)^T u < w)$ همچنین علامت $S_{q^*}(q_t + \delta u)$ به دلیل اثرات

مرتبه دوم نامشخص است و ابهام دارد. این جهت u اطلاعات کمی در مورد جهت گرایان ارائه می‌دهد و چون عبارت

مرتبه دوم ممکن است غالب باشد این علامت غیر قابل اعتماد است و به نوعی نویز ~~noise~~ است.

noise

$$E_3 = \{ \nabla S(q_t)^T u < -w \} \leftarrow \text{جهت تصادفی } u \text{ به شرت با گرایان همسو نیست چون ضرب داخلی از}$$

آستانه $-w$ کوچکتر است و بردارها خلاف جهت هم هستند. حرکت در جهت u باعث کاهش S_{q^*} می‌شود که برای

خاصیت تقاضی نامطلوب است. همچنین $S < 0$ و در نتیجه این جهت تصادفی u منجر به $\Phi(q_t + \delta u) = -1$ می‌شود. در واقع u در تخمین گرایان به شکل منفی مشارکت می‌کند.



بخش د) فرض کنیم $\{v_i\}_{i=1}^d$ یک پایه متعامد با $v_1 = \frac{\nabla S(\eta_t)}{\|\nabla S(\eta_t)\|_p}$ باشد. هر بردار تصادفی u که از یک توزیع یکنواخت (uniform) بر روی کره واحد می‌آید می‌تواند به شکل $u = \sum_{i=1}^d \beta_i v_i$ نوشته شود که $\sum_{i=1}^d \beta_i^2 = 1$ و $\beta_i = \langle v_i, u \rangle$ چون $\{v_i\}_{i=1}^d$ یک پایه متعامد (orthogonal basis) است. همین داریم:

$$v_1 = \frac{\nabla S(\eta_t)}{\|\nabla S(\eta_t)\|_p} \rightarrow \boxed{\nabla S(\eta_t) = v_1 \cdot \|\nabla S(\eta_t)\|_p}$$

پس داریم:

$$\nabla S(\eta_t)^T u = (\underbrace{\|\nabla S(\eta_t)\|_p}_{\text{scalar}} \cdot v_1)^T u = \|\nabla S(\eta_t)\|_p \cdot v_1^T u = \|\nabla S(\eta_t)\|_p \beta_1$$

چون $\{v_i\}_{i=1}^d$ یک پایه متعامد است.

$$i \neq j \rightarrow v_i \perp v_j \rightarrow \langle v_i, v_j \rangle = 0$$

$$\rightarrow \boxed{\nabla S(\eta_t)^T u = \|\nabla S(\eta_t)\|_p \beta_1}$$

حال برای E_1 داریم:

$$E_1: \nabla S(\eta_t)^T u > w \Rightarrow \|\nabla S(\eta_t)\|_p \beta_1 > w \Rightarrow \beta_1 > \frac{w}{\|\nabla S(\eta_t)\|_p} > 0$$

چون صورت و مخرج اعداد نامنفی هستند.

$$\boxed{\beta_1 > 0 \text{ with } \text{sign}(S(\eta_t + \delta u)) = +1}$$

برای E_3 داریم:

$$E_3: \nabla S(\eta_t)^T u < -w \Rightarrow \|\nabla S(\eta_t)\|_p \beta_1 < -w \Rightarrow \beta_1 < \frac{-w}{\|\nabla S(\eta_t)\|_p} < 0$$

چون $w \geq 0$ و $\|\cdot\|_p \geq 0$ و فرض می‌کنیم δu صفر مطلق نیست.

$$\boxed{\beta_1 < 0 \text{ with } \text{sign}(S(\eta_t + \delta u)) = -1}$$

حال با توجه به تقارن توزیع یکنواخت (symmetry of uniform distribution) روی کره، توزیع β_1 در حدود صفر متقارن است.

$$E[E[\beta_1 | E_1]] \text{ امید ریاضی شرطی } \beta_1 \text{ با فرض } \beta_1 > \frac{w}{\|\nabla S(\eta_t)\|_p} \text{ است.}$$

$$E[E[\beta_1 | E_3]] \text{ امید ریاضی شرطی } \beta_1 \text{ با فرض } \beta_1 < \frac{-w}{\|\nabla S(\eta_t)\|_p} \text{ است.}$$

بنابراین طبق symmetry یا همان تقارن توزیع یکنواخت روی کره داریم:

$$\boxed{E[\beta_1 | E_1] = -E[\beta_1 | E_3] > 0}$$



۲. برای $i \geq 2$ بردار v_i عمود بر بردار v_1 یعنی $v_i \perp v_1$ for $i \geq 2$, در واقع $0 = \langle v_1, v_i \rangle$ for $i \geq 2$.

رویدادهای E_1 و E_3 فقط با شرط روی B_1 (مؤلفه در امتداد v_1) تعریف می‌شوند چرا که v_1 بردار پایه در جهت $\nabla S(x_t)$ است و بقیه بردارهای v_i طبق تعریف پایه متعامند $\{v_i\}_{i=2}^d$ بر v_1 عمودند. ($v_i \perp v_1$ for $i \geq 2$). از آنجایی که توزیع یکنواخت روی کره از نظر چرخشی ثابت است (rotationally invariant)، بشرط گذاشتن روی B_1 بر توزیع مؤلفه‌های B_i برای $i \geq 2$ تأثیری ندارد که منجر به این می‌شود که در هر دو صفر متقارن باقی می‌مانند. توجه کنید که رویدادهای E_1 و E_3 فقط روی B_1 شرطی‌گذارند چرا که فقط v_1 در جهت گرادیان است. Conditioning event depends only on B_1 . در واقع توزیع ناشی از B_i اطراف صفر متقارن است و مستقل از تغییرات علامت در B_1 است. پس طبق تقارن، میانگین شرطی B_i برای هر رویداد متقارن با علامت B_1 برابر یا صفری شود. بنابراین:

$$\mathbb{E}[B_i | E_1] = \mathbb{E}[B_i | E_3] = 0 \text{ for all } i \geq 2$$

خلاصه: از آنجا که توزیع joint به شکل rotationally invariant است و رویدادهای E_1 و E_3 فقط B_1 بستگی دارند توزیع شرطی هر B_i که $i \geq 2$ حول صفر متقارن است و بنابراین میانگین شرطی صفر است. بخش هـ) با استفاده از قانون امید کل داریم:

$$\mathbb{E}[\phi_{x^*}(x + \delta u)] = P[E_1] \mathbb{E}[\phi_{x^*}(x + \delta u) | E_1] + P[E_2] \mathbb{E}[\phi_{x^*}(x + \delta u) | E_2] + P[E_3] \mathbb{E}[\phi_{x^*}(x + \delta u) | E_3]$$

توجه کنید: در رویداد E_1 : $\phi_{x^*}(x + \delta u) = +1$ $\Rightarrow S_{x^*}(x_t + \delta u) > 0$

در رویداد E_3 : $\phi_{x^*}(x + \delta u) = -1$ $\Rightarrow S_{x^*}(x_t + \delta u) < 0$

در رویداد E_2 علامت ϕ مبهم است و مشخص نیست.

فرض کنید $P[E_2] = p$ پس:

$$\mathbb{E}[\phi_{x^*}(x + \delta u)] = P[E_1] \times 1 + p \cdot \mathbb{E}[\phi_{x^*}(x + \delta u) | E_2] + P[E_3] \times (-1)$$

$$\mathbb{E}[\phi_{x^*}(x + \delta u)] = p \cdot \underbrace{\mathbb{E}[\phi_{x^*}(x + \delta u)]}_A + \underbrace{(P[E_1] - P[E_3])}_B = pA + B$$

$$A = \mathbb{E}[\phi_{x^*}(x + \delta u)], \quad B = P[E_1] - P[E_3]$$



$$\left. \begin{aligned} P[E_1] + P[E_2] + P[E_3] &= 1 \\ P[E_1] &= P[E_3] \\ P[E_2] &= p \end{aligned} \right\} \Rightarrow P[E_1] = P[E_3] = \frac{1-p}{2} \Rightarrow P[E_1] - P[E_3] = 0$$

همچنین توجه کنید که طبق تقارن (symmetry) داریم که

$$PA + B = E[\phi_{\eta^*}(x + \delta u)] = p \cdot E[\phi_{\eta^*}(x + \delta u) | E_2] \leftarrow \boxed{B=0}$$

$$E[\phi_{\eta^*}(x + \delta u) | E_2] = 0$$

حال سعی می کنیم با نتایج بعضی (د) آن را ساده تر کنیم.
امید ریاضی کامل جمله تعمیم تری شود:

$$E[\phi_{\eta^*}(x + \delta u) u] = P[E_1] E[u | E_1] + p E[\phi_{\eta^*}(x + \delta u) u | E_2] + P[E_3] E[u | E_3]$$

طبق $E[B_1 | E_1] v_1$

طبق $E[B_1 | E_3] v_1$

$$E[\phi_{\eta^*}(x + \delta u) u] = \frac{(1-p)}{2} (E[B_1 | E_1] + E[B_1 | E_3]) \quad E[B_1 | E_3] = E[B_1 | E_1]$$

$$E[\phi_{\eta^*}(x + \delta u) u] = (P[E_1] - P[E_3]) E[B_1 | E_1] v_1 + p E[\phi_{\eta^*}(x + \delta u) u | E_2]$$

می توان با تقارن این عبارت را ساده کرد.

$$\|a - b\|_p^2 = \|a\|_p^2 + \|b\|_p^2 - 2a^T b \quad \text{بخش و) اد ابتدا } \|a - b\|^2 \text{ را بسط می دهیم:}$$

$$2a^T b = \|a\|_p^2 + \|b\|_p^2 - \|a - b\|_p^2 \rightarrow a^T b = \frac{1}{2} (\|a\|_p^2 + \|b\|_p^2 - \|a - b\|_p^2) \geq \|a\|_p \|b\|_p$$

حال با استفاده از نامساوی AM-GM (Arithmetic Mean-Geometric mean) داریم:

$$a^T b = \frac{1}{2} (\|a\|_p^2 + \|b\|_p^2 - \|a - b\|_p^2) \geq \frac{1}{2} (2\|a\|_p \|b\|_p - \|a - b\|_p^2) \quad \boxed{\|a\|_p^2 + \|b\|_p^2 \geq 2\|a\|_p \|b\|_p}$$

اثبات با $\|a - b\|_p^2 \geq 0$

$$\rightarrow \boxed{a^T b \geq \|a\|_p \|b\|_p - \frac{1}{2} \|a - b\|_p^2}$$

$$\cos \angle(a, b) = \frac{a^T b}{\|a\|_p \|b\|_p} \geq \frac{\|a\|_p \|b\|_p - \frac{1}{2} \|a - b\|_p^2}{\|a\|_p \|b\|_p} = \frac{\|a\|_p \|b\|_p}{\|a\|_p \|b\|_p} - \frac{\frac{1}{2} \|a - b\|_p^2}{\|a\|_p \|b\|_p} = 1 - \frac{\|a - b\|_p^2}{2\|a\|_p \|b\|_p}$$

حال طبق فرض سوال a و b در فضای مشخص هستند بنابراین فرض می کنیم که $\|a\|_p \approx \|b\|_p$ (یا به طور دقیق تر اگر $a = E[\phi u]$ و $b = E[B_1 | v_1]$ که هر دو norm های مشابهی دارند) آنگاه:

$$\cos \angle(a, b) \geq 1 - \frac{\|a - b\|_p^2}{2\|a\|_p \|b\|_p} \approx 1 - \frac{\|a - b\|_p^2}{2\|b\|_p^2} \Rightarrow \boxed{\cos \angle(a, b) \geq 1 - \frac{\|a - b\|_p^2}{2\|b\|_p^2}}$$



۲. فرض کنید:

$$V_1 = \frac{\nabla S(x_t)}{\|\nabla S(x_t)\|_2}$$

طبق تعریف

$$b = \mathbb{E}[B_1 | V_1] = \mathbb{E}[B_1] \frac{\nabla S(x_t)}{\|\nabla S(x_t)\|_2} \quad , \quad a = \mathbb{E}[\Phi_{x^*}(x_t + \delta u) u]$$

positive scalar

$$\|\cdot\|_2 \rightarrow \|b\|_2 = \mathbb{E}[|B_1|] \frac{\|\nabla S(x_t)\|_2}{\|\nabla S(x_t)\|_2} = \mathbb{E}[|B_1|]$$

expectation

$$\hat{\nabla} S(x_t, \delta) = \frac{1}{B} \sum_{b=1}^B \Phi_{x^*}(x_t + \delta u_b) u_b$$

$$\mathbb{E}[\hat{\nabla} S(x_t, \delta)] = \mathbb{E}[\Phi_{x^*}(x_t + \delta u) u] = a$$

$$\|a - b\|_2^2 \leq 9\rho^2$$

$$- \|a - b\|_2^2 \geq -9\rho^2$$

توان ۲

باتوجه به رابطه (۲۶) داریم: $\|a - b\|_2 \leq 3\rho$

حال از رابطه (۲۵) استفاده می‌کنیم:

$$\cos \angle(\mathbb{E}[\hat{\nabla} S(x_t, \delta)], \nabla S(x_t)) = \cos \angle(a, \nabla S(x_t))$$

حال توجه کنید که تابع $\cos$ میان دو بردار scale invariant است چرا که فقط به زاویه میان آنها بستگی دارد پس:

$$\cos \angle(a, \nabla S(x_t)) = \cos \angle(a, \nabla S(x_t) \times \frac{\mathbb{E}[|B_1|]}{\|\nabla S(x_t)\|_2}) = \cos \angle(a, b)$$

$$\cos \angle(a, b) \geq 1 - \frac{\|a - b\|_2^2}{2\|b\|_2^2} \geq 1 - \frac{9\rho^2}{2\|b\|_2^2} = 1 - \frac{9\rho^2}{2(\mathbb{E}[|B_1|])^2}$$

Scalar ضربات

$$\cos \angle(\mathbb{E}[\hat{\nabla} S(x_t, \delta)], \nabla S(x_t)) \geq 1 - \frac{9\rho^2}{2(\mathbb{E}[|B_1|])^2}$$

بنابراین داریم:

$$\cos \angle(\mathbb{E}[\hat{\nabla} S(x_t, \delta)], \nabla S(x_t)) \geq 1 - \frac{9\rho^2}{2(\mathbb{E}[|B_1|])^2}$$

بخش ز) توجه کنید در مرحله قبل اثبات کردیم که

$$\rho = P(E_2) = P(|\nabla S(x_t)^T u| < w), \quad w = \frac{\mathcal{L}\delta}{\mu}$$

و کافی است بر μ و $\mathbb{E}[|B_1|]$ روابطی پیدا کنیم.

$$B_1^2 = \langle v_1, u \rangle^2 \sim \text{Beta}(\frac{1}{\mu}, \frac{d-1}{\mu})$$

برای بردار تصادفی u روی $\mathbb{R}^d$ کره واحد داریم:

$$\mathbb{E}[|B_1|] = \frac{2}{d-1}$$

باتوجه به راهشایی داده شده در صورت سوال داریم:

$$\mathbb{E}[|B_1|] = \left(\frac{2}{d-1}\right)^2$$

بنابراین

$$\cos \angle(\mathbb{E}[\hat{\nabla} S(x_t, \delta)], \nabla S(x_t)) \geq 1 - \frac{9\rho^2}{2\left(\frac{2}{d-1}\right)^2} = 1 - \frac{9\rho^2(d-1)^2}{8}$$

حال باید گرانی
برای μ پیدا
کنیم.



گران بالای p :

$$p = \mathbb{P}(|\nabla S(\eta_t)^T u| < w), \quad \nabla S(\eta_t)^T u = \|\nabla S(\eta_t)\|_2 \beta_1 \Rightarrow$$

$$p = \mathbb{P}(|\beta_1| < \frac{w}{\|\nabla S(\eta_t)\|_2}) \quad w = \frac{L\delta}{2} \quad p = \mathbb{P}(|\beta_1| < \frac{L\delta}{2\|\nabla S(\eta_t)\|_2})$$

حال چون $|\beta_1|$ دارای توزیع متقارن مشتق شده از توزیع Beta است، یک حد بالایی ساده (concentration bounds) به شکل زیر است

$$p \leq \frac{L\delta}{\|\nabla S(\eta_t)\|_2} \quad (\text{نابت های دقیق بعد از جذب می شوند؛ این ممکن است})$$

حال باید حد بالایی p را در رابطه جایگزین کنیم.

$$p^2 \leq \frac{L^2 \delta^2}{\|\nabla S(\eta_t)\|_2^2}$$

$$\cos \angle(a, b) \geq 1 - \frac{9(d-1)^2}{8} \cdot \frac{L^2 \delta^2}{\|\nabla S(\eta_t)\|_2^2}$$

که دقیقاً همان خواسته مسئله است.

$$\cos \angle(\mathbb{E}[\hat{\nabla} S(\eta_t, \delta)], \nabla S(\eta_t)) \geq 1 - \frac{9L^2 \delta^2 (d-1)^2}{8\|\nabla S(\eta_t)\|_2^2}$$

$$1 \leftarrow 1 - 0 \leftarrow 1 - \frac{9L^2 \delta^2 (d-1)^2}{8\|\nabla S(\eta_t)\|_2^2} \quad 2. \text{ بیاید دوباره به طرف راست نامساوی دقت کنیم:}$$

وقتی $\delta \rightarrow 0$: عبارت خطای تخمین بر حسب δ درجه دو است. بنابراین خیلی به صفر میل می کند پس:

$$\lim_{\delta \rightarrow 0} \cos \angle(\mathbb{E}[\hat{\nabla} S(\eta_t, \delta)], \nabla S(\eta_t)) = 1$$

وقتی $\cos \theta = 1$ یعنی زاویه بین $\mathbb{E}[\hat{\nabla} S]$ و ∇S به صفر میل می کند و در بردار هم سو و هم جهت می شوند. $\theta \rightarrow 0 \leftarrow \mathbb{E}[\hat{\nabla} S(\eta_t, \delta)] \rightarrow \nabla S(\eta_t)$

تفسیر: وقتی $\delta \rightarrow 0$ لذا $\theta \rightarrow 0$ می کند. یعنی تخمین گر گرایان جعبه سیاه مورد انتظار کاملاً با

گرایان واقعی هم سو و هم جهت می شود. با اینکه ما در آنجا احتمالات یا گرایان را مشاهده می کنیم و فقط بر حسب های پیش بینی شده را مشاهده می کنیم، تخمین گر جهت صحیح گرایان را باز یابی می کند.

که کوچکتر $\leftarrow$ ابهام کمتر در جهت ها $\leftarrow$ همسویی بهتر

این موضوع توجه می کند که چرا حالات جعبه سیاه فقط با بر حسب بهترین می توانند همگرا شوند.

مشاهده می شود: با کوچک شدن δ ، p های گروه تصادفی almost exactly در امتداد گرایان واقعی از مرز تصمیم گیری عبور می کنند. بنابراین میانگین جهت های δ ها به گرایان واقعی همگرا می شود. پس با کوچک کردن δ به اندازه کافی حالات almost exact عملگر خردی فواید داشت.