

۷	۴	۱
جمع نمرات	۵	۲
	۶	۳



شماره دانشجویی:	
نام و نام خانوادگی:	
شماره صندلی:	
نام استاد:	

صفحه ۱ از ۴

شماره سوال: ۱ : سوال ۱ : اضافه کردن نوز لاپلاس با مقیاس $\frac{1}{\epsilon}$ و ویژگی ϵ -DP یا همان $O(\epsilon)$ محرمانه قضاصلی را دارد. ولی اضافه کردن نوز یکنواخت از بازه $[\frac{3}{\epsilon}, \frac{3}{\epsilon}]$ و ویژگی ϵ -DP را ندارد و $O(\epsilon)$ -محرمانه قضاصلی نیست. جواب: خیر در ادامه توضیح می دهیم علت را

چرا نوز لاپلاس ϵ -DP است؟ در اسلاید ۱۱ از Lec ۱۹ این اثبات آمده است در اینجا به اختصار آن را بیان می کنیم.

دو دیتاست همسایه که در یک record متفاوت هستند در count شان حداکثر ۱ واحد متفاوت هستند. فرض کنید S و S' در مجموع ممکن به جاب پرسش باشند که از دیتاست های همسایه هستند پس $|S - S'| \leq 1$ چگالی توزیع لاپلاس در نقطه y برابر است با

$$Lap_b(y) = \frac{1}{2b} \exp\left(-\frac{|y|}{b}\right)$$

فرض کنید $b = \frac{1}{\epsilon}$ پس چگالی ضرر جی و متی مجموع واقعی S هست برابر است با $\frac{\epsilon}{2} e^{-\epsilon|y-S|}$ پس برای همسایه های S و S' با فرض $|S - S'| \leq 1$ داریم:

$$\frac{P_{S'}(y)}{P_S(y)} = \exp(\epsilon(|y-S| - |y-S'|))$$

برای $y \in \mathbb{R}$ و اعداد a و b با شرط $|a-b| \leq 1$ (در اینجا $a=S$ و $b=S'$) نامساوی مثلث بیان می کند که $|y-a| - |y-b| \leq |a-b| \leq 1 \iff |y-S| - |y-S'| \leq |S-S'| \leq 1$

$$\frac{P_{S'}(y)}{P_S(y)} \leq \exp(\epsilon(|y-S| - |y-S'|)) \leq \exp(\epsilon \times 1) = \exp(\epsilon)$$

به طور مشابه نسبت معکوس هم این ویژگی را دارد یعنی $\frac{P_S(y)}{P_{S'}(y)} \leq e^\epsilon$ بنابراین برای هر مجموعه قابل اندازه گیری S داریم: $\frac{P_{S'}(y)}{P_S(y)} \leq e^\epsilon$

$$Pr[\tilde{f}(x) \in S | S'] \leq e^\epsilon Pr[\tilde{f}(x) \in S | S] \quad \text{هر مجموعه قابل اندازه گیری measurable}$$

بنابراین مکانیزم لاپلاس با پارامتر $\frac{1}{\epsilon}$ دارای ϵ -DP است.

①

* غیر ممکن است چرا که support های آن ها shift می خورد. بنابراین برای این فرضی ها نسبت احتمال نامحدود و ∞ می شود. بنابراین نمی توان ϵ -DP خالص داشت و توزیع $O(\epsilon)$ محرمانه تفاضلی نیست. شماره سوال: ۲




چرا توزیع یکنواخت در بازه $[-\frac{3}{\epsilon}, \frac{3}{\epsilon}]$ ϵ -DP نیست و $O(\epsilon)$ محرمانه تفاضلی نیست؟ با مثال نقض اثبات می کنیم.

فرض کنید $Z \sim \text{Uniform}[-\frac{3}{\epsilon}, \frac{3}{\epsilon}]$ برای یک مجموع واقعی S چگالی احتمال خروجی می شود:

$$u_S(y) = \begin{cases} \frac{\epsilon}{6} & y \in [S - \frac{3}{\epsilon}, S + \frac{3}{\epsilon}] \\ 0 & \text{otherwise} \end{cases}$$

در مجموع همسایه S و $S+1$ را در نظر بگیرید. (مثلاً در یک dataset داریم $X_i \geq 0$ و در دیگری $X_i \geq 1$)

support های آنها بازه های زیر هستند: $I_S = [S - \frac{3}{\epsilon}, S + \frac{3}{\epsilon}]$ و $I_{S+1} = [S+1 - \frac{3}{\epsilon}, S+1 + \frac{3}{\epsilon}]$ توجه کنید این دو بازه نسبت به هم یک واحد شیفیت شده اند.



اجتماع این دو support دارای طول $\frac{6}{\epsilon} + 1$ است. $y_0 \in I_{S+1}$ و $y_0 \notin I_S$

$$|I_S \cup I_{S+1}| = |I_S| + |I_{S+1}| - |I_S \cap I_{S+1}| = \frac{6}{\epsilon} + \frac{6}{\epsilon} - (\frac{6}{\epsilon} - 1) = \frac{6}{\epsilon} + 1$$

بنابراین همیشه یک ناحیه وجود دارد که نقاط در آن ناحیه در یک support وجود دارند و در دیگری وجود ندارند.

به طور محسوس برای مثال ما مقدار زیر را انتخاب می کنیم: $y_0 = S+1 + \frac{3}{\epsilon} - \delta$, $\delta \in (0, 1)$

برای یک $0 < \delta < 1$ داریم: $y_0 \in I_{S+1}$ ولی $y_0 \notin I_S$ بنابراین:

$$u_{S+1}(y_0) = \frac{\epsilon}{6} > 0, \quad u_S(y_0) = 0$$

پس نسبت likelihood برابر است با

$$\frac{u_{S+1}(y_0)}{u_S(y_0)} = \infty$$

که هر bound حاصل از ضرب عددی در $\exp(\epsilon)$ را نقض می کند. بنابراین

یک measurable set (هر همسایگی کوچکی از y_0) وجود دارد که $\Pr[\tilde{f} \in S | S+1] > 0$ ولی $\Pr[\tilde{f} \in S | S] = 0$ یک ϵ -DP خالص نیاز دارد که هر فرضی ممکن y چگالی های شرطی احتمال مثبت باشند و نسبت آنها با $\exp(\epsilon)$ محدود باشد. توزیع لاپلاس دارای full support در $\mathbb{R}$ است (همه جا چگالی مثبت دارد). بنابراین نسبت احتمال محدود است و دارای bound با ضربی از $\exp(\epsilon)$ است. یک توزیع bounded-support مانند توزیع یکنواخت مقادیر فرضی ای دارد که برای یک دیتاست همسایه ممکن است ولی برای دیتاست مجاور آن

(2)

* ادامه بالا، صفحه

* ادامه بالا، صفحه

$$A(X_1, X_2, \dots, X_n) = A(X)$$

$$\tilde{m}(X_1, X_2, \dots, X_n) = \tilde{m}(X)$$

قرارداد

صفحه ۳



شماره سوال:

سوال ۲. ۱. رویکرد برش دهی ساده

اجازه دهید $T = R + C \sqrt{\log(n)}$ با $C > 0$ یک عدد ثابت به اندازه کافی بزرگ. بنابراین تضمین گردش

$$\tilde{m} = \frac{1}{n} \sum_{i=1}^n X_i \cdot 1_{[|X_i| \leq T]}$$

خورده می شود:

پس ℓ_1 -sensitivity $\tilde{m}$ برابر است با $\Delta = \frac{2T}{n}$ چرا که تغییر دادن یک X_i خاص جمع را

حواکشی تواند $2T$ تغییر دهد. (دلیل: هر عبارت دارای کران T برای قدر مطلق خود است. پس $\max$ تفاوت برابر $2T - (-2T) = 4T$ است و در حالت extreme داریم $X_i = T$ و $X_i' = -T$ چون $X_i' \cdot 1_{[|X_i| \leq T]} \leq T$ و $-T \leq X_i \cdot 1_{[|X_i| \leq T]}$)

$$A(X) = \tilde{m} + \text{Lap}\left(\frac{\Delta}{\epsilon}\right) \Rightarrow A(X) = \tilde{m} + \text{Lap}\left(\frac{2T}{n\epsilon}\right)$$

بنابراین خروجی الگوریتم A برابر است با:

که این الگوریتم $DP(\epsilon, 0)$ است بر وسیله مکانیزم لاپلاس.

حال به سراغ تحلیل خطای الگوریتم می رویم: توجه کنید خطای الگوریتم می شود: $|A(X) - \mu|$

$$A(X) - \mu = (\tilde{m} - \mu) + \text{Lap}\left(\frac{2T}{n\epsilon}\right)$$

الگوریتم را به دو بخش می نویسیم

حال $|\tilde{m} - \mu|$ را با احتمال بالا bound می کنیم. فرض کنید متغیر تصادفی Y_i می شود: $Y_i = X_i \cdot 1_{[|X_i| \leq T]}$ پس:

$$\tilde{m} - \mu = \frac{1}{n} \sum_{i=1}^n (Y_i - \mu) = \frac{1}{n} \sum_{i=1}^n (X_i - \mu) 1_{[|X_i| \leq T]} - \frac{\mu}{n} \sum_{i=1}^n 1_{[|X_i| > T]}$$

عبارت اول عبارت دوم

حال چون $X_i \sim N(\mu, 1)$ و $\mu \in [-R, R]$ داریم:

$$\Pr[|X_i| > T] \leq \Pr[|X_i - \mu| > C \sqrt{\log(n)}] \leq 2 \exp\left(-\frac{C^2 \log(n)}{2}\right) = 2n^{-\frac{C^2}{2}}$$

$$1 - e^{-\Omega(n)} \quad \text{حال با استفاده از یک Chernoff bound با احتمال} \quad 2n^{-\frac{C^2}{2}} - \frac{C^2 \log(e)}{2} \approx 2n^{-\frac{C^2}{2}}$$

تعداد نقاط برش داده شده حداکثر $O(n^{1-\frac{C^2}{2}})$ است.

بنابراین عبارت دوم برای یک C به اندازه کافی بزرگ $O(n^{-\frac{C^2}{2}}) = O(\sqrt{\frac{1}{n}})$ همچنین برای عبارت اول

توجه کنید که $(X_i - \mu) 1_{[|X_i| \leq T]}$ با $O(T)$ کران دار است و همچنین $\text{Variance} \leq 1$ چون $X_i \sim N(\mu, 1)$

پس بر وسیله Bernstein's inequality با احتمال 0.995 داریم: $\left| \frac{1}{n} \sum_{i=1}^n (X_i - \mu) 1_{[|X_i| \leq T]} \right| \leq \sqrt{\frac{1}{n}}$

حال چون برای هر دو عبارت اول و عبارت دوم $O(\sqrt{\frac{1}{n}})$ را نشان داریم پس:

$$|\tilde{m} - \mu| \leq \sqrt{\frac{1}{n}} \text{ with probability } \geq 0.99$$

(3)



عبارت نویز لاپلاس $(Lap(\frac{\sqrt{T}}{n\epsilon}))$ با احتمال $1-\delta$ برابر $O(\frac{\sqrt{T} \log(\frac{1}{\delta})}{n\epsilon})$ است.

مثلاً $\delta = 0.01$ می گیریم. بنابراین با احتمال حداقل 0.97 (probability ≥ 0.97) خواهیم داشت $Probability \geq 0.99$

$$|A(x_1, \dots, x_n) - \mu| \leq \sqrt{\frac{T}{n}} + \frac{T}{n\epsilon} \xrightarrow{T=R+C\sqrt{\log(n)}} |A(x) - \mu| \leq \sqrt{\frac{T}{n}} + \frac{R+C\sqrt{\log(n)}}{n\epsilon}$$

حکم ثابت شد.

۲. روش هیستوگرام: بازه $[R, R]$ را به بازه های به طول واحد I افزایش می دهیم که n عدد صحیح است. فرض کنید f_I

تعداد نمونه های موجود در سطل I باشد. همچنین فرض کنید n^* از اندیسی است که f_I را بیشینه می کند.

ابتدا سطل (بازه) ای که شامل مکان μ است را ثابت می کنیم. فرض کنید n عدد صحیحی است که مربوط به بازه ای

است که شامل μ است. احتمال اینکه یک نمونه از توزیع گاوسی $(x_i \sim N(\mu, 1))$ در یک بازه با طول واحد که μ در مرکز آن باشد برابر است با:

$$p_0 = \Pr[|x_i - \mu| \leq \frac{1}{2}] = \Phi(\frac{1}{2}) - \Phi(-\frac{1}{2}) \approx 0.3829$$

بنابراین تعداد مورد انتظار expected در این سطل (بازه به طول واحد) برابر است با $p_0 n = 0.3829n$

حال برسیله یک Chernoff bound با احتمال $1 - \exp(-\Omega(n))$ داریم:

$$f_{I_0} \geq p_0 n - O(n) \geq 0.3 \quad n \geq 0.1n \Rightarrow f_I(x_1, \dots, x_n) \geq 0.1n$$

حال هر سطل I را که فاصله مرکز آن از μ بیشتر از 5 است را در نظر بگیریم. $(|x - \mu| > 5)$ بنابراین برای هر نقطه

در این بازه (سطل) داریم $|x - \mu| \geq 4.5$ (چرا که بازه های به طول واحد و فرض کردیم μ در وسط بازه است). پس احتمال اینکه

یک نمونه در این بازه بیفتد حداکثر p_{far} برابر است با:

$$p_{far} \leq \Pr[|x - \mu| \geq 4.5] \leq \exp(-\frac{4.5^2}{2}) = \exp(-10.125) \approx 4 \times 10^{-5} \Rightarrow p_{far} < 0.02$$

بنابراین تعداد مورد انتظار (expected count) در یک سطل (بازه) دور ناچیز است و برابر $n < 0.02n$ است و

با استفاده از Chernoff bound با احتمال $1 - \exp(-\Omega(n))$ تعداد واقعی موجود در سطل های دور تر ناچیز و $< 0.02n$ است.

بنابراین سطل با دارای بیشترین تعداد n^* (max count bin) باید در فاصله حداکثر 5 از میانگین قرار گیرد و

یعنی $|x^* - \mu| \leq 5$ با احتمال زیاد $1 - \exp(-\Omega(n))$ و بنابراین bound های گفته شده در سوال ثابت می شوند.

اگر از یک الگوریتم هیستوگرام محرمانه بجای مقدارها واقعی (true counts) استفاده کنیم فاصله زیاد (large margin) موجود یعنی $f_{I_0} - \max_{I \neq I_0} f_I > 5$ $f_{I_0} \geq 0.3n$ 4

★ ادامه بالی صفحه

$$|A(x) - \mu| \lesssim \sqrt{\frac{1}{n}} + \frac{R + \sqrt{\log(n)}}{n\epsilon} \xrightarrow[n \gtrsim \frac{\log(R)}{\epsilon}]{\text{روش هیستوگرام}} |A(x) - \mu| \lesssim \sqrt{\frac{1}{n}} + \frac{O(1) + \sqrt{\log(n)}}{n\epsilon}$$

۷	۴	۱
جمع نمرات	۵	۲
	۶	۳



شماره دانشجویی:	
نام و نام خانوادگی:	
شماره صندلی:	نام استاد:

صفحه ۱ از ۴

شماره سوال: ۳. ترکیب تطبیقی و کران های بهبود یافته

وجود الگوریتم را با معرفی آن نشان می دهیم. الگوریتم کا را مد $DP - (0, \epsilon)$ به شکل زیر است:
الگوریتم A شامل ۲ مرحله است:

۱. از یک الگوریتم هیستوگرام (محرمانه) روی بازه (سطح) های I به طول واحد استفاده می کنیم تا یک z^* که

بازه با بیشترین تعداد (محرمانه) را پیدا کنیم. طبق قسمت (۲) همین سوال با احتمال زیاد z^* شرط $|z - \mu| \leq 5$ را برآورده می کند.
چون می خواهیم ۵ تا بازه قبل و بعد را شامل شود ۶ در نظر می گیریم

۲. حال توجه را به بازه $I = [z^* - 6, z^* + 6]$ دارای شعاع ثابت (مثلاً در اینجا شعاع = 6) محدود می کنیم.

هر x_i را برش می دهیم تا در این بازه کوچک به شعاع ثابت قرار گیرد. (به علاوه عبارت $C\sqrt{\log(n)}$)

سپس الگوریتم برش دهی ساده برای تخصیص میانگین توزیع گاوسی + مکایفزم لاپلاس در قسمت (۱) همین سوال ولی با کران $\mu \in [z^* - 6, z^* + 6]$ اجرای کنیم درواقع با $T' = O(1) + C\sqrt{\log(n)}$ به جای استفاده از $T = R + C\sqrt{\log(n)}$ الگوریتم را اجرای کنیم.
چون شعاع ثابت است مثلاً در اینجا عدد ثابت

تحلیل خطای الگوریتم: با احتمال حداقل $1 - \exp(-\Omega(n))$ (هیستوگرام) یک سطح (بازه) با حداکثر فاصله ۵ از μ را مشخص می کند. وقتی که شعاع ثابت این بازه کوچک دانسته شود مثلاً ۵ در اینجا آنگاه bound برش T' برابر است با $O(1) + C\sqrt{\log(n)}$ که مستقل از R است. سپس با استفاده از پارامتر

sensitivity/noise دقیقاً مشابه قسمت (۱) همین سوال پارامتر مقیاس مکایفزم لاپلاس می شود $\frac{\sqrt{T'}}{n\epsilon} = O\left(\frac{1 + \sqrt{\log(n)}}{n\epsilon}\right)$ و خطای نمونه برداری همان $O\left(\sqrt{\frac{1}{n}}\right)$ باقی می ماند. اگر n به اندازه

کافی بزرگ باشد $\frac{1 + \sqrt{\log(n)}}{n\epsilon}$ خیلی کوچک تر از ۵ ($\ll 5$) می شوند و خروجی حداکثر فاصله ۵ از μ با احتمال بالای ادعا شده خواهد بود. به طور مشخص، اگر $n \gtrsim \frac{\log(R)}{\epsilon}$

(پس مرحله ۱ یا همان مرحله هیستوگرام به طور ~~محرمانه~~ موفق خواهد بود و ~~count gap~~ بر نویز محرمانه

غلبه می کند) می توانیم ضمانت کنیم با احتمال حداقل $0.99 - \exp(-\Omega(n))$ داریم $|A(x_1, \dots, x_n) - \mu| \leq 5$

چرا این نتیجه ~~یک~~ نشان دهنده یک بهبود نهایی در روابطی به R است؟ در قسمت (۱) این سوال عبارت نویز جمع شونده یک فاکتور وابسته R داشت ($T \approx R$) که منجر به عبارت خطای $\propto \frac{R}{n\epsilon}$ می شد. این عبارت رابطه خطی با R دارد. در روش تطبیقی ما ابتدا μ را ocalize می کنیم در یک شعاع ثابت با روش هیستوگرام

(۵) بالای صفحه را هم ببینید.



بنابراین وابستگی به R از عبارت $sensitivity/noise$ حذف می شود و الگوریتم فقط وابسته به $Constant$ ها و n که ϵ می شود. همچنین مرحله (۱) یا همان هیستوگرام فقط به اندازه $\frac{1}{\epsilon} R$ نمونه نیاز دارد تا بازه (سطح) نزدیک M و محدوده را پیدا کند. بنابراین وابستگی به R ~~حذف~~ تبدیل به فقط وابستگی به R و ϵ می شود. که به معنای بهبود زیادی در ~~مقیاسه~~ مقایسه با وابستگی خطی R است.

(R و ϵ) سوال ۳ الف) چون قضیه اگر و تنها اگر است باید در جهت آن را ثابت کنیم.

جهت ۱: $\Rightarrow$ Heckey-stick bound (ϵ, δ) -DP

فرض کنید M یک مکانیزم (ϵ, δ) -DP است. پس برای تمامی measurable set های نظیر S داریم:

$$Pr[M(X') \in S] \leq e^{\epsilon} \cdot Pr[M(X) \in S] + \delta$$

حال مجموعه S^* را به این شکل تعریف می کنیم:

$$S^* = \{y : f_{X'}(y) > e^{\epsilon} f_X(y)\}$$

این مجموعه ای است که X' احتمال خیلی زیادی نسبت به X دارد. برای این مجموعه ~~همانند~~ S^* مجموعه ها داریم:

$$Pr[M(X') \in S^*] \leq e^{\epsilon} Pr[M(X) \in S^*] + \delta$$

$$\int_{S^*} f_{X'}(y) dy \leq e^{\epsilon} \int_{S^*} f_X(y) dy + \delta \Rightarrow \int_{S^*} [f_{X'}(y) - e^{\epsilon} f_X(y)] dy \leq \delta$$

همچنین توجه کنید که $H_{\epsilon}(M(X') \| M(X)) = \int [f_{X'}(y) - e^{\epsilon} f_X(y)]_+ dy$

بنابراین فقط تفاوت در $[0, \infty]$ برای اثبات است. توجه کنید که بخش مثبت $[0, \infty]$ یعنی ما فقط باید انتگرال را روی y هایی که $f_{X'}(y) > e^{\epsilon} f_X(y)$ هست بگیریم که دقیقاً همان تعریف S^* است پس داریم:

$$\int_{S^*} [f_{X'}(y) - e^{\epsilon} f_X(y)] dy = \int_{S^*} [f_{X'}(y) - e^{\epsilon} f_X(y)]_+ dy$$

بنابراین حکم ثابت می شود و داریم:

$$H_{\epsilon}(M(X') \| M(X)) = \int_{S^*} [f_{X'}(y) - e^{\epsilon} f_X(y)]_+ dy \leq \delta$$

جهت اول ثابت شد.

توجه کنید که S^* بدترین حالت بر دو برای measurable set ها دیگر که شامل اعضایی با شرط $f_{X'}(y) \leq e^{\epsilon} f_X(y)$ می باشد. روابط بالا برقرار است چرا که وجود چنین y هایی باعث کاهش یافتن $H_{\epsilon}(M(X') \| M(X))$ می شود چرا که در عملگر $[0, \infty]$ صفر می شود و margin میان $H_{\epsilon}(M(X') \| M(X))$ با δ بیشتر خواهد شد.

(6)



حالت دوم را اثبات می‌کنیم: (ϵ, δ) -DP $\Rightarrow$ Hockey-stick bound

فرض کنید برای هر دو مجموعه داده مجاور X و X' داریم:

$$H_{\epsilon}(M(X') \| M(X)) \leq \delta$$

برای هر measurable set S نظیر S داریم:

$$\Pr[M(X') \in S] = \int_S f_{X'}(y) dy$$

حال S را به دو بخش افزازی کنیم:

$$S_1 = S \cap \{y: f_{X'}(y) \leq e^{\epsilon} f_X(y)\}$$

$$S_2 = S \cap \{y: f_{X'}(y) > e^{\epsilon} f_X(y)\}$$

$$\int_{S_1} f_{X'}(y) dy \leq e^{\epsilon} \int_{S_1} f_X(y) dy \quad \text{برای } S_1 \text{ داریم:}$$

$$\int_{S_2} f_{X'}(y) dy = \int_{S_2} [f_{X'}(y) - e^{\epsilon} f_X(y)] dy + e^{\epsilon} \int_{S_2} f_X(y) dy \quad \text{برای } S_2 \text{ داریم:}$$

$$\rightarrow \int_{S_2} f_{X'}(y) dy \leq H_{\epsilon}(M(X') \| M(X)) + e^{\epsilon} \int_{S_2} f_X(y) dy \leq \delta + e^{\epsilon} \int_{S_2} f_X(y) dy$$

از فرض سوال استفاده کردیم

با ترکیب کردن عبارات S_1 و S_2 داریم:

$$\Pr[M(X') \in S] = \int_{S_1} f_{X'}(y) dy + \int_{S_2} f_{X'}(y) dy \leq e^{\epsilon} \int_{S_1} f_X(y) dy + \delta + e^{\epsilon} \int_{S_2} f_X(y) dy$$

$$\Pr[M(X') \in S] \leq e^{\epsilon} \left[\int_{S_1} f_X(y) dy + \int_{S_2} f_X(y) dy \right] + \delta = e^{\epsilon} \Pr[M(X) \in S] + \delta$$

$$\Rightarrow \Pr[M(X') \in S] \leq e^{\epsilon} \Pr[M(X) \in S] + \delta$$

بر وسیله تقارن یا همان symmetry (باجابه جایی X و X') ما همچنین نامساوی برعکس را نتیجه می‌گیریم که اثبات را کامل می‌کند.

ب) فرض کنید X و X' دو مجموعه داده مجاور اند. برای هر measurable set S داریم:

$$\Pr[M(X') \in S] = \int_S f_{X'}(y) dy$$

حالت S را با توجه به $\underbrace{\text{privacy loss}}_{\text{انلاف محرمانه}}$ به دو مجموعه افزازی کنیم:



$$S_{low} = \{y \in S : L_{X' \| X}(y) < \varepsilon\} = \{y \in S : f_{X'}(y) < e^\varepsilon \cdot f_X(y)\}$$

$$S_{high} = \{y \in S : L_{X' \| X}(y) \geq \varepsilon\} = \{y \in S : f_{X'}(y) \geq e^\varepsilon \cdot f_X(y)\}$$

$$S = S_{high} \cup S_{low}$$

برای S_{low} داریم:

$$\int_{S_{low}} f_{X'}(y) dy < \int_{S_{low}} e^\varepsilon \cdot f_X(y) dy = e^\varepsilon \int_{S_{low}} f_X(y) dy \quad (*)$$

برای S_{high} داریم:

$$\int_{S_{high}} f_{X'}(y) dy \leq \int_{\text{all } y: L_{X' \| X}(y) \geq \varepsilon} f_{X'}(y) dy = \Pr[L_{X' \| X}(Y') \geq \varepsilon] \leq \delta \quad (**)$$

که در آن $Y' \sim M(X')$ است. توجه کنید در نامگذاری آخر از فرض سوال استفاده شد.

حال رابطه $(*)$ و $(**)$ را ترکیب می‌کنیم:

$$\Pr[M(X') \in S] = \int_S f_{X'}(y) dy = \int_{S_{low}} f_{X'}(y) dy + \int_{S_{high}} f_{X'}(y) dy \leq e^\varepsilon \int_{S_{low}} f_X(y) dy + \delta$$

$$S_{low} \subseteq S \rightarrow \Pr[M(X') \in S] \leq e^\varepsilon \int_S f_X(y) dy + \delta = e^\varepsilon \cdot \Pr[M(X) \in S] + \delta$$

توجه کنید چون ترتیبی برای اثبات نداشتیم بوسیله تقارن یا symmetry با جواب جایی X و X' نامگذاری برعکس نیست ثابت می‌شود. پس مکانیزم M در تعریف $DP - (\varepsilon, \delta)$ صدق می‌کند.

$$\Pr[M(X') \in S] \leq e^\varepsilon \cdot \Pr[M(X) \in S] + \delta$$

8 ج) خیر. شرط $tail\ bound$ موجود در قسمت (ب) دقیق ($tight$) نیست. در واقع شرط کافی است ولی شرط لازم نیست. یعنی $DP - (\varepsilon, \delta)$ لزوماً ایجاب نمی‌کند که $\Pr[L \geq \varepsilon] \leq \delta$ باشد. در واقع وجود دارن $DP - (\varepsilon, \delta)$ مکانیزم‌هایی که برای آنها $\Pr[L \geq \varepsilon] > \delta$ است.

در بخش (ب) ثابت کردیم که $DP - (\varepsilon, \delta) \Rightarrow tail\ bound\ condition$ ولی برعکس این قضیه ~~در حالت کلی برقرار نیست~~.

چرا این شرط دقیق ($tight$) نیست؟ مشغله سازی و اگرایی‌هاکی - استیک در ~~بخش الف~~ یک مشغله سازی دقیق و $exact$ است:

$$H_{\varepsilon}(M(X') \| M(X)) = \int [f_{X'}(y) - e^\varepsilon f_X(y)]_+ dy \leq \delta$$

ولی $tail\ bound$ دقیق نیست:

$$\Pr[L_{X' \| X}(Y') \geq \varepsilon] = \int_{\{y: f_{X'}(y) \geq e^\varepsilon f_X(y)\}} f_{X'}(y) dy \leq \delta$$

8

۷	۴	۱
جمع نمرات	۵	۲
	۶	۳



شماره دانشجویی:	
نام و نام خانوادگی:	
شماره صندلی:	
نام استاد:	

صفحه ۱ از ۴

شماره سوال:

تفاوت: هائی - استیک excess mass یا جرم اضافه $[f_{X'}(y) - e^\epsilon \cdot f_X(y)]_+$ را اندازه گیری می کند در حالی که tail bound جرم کل $f_{X'}(y)$ (total mass) در ناحیه ای که نسبت چگالی احتمالات بزرگ است اندازه گیری می کند. حال یک مثال نقض سی زینم.

مثال نقض: یک مکانیزم را در نظری بگیریم که در ناحیه $\{y: L_{X' \| X}(y) \geq \epsilon\}$ داریم:

$$f_{X'}(y) = e^\epsilon \cdot f_X(y) + \text{small excess}$$

توجه کنید که tail probability در این مثال می تواند خیلی بزرگ تر از δ باشد ولی واگرایی هائی - استیک همچنان می تواند کوچکتر مساوی δ باشد. $H_{\epsilon}(M(X') \| M(X)) \leq \delta$

بنابراین tail bound یک شرط کافی ولی نه لازم بر (ϵ, δ) -DP است. توجه کنید tail bound یک تکنیک اثبات ضعیف است چرا که محاسبه tail probabilities معمولاً ساده تر از محاسبه واگرایی هائی - استیک است ولی مقداری از tightness را از دست می دهد.

مثال نقض محسوس تر: یک مکانیزم را در نظر بگیرید که با احتمال δ مقداری را خروجی می دهد که کاملاً مجموع داده را آشکار می کند و با احتمال $1 - \delta$ خروجی ای می دهد که ϵ -DP است. مقدار privacy loss روی رویار و بد و نقض کننده محرمانگی تفاضلی ممکن است بزرگ باشد ولی مکانیزم هنوز (ϵ, δ) -DP است چرا که P_{good} رویداد بد با احتمال حداکثر δ رخ می دهد. ولی $\Pr[L \geq \epsilon]$ می تواند به اندازه $\delta + (1 - \delta) \cdot \Pr[L \geq \epsilon \text{ in the good part}]$ بزرگ باشد و ممکن است بزرگ تر از δ شود.

سوال ۴: مکانیزم گاوسی: برای اثبات این قضیه از کتاب The Algorithmic Foundation of Differential Privacy از Cynthia Dwork و Aaron Roth کمک می گیریم. در قسمت A از Appendices این اثبات موجود است. توجه کنید این قضیه را می توان به شکل زیر (همان طور که در اسلایدهای درس و کتاب ذکر شده) آورده است) بیان کرد که در آن از $\ln(\frac{1.25}{\delta})$ به جای $\ln(\frac{1.32}{\delta})$ و ۱ در صورت سوال استفاده شده که تفاوتی ندارد و صورت های مختلف قضیه را با تغییر فرایب و پایه های لگاریتم به هم تبدیل می شوند.

فرض کنید $\epsilon \in (0, 1)$ یک عدد دلخواه باشد. برای $C^2 > 2 \ln(\frac{1.25}{\delta})$ مکانیزم گاوسی با پارامتر $\sigma \geq \frac{C \cdot \Delta_2 f}{\epsilon}$ یک مکانیزم (ϵ, δ) -DP است. حساسیت ℓ_2 آن هم برابر است با:

$$\Delta_2 f = \max_{\text{adjacent } x, y} \|f(x) - f(y)\|_2$$

۹ $f: \mathbb{N}^{|X|} \rightarrow \mathbb{R}^d$

یک دیتابیس D وجود دارد به همراه یک پرسش f از آن و مکانیزم گاوسی $\eta + f(D)$ را خروجی می دهد که در آن نویز η از توزیع نرمال می آید. در واقع داریم نویز $N(0, \sigma^2)$ را اضافه می کنیم. در حال حاضر فرض کنیم

فہم داریم، راجع بہ real-valued صحبت می کنیم. بنابراین $\Delta f = \Delta_1 f = \Delta_2 f$

ما داریم به این مقدار توجه می کنیم:

$$\left| \ln \frac{e^{(\frac{-1}{10-r})x^r}}{e^{(\frac{-1}{10-r})(9+\Delta f)^r}} \right|$$

~~مادر طالب بررسی این احتمال بشرط داشتن دیستاسی D و همچنین دیستاسی D'~~

ما در حال بررسی احتمال خروجی هستیم که با احتمال متفاوتی تحت D نسبت به پایگاه داده مجاور D' رخ می دهد، با توجه به اینکه پایگاه داده را داریم که در آن فضای احتمال الگوریتم تولید نویز است. صورت کسر در نسبت بالا احتمال مشاهده $f(D) + \eta$ را در زمانی که پایگاه داده D است توصیف می کند. مخرج کسر مربوط به احتمال مشاهده همین مقدار در زمانی است که پایگاه داده D' است. این نسبت احتمالات است بنابراین همیشه مثبت است اما الگوریتم نسبت ممکن است منفی باشد. متغیر تصادفی مورد نظرها privacy loss است که عبارت است از

$$B_n = \frac{e^{(-\frac{1}{r_0 r})x^r}}{e^{(-\frac{1}{r_0 r})(n+\Delta f)^r}}$$

و ما به رنباں قدر مطلق آن هستیم :

و ما به دنبال مقدار مطلق آن هستیم:

$$\left| \ln \frac{e^{(\frac{-1}{2\sigma^2})x^2}}{e^{(\frac{-1}{2\sigma^2})(x+\Delta f)^2}} \right| = \left| \ln e^{(\frac{-1}{2\sigma^2})(x^2 - (x+\Delta f)^2)} \right| = \left| -\frac{1}{2\sigma^2} [x^2 - (x^2 + 2x\Delta f + \Delta f^2)] \right|$$

$$= \left| \frac{1}{2\sigma^2} [2x\Delta f + (\Delta f)^2] \right| \quad \text{معادله ①}$$

این نسبت هر زمان که $\frac{\Delta f}{f} - \frac{\sigma^2}{\Delta f} < 9\%$ باشد توسط ϵ محرومی شود. برای اطمینان از محرومی

شدن privacy loss توسط ϵ با احتمال حداقل $1 - \epsilon$ نیاز داریم:

$$\Pr[|x| \geq \frac{\sigma^2 \varepsilon}{\Delta f} - \frac{\Delta f}{\gamma}] < \delta$$

وازان جاکه با اسر و کار داریم را طوری خواهیم یافت که:

$$Pr[x \geq \frac{\sigma^2 \epsilon}{\Delta f} - \frac{\Delta f}{\gamma}] < \frac{\delta}{\gamma}$$

مادر کل فرض می کنیم که $\Delta f \leq 1 \leq \epsilon$ همچنین از tail bound استفاده می کنیم:

$$Pr[X > t] \leq \frac{\sigma}{\sqrt{Y\pi}} e^{-\frac{t^2}{Y\sigma^2}}$$



ما نیاز داریم که

$$\frac{\sigma}{\sqrt{2\pi}} \frac{1}{t} e^{-\frac{t^2}{2\sigma^2}} < \frac{\delta}{\gamma} \Leftrightarrow \sigma \frac{1}{t} e^{-\frac{t^2}{2\sigma^2}} < \frac{\sqrt{2\pi}\delta}{\gamma} \Leftrightarrow \frac{t}{\sigma} e^{\frac{t^2}{2\sigma^2}} > \frac{\gamma}{\sqrt{2\pi}\delta}$$

$$\Leftrightarrow \ln\left(\frac{t}{\sigma}\right) + \frac{t^2}{2\sigma^2} > \ln\left(\frac{\gamma}{\sqrt{2\pi}\delta}\right)$$

با در نظر گرفتن $t = \frac{\sigma^2 \varepsilon}{\Delta f} - \frac{\Delta f}{\gamma}$ خواهیم داشت:

$$\ln\left(\frac{\frac{\sigma^2 \varepsilon}{\Delta f} - \frac{\Delta f}{\gamma}}{\sigma}\right) + \frac{\left(\frac{\sigma^2 \varepsilon}{\Delta f} - \frac{\Delta f}{\gamma}\right)^2}{2\sigma^2} > \ln\left(\frac{\gamma}{\sqrt{2\pi}\delta}\right) = \ln\left(\sqrt{\frac{\gamma}{\pi}} \frac{1}{\delta}\right)$$

ابزاره دید بنویسیم $\sigma = \frac{c\Delta f}{\varepsilon}$ مای خواهیم c را bound کنیم. با یافتن شرایطی که تحت آنجا جمله اول غیر منفی است، شروع می کنیم.

$$\frac{1}{\sigma} \left(\sigma^2 \frac{\varepsilon}{\Delta f} - \frac{\Delta f}{\gamma} \right) = \frac{1}{\sigma} \left[\left(c^2 \frac{\Delta f^2}{\varepsilon^2} \right) \frac{\varepsilon}{\Delta f} - \frac{\Delta f}{\gamma} \right] = \frac{1}{\sigma} \left[c^2 \left(\frac{\Delta f}{\varepsilon} \right) - \frac{\Delta f}{\gamma} \right]$$

$$= \frac{\varepsilon}{c\Delta f} \left[c^2 \left(\frac{\Delta f}{\varepsilon} \right) - \frac{\Delta f}{\gamma} \right] = c - \frac{\varepsilon}{\gamma c}$$

از آنجایی که $\varepsilon \leq 1$ و $c \geq 1$ مستند داریم $c - \frac{\varepsilon}{\gamma c} \geq c - \frac{1}{\gamma}$ بنابراین $\ln\left(\frac{1}{\sigma} \left(\sigma^2 \frac{\varepsilon}{\Delta f} - \frac{\Delta f}{\gamma} \right)\right) > 0$ به شرطی که $c \geq \frac{\gamma}{3}$ باشد. بنابراین می توانیم رری عبارت $\frac{t^2}{2\sigma^2}$ تمرکز کنیم.

$$\left(\frac{1}{\sqrt{2\pi}} \frac{\sigma^2 \varepsilon}{\Delta f} - \frac{\Delta f}{\gamma} \right)^2 = \frac{1}{2\pi} \left[\Delta f \left(\frac{c^2}{\varepsilon} - \frac{1}{\gamma} \right) \right]^2 = \left[(\Delta f)^2 \left(\frac{c^2}{\varepsilon} - \frac{1}{\gamma} \right) \right]^2 \left[\frac{\varepsilon^2}{c^2 (\Delta f)^2} \right] \frac{1}{2}$$

$$= \frac{1}{\gamma} \left(\frac{c^2}{\varepsilon} - \frac{1}{\gamma} \right)^2 \frac{\varepsilon^2}{c^2} = \frac{1}{\gamma} \left(\frac{c^2 - \varepsilon + \varepsilon^2}{\gamma c^2} \right)$$

چون $\varepsilon \leq 1$ است مشتق $\frac{c^2 - \varepsilon + \varepsilon^2}{\gamma c^2}$ نسبت به c در بازه مورد بررسی ما $(c \geq \frac{\gamma}{3})$ مثبت است، پس

$$c^2 - \frac{\Delta}{9} > \gamma \ln\left(\sqrt{\frac{\gamma}{\pi}} \frac{1}{\delta}\right) \quad \text{و کافی است اطمینان حاصل شود که} \quad \frac{c^2 - \varepsilon + \varepsilon^2}{\gamma c^2} \geq c^2 - \frac{\Delta}{9}$$

به عبارت دیگر ما به آن نیاز داریم که:

$$c^2 > \gamma \ln\left(\sqrt{\frac{\gamma}{\pi}}\right) + \gamma \ln\left(\frac{1}{\delta}\right) + \ln\left(e^{\frac{\Delta}{9}}\right) = \ln\left(\frac{\gamma}{\pi}\right) + \ln\left(e^{\frac{\Delta}{9}}\right) + \gamma \ln\left(\frac{1}{\delta}\right)$$

که از آنجایی که $\left(\frac{\gamma}{\pi}\right) e^{\frac{\Delta}{9}} < 1.55$ هرگاه $\left(\frac{\gamma}{\delta}\right) > 2 \ln\left(\frac{1.55}{\delta}\right)$ باشد برقرار است.

بنگذاریم R را به صورت $R = R_1 \cup R_2$ تقسیم کنیم که در آن $R_1 = \{x \in R : |x| \leq \frac{c\Delta f}{\varepsilon}\}$ و $R_2 = \{x \in R : |x| > \frac{c\Delta f}{\varepsilon}\}$ هر زیر مجموعه $S \subseteq R$ را ثابت (fix) می کنیم و تعریف می کنیم:



$$S_1 = \{f(x) + x \mid x \in R_1\} \quad S_2 = \{f(x) + x \mid x \in R_2\}$$

پس داریم:

$$\Pr_{x \sim N(0, \sigma^2)} [f(x) + x \in S] = \Pr_{x \sim N(0, \sigma^2)} [f(x) + x \in S_1] + \Pr_{x \sim N(0, \sigma^2)} [f(x) + x \in S_2]$$

$$\leq \Pr_{x \sim N(0, \sigma^2)} [f(x) + x \in S_1] + \delta \leq e^\epsilon \left(\Pr_{x \sim N(0, \sigma^2)} [f(y) + x \in S_1] \right) + \delta$$

که differential privacy (ϵ, δ) را برای مکانیزم گاوسی در یک بعد نتیجه می دهد.

حال برای ابعاد بالا و به شکل برداری تعمیم می دهیم. برای تعمیم این قضیه به توابع $\mathbb{R}^m$ تعریف می کنیم $\Delta f = \Delta_2 f$ اکنون می توانیم این استدلال را با استفاده از norm های اقلیدسی تکرار کنیم.

فرض کنید v هر برداری باشد که $\|v\| \leq \Delta f$ را برآورده کند. برای یک جفت ثابت از پایگاه داده های x و y ما به $v = f(x) - f(y)$ علاقه مند هستیم زیرا این چیزی است که نویز ما با ید آن را پنهان کند. مانند حالت یک بعدی ما به دنبال شرایطی روی σ هستیم که تحت آن privacy loss زیر

$$\left| \ln \frac{e^{\left(\frac{-1}{2\sigma^2}\right) \|x - \mu\|^2}}{e^{\left(\frac{-1}{2\sigma^2}\right) \|x + v - \mu\|^2}} \right|$$

توسط ϵ محدود شود. در اینجا μ از $\mathcal{N}(0, \Sigma)$ انتخاب شده است، که در آن $\sum$ یک ماتریس قطری با درایه های σ^2 است، $\mu = (0, \dots, 0)$ و از این رو

$$\left| \ln \frac{e^{\left(\frac{-1}{2\sigma^2}\right) \|x - \mu\|^2}}{e^{\left(\frac{-1}{2\sigma^2}\right) \|x + v - \mu\|^2}} \right| = \left| \ln e^{\left(\frac{-1}{2\sigma^2}\right) [\|x - \mu\|^2 - \|x + v - \mu\|^2]} \right| = \left| \frac{1}{2\sigma^2} (\|x\|^2 - \|x + v\|^2) \right|$$

ما از این واقعیت استفاده خواهیم کرد که توزیع یک نرمال متقارن کروی (spherically symmetric normal) مستقل از پایه متعامدی است که نرمال های تشکیل دهنده آن از آن گرفته شده اند، پس می توانیم در پایه ای کار کنیم که با v همسو (aligned) باشد. چنین پایه ای را با $b_1, \dots, b_m$ تعیین می کنیم و x را با گرفتن طول های نشانه دار $\lambda_i \sim \mathcal{N}(0, \sigma^2)$ برای $i \in [m]$ برمی داریم و سپس $x^{[i]} = \lambda_i b_i$ را تعریف می کنیم و درجه نهایت $x = \sum_{i=1}^m x^{[i]}$ را در نظر می گیریم. بدون از دست دادن کلیت فرض می کنیم b موازی v است. ما به $\|x\|^2 - \|x + v\|^2$ علاقه مند هستیم.

مثلاً قائم الزامی با قاعده $x^{[i]} + v$ وضع $\sum_{i=1}^m x^{[i]}$ مورد بهره v در نظر بگیرد. و ترائین مثلث $x + v$ است.

(12)

Subject:

Year: Month: Date:

$$\|x+v\|^2 = \|v+x^{[1]}\|^2 + \sum_{i=2}^m \|x^{[i]}\|^2 \quad \text{و} \quad \|x\|^2 = \sum_{i=1}^m \|x^{[i]}\|^2$$

از آنجایی که v موازی با $x^{[1]}$ است، داریم: $\|v+x^{[1]}\|^2 = (\|v\| + \lambda_1)^2$

$$\|x+v\|^2 - \|x\|^2 = \|v\|^2 + 2\lambda_1 \cdot \|v\| \quad \text{بنابراین}$$

به یاد بیاورید که $\|v\| \leq \Delta f$ و $\lambda \sim N(0, \sigma^2)$ بنابراین اکنون دقیقاً به حالت

یک بعدی برشته ایم و به جای x در معادله ① λ_1 می نویسیم:

$$\left| \frac{1}{2\sigma^2} (\|x\|^2 - \|x+v\|^2) \right| \leq \left| \frac{1}{2\sigma^2} (2\lambda_1 \Delta f - (\Delta f)^2) \right|$$

و بقیه استدلال به شرح فوق ادامه می یابد. $\square$